

CHAPTER-6-INTRODUCTION TO MACHINE LEARNING

Wattanapong Suttapak



OUTLINE

- What is Machine Learning?
- Why we need Machine Learning?
- Machine Learning Concept
- Supervised Learning
- Unsupervised Learning

WHAT IS MACHINE LEARNING?



บทนำ

- ในยุคที่เทคโนโลยีก้าวหน้า เครื่องจักรไม่ใช่แค่เครื่องมือธรรมดา
- เครื่องจักรกลายเป็นผู้ช่วยที่ชาญฉลาดในการช่วยตัดสินใจ (decision-making processes)
- หนึ่งในกุญแจเทคโนโลยีที่ขับเคลื่อนการเปลี่ยนแปลงนี้คือ การเรียนรู้ของเครื่องจักร (Machine Learning)

DEFINITION OF MACHINE LEARNING

- Machine Learning (ML) เป็นแขนงหนึ่งของ Artificial Intelligence ที่เพิ่มพลังคอมพิวเตอร์โดยการเรียนรู้จากข้อมูล
- ML ไม่ได้ขึ้นกับภาษาเขียนโปรแกรมภาษาใดภาษาหนึ่ง สามารถพัฒนาได้ทั้ง Matlab C++ Java และ Python
- ML ใช้อัลกอริทึมเรียนรู้จากรูปแบบ (Pattern) และ ข้อมูลพิเศษ (Insight) จากข้อมูลที่ใช้สอน (Training Dataset)

WHY MACHINE LEARNING MATTERS?

- ML พัฒนาขึ้นให้มีความสามารถเป็นไปตาม (lies in) เป้าหมายที่ผู้สร้างต้องการ เช่น
 - ใช้ในการวิเคราะห์ข้อมูลจำนวนมาก ซึ่งมนุษย์ไม่สามารถเรียนรู้ข้อมูลเหล่านี้ในเวลาช่วงชีวิตได้
 - การจดจำรูปแบบ (Recognize Patterns) ซึ่งมีความน่าจะเป็นหลากหลาย การหาความสัมพันธ์จากรูปแบบข้อมูลที่ป้อนขึ้น นั้นมีความหลากหลายสูงมาก
 - พยากรณ์ หรือตัดสินใจโดยมีมนุษย์เข้ามาช่วยเหลือน้อยที่สุด (Minimal Human Intervention) จนถึงไม่มีเลย

KEY CONCEPTS IN MACHINE LEARNING

- Fundamental concepts in machine learning
 - Supervised Learning: [Learning](#) from [labeled data](#).
 - Classification: [Categorizing](#) data into predefined [classes](#) (จำแนกข้อมูลตามจำนวนคลาสที่กำหนด)
 - Regression: [Predicting](#) numerical values (พยากรณ์ข้อมูลที่ไม่เคยเรียนรู้มาก่อน)
 - Unsupervised Learning: [Learning](#) patterns from [unlabeled data](#).
 - Clustering: [Grouping](#) similar data points (แบ่งกลุ่มข้อมูลตามจำนวนคลาสที่กำหนด)

KEY CONCEPTS IN MACHINE LEARNING

- ในปัจจุบันมีวิธีการเรียนรู้ที่เพิ่มขึ้นมาเนื่องด้วยประเภทข้อมูลที่แตกต่างกัน และวัตถุประสงค์ที่แตกต่างจากในอดีต
 - Weakly (Semi) supervised Learning จำนวนรูปมี labeled น้อย
 - Few-shot supervised Learning เรียนรู้จากรูป 2 – 3 รูป
 - One-shot Learning เรียนรู้จากข้อมูลรูปภาพเพียงรูป (คู่) เดียว
 - Zero-shot Learning คล้าย Unsupervised Learning แต่ไม่ใช้การจัดกลุ่ม เป็น Object Detection หรือ Object Segmentation

SUPERVISED LEARNING

Supervised Learning เป็นหนึ่งในวิธีการเรียนรู้ของ ML

Algorithm จะเรียนรู้จาก **labeled dataset**

ทุก ๆ input จะมี output ที่ต้องการ (Desire output, Ground-truth, Label)

Model ที่ถูก Train จะพยายามคำนวณ หรือ พยากรณ์ (Actual, Predicted Output) ให้ผลลัพธ์ที่ได้จาก Model มีค่าใกล้เคียงกับ Ground-truth

เป้าหมายของการ Train Model คือ พยากรณ์ข้อมูลที่ไม่เคยเห็นมาก่อน ให้แม่นยำเหมือนข้อมูลที่ถูก Train (~**Generalization**)

SUPERVISED LEARNING

Input Features (X): These are the variables or attributes that the model uses to make predictions.

Output Labels (Y): These are the desired outcomes that the model aims to predict.

Model (f(.)): The algorithm or mathematical function that maps inputs to outputs.

Definition $Y = f(X)$



SUPERVISED LEARNING

- In supervised training consists of three processes
 1. Training
 2. Validation
 3. Testing

SUPERVISED LEARNING

- Training

$$Y' = f(X) \quad \text{for } X \in \mathbb{R}$$

$$\text{Minimize error} = \min |Y - Y'| \rightarrow 0$$


Training Input (X)

Predicted output (Y')

Output (Y)

SUPERVISED LEARNING


- Training



$C_i = \{1, 2, m\}$ เมื่อ m คือจำนวนของ class ทั้งหมด สำหรับ $i = \{1, 2, \dots, n\}$ จากตัวอย่าง $n = 12$

SUPERVISED LEARNING


- Training



SUPERVISED LEARNING


- Validation

- Check model performance by using new data (Never feed in training)
- **Overfitting** prevention



SUPERVISED LEARNING

- Testing (Inference)



SUPERVISED LEARNING: EXAMPLES

- **Classification**

- + Data Classification, Image Classification, Audio Classification

- **Prediction (Regression)**

- + Flood Water Level, Time Series Forecast (Stock, Crypto, Lottery)

- **Deep Learning Technique**


- + Image Detection, Image Segmentation, Voice Splitter, Speech Recognition, Object Tracking

- **Generative Adversarial Network (GAN)**

- + Text-to-Image, Inpainting, Deep Fake, Speech Fake

CLASSIFICATION


- Iris Dataset



- 150 samples for 3 classes
 - Iris Setosa
 - Iris Versicolour
 - Iris Virginica
- Each sample contains
 - 1. sepal length in cm
 - 2. sepal width in cm
 - 3. petal length in cm
 - 4. petal width in cm

CLASSIFICATION

- Animal Classification



- 28,000 images for 10 classes
 - dog, cat, horse, spider, butterfly, chicken, sheep, cow, squirrel, elephant.

***Image Processing

CLASSIFICATION


- Covid-19 Cough Classification

```
▼ "root" : { 9 items
  "datetime" : string "2020-04-12T04:02:18.159383+00:00"
  "cough_detected" : string "0.9301"
  "latitude" : string "40.0"
  "longitude" : string "-75.1"
  "age" : string "34"
  "gender" : string "male"
  "respiratory_condition" : string "True"
  "fever_muscle_pain" : string "False"
  "status" : string "healthy"
}
```

- 25,000 crowdsourced cough recordings
- a wide range of participant ages, genders, geographic locations, and COVID-19 statuses

REGRESSION

Air Quality PM2.5



REGRESSION

BTC prediction



UNSUPERVISED LEARNING

Unsupervised Learning

- is such an **algorithm** presented with **unlabeled data**
- its task is to **find patterns, relationships, or structures** of data **without guidance**.

UNSUPERVISED LEARNING

Input Features (X): These are the variables or attributes that the model uses to make clustering.

Cluster (C): These are the grouping outcomes that the model aims to cluster.

Model (f(.)): The algorithm or mathematical function that maps inputs to outputs.

Definition $f(X) \rightarrow C$ when $X \in \{x_1, x_2, \dots, x_n\}$, $C \in \{c_1, c_2, \dots, c_m\}$,

n is number samples, m is number of clusters




UNSUPERVISED LEARNING

- In unsupervised training all processes are the same as supervised learning
 1. Training
 2. Validation
 3. Testing

UNSUPERVISED LEARNING EXAMPLES

- Hard C-mean Algorithm
- Fuzzy C-mean Algorithm
- tSNE




PERFORMANCE MATRICES



PERFORMANCE MATRICES

- การจำแนกวัตถุ (Object Classification)
- การตรวจจับวัตถุ (Object Detection)
- การแบ่งส่วนวัตถุ (Object Segmentation)

การจำแนกวัตถุ (OBJECT CLASSIFICATION)



PERFORMANCE MATRICES

- การวัดประสิทธิภาพจะใช้ตารางสับสน (Confusion Matrix) ในการแสดงผลการพยากรณ์ของโมเดล
- โดยจะแสดงให้เห็นว่าโมเดลมีการจำแนกข้อมูลแต่ละคลาส (Class) ได้ถูกต้องหรือผิดพลาดอย่างไร เมื่อเทียบกับค่าจริง (Actual Value) ของข้อมูลนั้นๆ โดยทั่วไปแล้ว สำหรับปัญหาการจำแนกแบบไบนารี (Binary Classification) ที่มีเพียงสองคลาส เช่น คลาส "เป็น" และ "ไม่เป็น" เราจะสามารถสร้าง Confusion Matrix (คอนฟิวชันเมทริกซ์) ได้ดังนี้

		ค่าความจริง (Actual)	
		Class 1 (Positive)	Class 2 (Negative)
คาดการณ์ (Predicted)	Class 1 (Positive)	True Positive (TP) (บวกจริง)	False Positive (FP) (บวกปลอม)
	Class 2 (Negative)	False Negative (FN) (ลบปลอม)	True Negative (TN) (ลบจริง)

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	TP	FP
	ไม่เป็น	FN	TN

ตัวอย่างเช่น การวินิจฉัยโรคปอดอักเสบ

- ผลทำนายบอกว่า เป็น และค่าความจริง คือ เป็น
จะถูกนับว่าเป็น TP
- ผลทำนายบอกว่า เป็น และค่าความจริง คือ ไม่เป็น
จะถูกนับว่าเป็น FP (Over-detection)
- ผลทำนายบอกว่า ไม่เป็น และค่าความจริง คือ เป็น
จะถูกนับว่าเป็น FN (เป็นแต่ตรวจไม่เจอ)
- ผลทำนายบอกว่า ไม่เป็น และค่าความจริง คือ ไม่เป็น
จะถูกนับว่า TN (ไม่เป็นจริง ๆ)

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	0	0
	ไม่เป็น	0	0

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	0	0
	ไม่เป็น	1	0

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	0	0
	ไม่เป็น	1	1

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	1	1
	ไม่เป็น	2	1

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	2	2
	ไม่เป็น	4	2

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	3	3
	ไม่เป็น	6	3

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	5	4
	ไม่เป็น	6	5

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- ให้ผลการทำนายจากโมเดล มาจากการอ่านฟิล์ม Xray จำนวน 20 ภาพ และผลการทำนายออกเป็นตัวเลขดังนี้

0 0 1 1 0 1 1 0 0 0 1 0 1 0 0 1 0 1 1 0

- สมมติให้ผลการวินิจฉัยจากแพทย์เป็น

1 0 1 0 1 0 1 0 1 1 1 0 0 1 1 0 0 1 1 0

- กำหนดให้ 0 หมายถึง ไม่เป็น และ 1 หมายถึง เป็น

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	5 (TP)	4 (FP)
	ไม่เป็น	6 (FN)	5 (TN)

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- จากตาราง สามารถคำนวณ ความถูกต้องเป็น

$$\begin{aligned} &= \frac{TP+TN}{TP+FP+FN+TN} \\ &= \frac{5+5}{20} = 0.5 \text{ หรือ } 50\% \end{aligned}$$

CONFUSION MATRIX

		ค่าความจริง (Actual)	
		เป็น	ไม่เป็น
คาดการณ์ (Predicted)	เป็น	5 (TP)	4 (FP)
	ไม่เป็น	6 (FN)	5 (TN)

ตัวอย่างการวัดค่าการวินิจฉัยโรคปอดอักเสบ ด้วยโมเดล

- การคำนวณ Sensitivity (ความไว) และ Specificity (ความจำเพาะ)
- Sensitivity บ่งบอกถึงความสามารถในการทำนายคลาส 1 ได้ถูกต้อง ในที่นี้คือ ประสิทธิภาพในการวินิจฉัยคนที่เป็นโรค
- Specificity บ่งบอกถึงความสามารถในการทำนายคลาส 0 ได้ถูกต้อง ในที่นี้คือ ประสิทธิภาพในการวินิจฉัยคนปกติ

$$\text{Sensitivity} = \frac{TP}{TP+FN} \text{ และ } \text{Specificity} = \frac{TN}{TN+FP}$$

Sensitivity = 45.45% และ Specificity = 55.56%

Sens. สูงบ่งบอกโอกาสพลาดในการวินิจฉัยว่าเป็นโรคน้อย

Spec. สูงบ่งบอกโอกาสพลาดในการวินิจฉัยว่าไม่เป็นโรคน้อย

* ระวังการสลับคลาส Active (คลาส 1) ความหมายจะแปลตาม Active Class

THANK YOU

