



CHAPTER-7-DECISION TREE

Wattanapong Suttapak



2 OUTLINE

- Definition of Decision Tree
- Decision Tree Classification
- The Example of Decision Tree Classification
- Decision Tree Regression
- The Example of Decision Tree Regression

3 DEFINITION

- **Decision Trees** หรือ แผนภาพการตัดสินใจเป็นหนึ่งในอัลกอริทึม **machine learning** ที่นิยมใช้งาน ทั้งในงานด้าน **classification** และ **regression**
- **Decision Tree** มีลักษณะของข้อมูล (Node) ประกอบกันเป็นรูปของต้นไม้ (Tree) โดยแต่ละข้อมูล (Node) จะถูกแบ่งแยกข้อมูลด้วยจุดตัดสินใจ (Decision Point)
- ทำให้ เมื่อมีข้อมูล (Node) ใหม่เข้ามา **Decision Tree** จะสามารถพยากรณ์ว่า **Node** ควรอยู่ภายใต้จุดตัดสินใจใด

4 DECISION-TREE CLASSIFICATION

Binary classification

- Classify data into 2 classes

Multiclass Classification

- Classify data into multiple classes

5 DECISION-TREE CLASSIFICATION

Binary classification

- Classify data into 2 classes

Multiclass Classification

- Classify data into multiple classes


6

ตัวอย่าง DECISION TREE



7 DECISION-TREE CLASSIFICATION

Time Complexity : $O(\log n)$ in Best Case




8 EXAMPLE I

ตัวอย่างเช่นการพยากรณ์เกรดที่ได้

Input = คะแนน


Output = เกรดที่ได้

Time Complexity : $O(n)$ in Worst Case




9 EXAMPLE I

Time Complexity : $O(\log_2 n)$



10

Time Complexity : $O(\log_2 n)$




II EXAMPLE I

ตัวอย่าง ชุดข้อมูลจริง ค้นหาเกณฑ์ตัดเกรด เพื่อคาดการณ์เกรดที่ควรจะเป็นของข้อมูลทดสอบ (Testing Dataset)

Train								Test							
student1	71.29	B	student21	66.04	C+	student41	47.41	D+	student61	47.84	student71	77	student81	76.18	
student2	67.14	C+	student22	33.7	F	student42	55.6	C	student62	67.27	student72	50.64	student82	82.5	
student3	54.52	C	student23	49.64	D+	student43	50	D+	student63	63.73	student73	59.46	student83	48.3	
student4	71	B	student24	54.97	C	student44	66.97	C+	student64	47.6	student74	52.14	student84	57.41	
student5	57.26	C	student25	59.93	C	student45	41.8	D	student65	67.5	student75	44.03	student85	54.1	
student6	65.64	C+	student26	41.64	D	student46	68.67	C+	student66	19.59	student76	55.33	student86	50.07	
student7	56.52	C	student27	56.81	C	student47	55.6	C	student67	74.64	Student77	69.5	student87	52.4	
student8	28.06	F	student28	40.34	D	student48	56.17	C	student68	45.12	Student78	52.49	student88	44.27	
student9	48.71	D+	student29	63.8	C	student49	59.5	C	student69	68.81	student79	52.37	student89	61.12	
student10	33.5	F	student30	68.93	C+	student50	57.66	C	student70	38.89	student80	63.67	student90	52.36	
student11	42.44	D	student31	62.52	C	student51	63.36	C							
student12	11.43	F	student32	40.94	D	student52	16.6	F							
student13	55.18	C	student33	65.64	C+	student53	46.37	D+							
student14	57.59	C	student34	52.34	D+	student54	46.6	D+							
student15	46.53	D+	student35	71.43	B	student55	77.37	B+							
student16	47.98	D+	student36	53.46	D+	student56	80	A							
student17	50.17	D+	student37	50.14	D+	student57	56.51	C							
student18	51.99	D+	student38	70.13	B	student58	65.98	C+							
student19	58.95	C	student39	54.21	D+	student59	54.51	C							
student20	65.87	C+	student40	66.38	C+	student60	56.64	C							

I2 EXAMPLE 2




จะจัดกลุ่มข้อมูลเป็น 2 กลุ่ม คือ คลาสวงกลม และคลาสสี่เหลี่ยมผืนผ้า
ได้อย่างไร?


แนวทาง:

เลือก **Feature** ที่ดีที่สุดสำหรับการแบ่งข้อมูล


13 EXAMPLE 2




จะจัดกลุ่มข้อมูลเป็น 2 กลุ่ม คือ คลาสวงกลม และคลาสสี่เหลี่ยมผืนผ้า
ได้อย่างไร?



14 EXAMPLE 2



จะจัดกลุ่มข้อมูลเป็น 2 กลุ่ม คือ คลาสวงกลม และคลาสสี่เหลี่ยมผืนผ้า
ได้อย่างไร?



15 ข้อดีของวิธี DECISION TREE

- แปลผลง่ายต่อการเข้าใจ โดยสามารถแสดงข้อมูลเป็นแผนภาพได้ (Visualization)
- ไม่ต้องมี กระบวนการแปลงข้อมูลก่อนเข้า Decision Tree
- จัดการข้อมูล Non-linear ได้ด้วย

16 LIMITAION

- **Overfitting:** ง่ายต่อการเกิด **overfitting** กรณีข้อมูลมี **noise** เยอะ
- **Instability:** ไม่เสถียร การเปลี่ยนแปลงข้อมูลเพียงเล็กน้อย นำไปสู่การเปลี่ยนแปลงโครงสร้าง **Decision Tree** ได้
- **Biased to Dominant Classes:** ค่าการตัดสินใจ โอนเอียงไปยังกลุ่มข้อมูลส่วนใหญ่

17 CLASSIFICATION ALGORITHM

ขั้นตอนการ Classify ข้อมูลด้วย Decision Tree แบ่งเป็น 6 ขั้นตอน

- **Data Exploration:**
 - Load and explore the dataset.
 - Check for missing values and handle them if necessary.
 - Visualize the relationships between the features and the target variable.
- **Data Preprocessing:**
 - Encode categorical variables if there are any.
 - Split the dataset into training and testing sets.
- **Decision Tree Classification:**
 - Build a decision tree classification model using a library of your choice (e.g., scikit-learn).
 - Train the model on the training set.
- **Model Evaluation:**
 - Evaluate the performance of the model on the testing set.
 - Use appropriate regression metrics such as Mean Absolute Error (MAE), Mean Squared Error (MSE), or R-squared.
- **Visualize the Decision Tree:**
 - Visualize the decision tree to understand the splits and decision-making process.
- **Prediction:**
 - Use the trained model to classify the output in testing dataset.

18 CLASSIFICATION ALGORITHM

1. สำรวจข้อมูล:

- โหลด และสำรวจข้อมูล
- กรณีมีข้อมูลหายไป ให้จัดการข้อมูลนั้น โดยการลบ หรือแทนที่ด้วยค่าประมาณการจากค่าใกล้เคียง
- Visualize ความสัมพันธ์ระหว่าง features และเป้าหมาย Output Class

2. Data Preprocessing:

- แปลงค่า class อยู่ในรูปแบบของตัวเลข
- แยก dataset เป็น training และ testing sets.

3. Decision Tree Classification:

- Build a decision tree classification model using a library of your choice (e.g., scikit-learn).
- Train the model on the training set.

19 CLASSIFICATION ALGORITHM

4. Model Evaluation:

- Evaluate ประสิทธิภาพของ model สำหรับข้อมูล Validation
- คำนวณค่าความผิดพลาดด้วย Mean Absolute Error (MAE), Mean Squared Error (MSE), or R-squared.

5. Visualize the Decision Tree:

- Visualize the decision tree เพื่อดูการตัดสินใจที่เกิดขึ้นจากการ Train

6. Prediction:

- นำ trained model ไป classify testing dataset.

20

REGRESSION USING DECISION TREE



21 WHAT IS REGRESSION?

- **Regression** เป็นการพยากรณ์ผลลัพธ์ของข้อมูล โดยพยากรณ์เป็นค่าตัวเลขออกมา

$$Y' = f(X) + \varepsilon \quad \text{for } X \in \mathbb{R}$$

Training Input (X)

Predicted output (Y')

Noise (ε)

- **Regression** เป็นการพยากรณ์ตัวเลขผลลัพธ์ที่มีค่าเป็นค่าใดก็ได้ $Y' \in \mathbb{R}$
- แตกต่างจากวิธีการ **Classification** ที่เป็นการพยากรณ์ว่าผลลัพธ์อยู่ในกลุ่มใด (จำนวนกลุ่มจะเป็นตัวเลขที่จำกัด)
- ในหัวข้อนี้จะพูดถึงการ **Regression** ด้วย **Decision Tree** โดยการพยากรณ์ **Node** ข้อมูล เป็นตัวเลข

22 REGRESSION APPLICATION

- Weather Forecast เช่น คุณหมอมิ PM2.5
- พยากรณ์ปริมาณน้ำ
- พยากรณ์ราคาหุ้น ทองคำ
- พยากรณ์ราคาบ้าน

23 OPTIMIZATION ALGORITHM IN DECISION TREE

- ในการ Train Machine Learning ทุกประเภท จะต้องมีการ Optimization Function เพื่อให้ Model เรียนรู้ได้ดีขึ้น
- ในหัวข้อ Neural Network จะใช้ Mean Square Error หรือ Cross Entropy Loss เพื่อทำการลดค่า Error ระหว่าง Output จริงกับ Output ทำนาย ให้มีค่าเข้าใกล้ 0
- ใน Decision Tree ก็ต้องมี Optimization Function เหมือนกัน โดยจะเรียกว่า Criterion Function
- Criterion Function จะเป็นฟังก์ชัน เพื่อคำนวณค่า Error ระหว่าง Output จริงกับ Output ทำนาย ให้มีค่าใกล้กันที่สุด
- Criterion Function ของ Decision Tree จะไม่มี Gradient Descent เพื่อช่วยการเรียนรู้ของ Model

24 OPTIMIZATION ALGORITHM IN DECISION TREE

CLASSIFICATION

- Gini Impurity (ใช้กับ Regression ได้)
- Entropy
- Gain Ratio
- Chi-Square
- Hellinger Distance
- Misclassification Rate
- Log Loss

REGRESSION

- Mean Squared Error (MSE)
- Mean Absolute Error (MAE)
- Friedman's MSE
- Poisson Deviance
- Reduction in Variance

25 GINI

ไม่ออกสอบ

- Gini Impurity is a measure of the likelihood that a randomly chosen element from the dataset would be incorrectly classified if it were randomly labeled according to the distribution of labels in the dataset.

Formula

The formula for Gini Impurity at a node is:

$$Gini = 1 - \sum_{i=1}^C p_i^2$$

Where:

- p_i is the proportion of samples that belong to class i at the node.
- C is the total number of classes.

How it Works

- **Pure Node:** If a node contains only one class, the Gini Impurity is 0 (pure node).
- **Impure Node:** If the samples are uniformly distributed among the classes, Gini Impurity reaches its maximum (close to 0.5 for two classes).

26 ENTROPY

ไม่ออกสอบ

- Entropy is a measure of the disorder or impurity in the dataset. It quantifies the uncertainty or randomness in the class distribution at a node.

Formula

The formula for Entropy at a node is:

$$Entropy = - \sum_{i=1}^C p_i \log_2(p_i)$$

Where:

- p_i is the proportion of samples that belong to class i at the node.
- C is the total number of classes.

How it Works

- **Pure Node:** If all samples belong to one class, the Entropy is 0 (indicating no impurity).
- **Impure Node:** If the samples are evenly distributed among the classes, Entropy is at its maximum (1 for two classes).

27 LOG LOSS

ไม่ออกสอบ

- To measure the uncertainty of predictions, penalizing more heavily the confident and incorrect predictions.

- **Formula:**

$$\text{Log Loss} = -\frac{1}{n} \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

where p_i is the predicted probability of the positive class.

- **Usage:** Common in logistic regression and some decision trees, especially when probabilistic predictions are important.

28

THANK YOU

