

บทที่ 10

จริยธรรมในปัญญาประดิษฐ์

Ethics in Artificial Intelligence

226361 แนวคิดปัญญาประดิษฐ์

ผศ. ดร.วัฒนพงศ์ สุทธภักดิ์

สาขาวิชาวิศวกรรมคอมพิวเตอร์ มหาวิทยาลัยพะเยา

วัตถุประสงค์การเรียนรู้

1

อธิบายหลักการจรรยาบรรณปัญญาประดิษฐ์ 10 มิติ

ตามแนวทางของ UNESCO และบริบทของประเทศไทย

2

วิเคราะห์แหล่งที่มาของความลำเอียงในระบบ AI

พร้อมเสนอแนวทางลดผลกระทบที่เกิดขึ้น

3

อธิบายกระบวนการประเมินผลกระทบทางจริยธรรม (EIA)

ทั้ง 3 ส่วน และเกณฑ์การวิเคราะห์ 5 ด้าน

4

ประยุกต์กระบวนการ EIA กับกรณีการใช้งานจริง

และกำหนดมาตรการลดผลกระทบที่เหมาะสม

เหตุใดจริยธรรมปัญญาประดิษฐ์จึงสำคัญ

เมื่อความสามารถของ AI เพิ่มขึ้น ความเสี่ยงและผลกระทบต่อบุคคล องค์กร และสังคมก็เพิ่มขึ้นตามไปด้วย

ยิ่งสำคัญมากขึ้นในยุคของ Generative AI และโมเดลภาษาขนาดใหญ่ ซึ่งกระทบผู้ใช้งานหลายพันล้านคนทั่วโลก

ประเด็นที่ต้องพิจารณา

- การละเมิดความเป็นส่วนตัว
- ความไม่เป็นธรรมต่อกลุ่มเปราะบาง
- การตัดสินใจที่ไม่โปร่งใส
- ผลกระทบต่อสิทธิมนุษยชน

UNESCO

Recommendation on the Ethics of AI
รับรองโดย 194 ประเทศ ปี 2021

ETDA / AIGPC

คู่มือการประเมินผลกระทบ
ทางจริยธรรมปัญญาประดิษฐ์

PDPA

พ.ร.บ. คุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562
ข้อมูลอ่อนไหว: สุขภาพ ชีวมิติ เชื้อชาติ

หลักการจริยธรรมปัญญาประดิษฐ์ 10 มิติ

กรอบอ้างอิงสากลตาม UNESCO ที่ประเทศไทยนำมาปรับใช้

รูปที่ 10.1 หลักการจริยธรรมปัญญาประดิษฐ์ 10 มิติ ตามแนวทางของ UNESCO
(Recommendation on the Ethics of Artificial Intelligence, 2021)



■ ใช้ในขั้นกำหนดขอบเขตการประเมิน (Scoping Questions)
■ ใช้ในขั้นประเมินตามหลักการและวิเคราะห์ผลกระทบ (Principles-Based / Impact Mapping)

สาระสำคัญของหลักการ มิติที่ 1–5

1

ความสมเหตุสมผลและการไม่ก่อให้เกิดอันตราย

ใช้ AI ได้สัดส่วนกับวัตถุประสงค์ ไม่ละเมิดสิทธิมนุษยชน

2

ความปลอดภัยและความมั่นคงปลอดภัย

เชื่อถือได้ ป้องกันข้อผิดพลาดและการโจมตีทางไซเบอร์

3

ความเป็นธรรม การไม่เลือกปฏิบัติ และความหลากหลาย

ไม่ก่อให้เกิดการเลือกปฏิบัติหรือความเหลื่อมล้ำ

4

ความยั่งยืน

พิจารณาผลกระทบยาวต่อสังคม เศรษฐกิจ และสิ่งแวดล้อม

5

ความเป็นส่วนตัวและการคุ้มครองข้อมูล

คุ้มครองข้อมูลตลอดวงจรชีวิต ออกแบบโดยคำนึงตั้งแต่ต้น

สาระสำคัญของหลักการ มิติที่ 6–10

6

การกำกับดูแลและการตัดสินใจโดยมนุษย์

มนุษย์ตรวจสอบ ทบทวน แก้ไข หรือยกเลิกได้เมื่อจำเป็น

7

ความโปร่งใสและความสามารถในการอธิบาย

ผู้ใช้ทราบว่ามีการใช้ AI และเข้าถึงคำอธิบายผลลัพธ์ได้

8

ความรับผิดชอบและการรับผิดชอบ

ผลการตัดสินใจผูกพันกับมนุษย์ ตรวจสอบและสืบทอดกลับได้

9

ความตระหนักรู้และความรู้ความสามารถ

ส่งเสริมความเข้าใจ ไม่พึ่งพาการตัดสินใจของ AI มากเกินไป

10

การกำกับดูแลที่ปรับตัวได้และการมีส่วนร่วม

เปิดให้ผู้มีส่วนได้ส่วนเสียหลากหลายเข้ามามีส่วนร่วม

ที่มาของหัวข้อถัดไป

หัวข้อที่เหลือในบทนี้คือหลักการทั้ง 10 มิติ จัดกลุ่มใหม่และเรียงตามขอบเขตของผลกระทบ

หัวข้อในบทนี้	มิติที่	ระดับของผลกระทบ
ความเป็นธรรมและความลำเอียง	3	ข้อมูลและแบบจำลอง
ความโปร่งใสและความสามารถในการอธิบาย	7	ข้อมูลและแบบจำลอง
ความเป็นส่วนตัวและความปลอดภัย	5, 2	ระบบ
ความรับผิดชอบและการกำกับดูแลโดยมนุษย์	8, 6	ระบบและองค์กร
ความยั่งยืน	4	องค์กรและสังคม
ความตระหนักรู้และการกำกับดูแลแบบมีส่วนร่วม	9, 10	สังคม

ทำไมไม่เรียงตามเลขมิติ

เรียงจากสิ่งที่พบได้ในข้อมูลและแบบจำลอง ซึ่งผู้เรียนเพิ่งลงมือทำมา แล้วจึงขยายไปสู่ระดับระบบ องค์กร และสังคม

มิติที่ 1 อยู่ที่ใด

ไม่ได้ว่าด้วยคุณสมบัติของระบบ แต่เป็นคำถามว่าสมควรใช้ AI หรือไม่ จึงอยู่ในขั้นกำหนดขอบเขตของ EIA

ส่วนที่ 1


หลักการสำคัญรายมิติ

Key Ethical Principles in Practice

ความเป็นธรรมและความลำเอียง – มิติที่ 3

ความลำเอียงแฝงอยู่ได้ในทุกขั้นตอนของการพัฒนา ตั้งแต่การเก็บข้อมูลจนถึงการใช้งานจริง

รูปที่ 10.2 แหล่งที่มาของความลำเอียง (Bias) ในระบบ AI



แหล่งที่มาของความลำเอียง 4 ประเภท

1

ลำเอียงจากข้อมูล

Data Bias

ข้อมูลฝึกไม่ครอบคลุมกลุ่มประชากรทั้งหมดอย่างสมดุล เช่น ระบบจดจำใบหน้าที่ฝึกด้วยภาพคนผิวขาวเป็นส่วนใหญ่

2

ลำเอียงจากการเก็บข้อมูล

Collection Bias

วิธีเก็บข้อมูลสร้างความลำเอียงโดยไม่ตั้งใจ เช่น สัมภาษณ์ผ่านช่องทางออนไลน์เท่านั้น

3

ลำเอียงจากขั้นตอนวิธี

Algorithm Bias

การออกแบบโมเดลให้น้ำหนักกับคุณลักษณะบางอย่างมากเกินไป จนกระทบความเป็นธรรมของผลลัพธ์

4

ลำเอียงจากข้อมูลสะท้อนกลับ

Feedback Bias

ผลลัพธ์ของ AI ถูกนำกลับมาเป็นข้อมูลฝึก ทำให้ความลำเอียงเดิมถูกขยายให้รุนแรงขึ้น

ตัวอย่างผลกระทบของความลำเอียง

2018

Amazon ยกเลิกระบบ AI คัดเลือกผู้สมัครงาน

ระบบให้คะแนนผู้สมัครเพศหญิงต่ำกว่าเพศชายอย่างเป็นระบบ สาเหตุมาจากข้อมูลประวัติการรับสมัครย้อนหลัง 10 ปี ที่ใช้ฝึกโมเดล สะท้อนภาพอุตสาหกรรมเทคโนโลยีซึ่งมีผู้ชายเป็นส่วนใหญ่ โมเดลจึงเรียนรู้รูปแบบนั้นมาใช้นำนาย

ข้อสังเกตสำคัญ

ผลลัพธ์ที่ดูเหมือนเป็นกลางทางคณิตศาสตร์ อาจยังไม่เป็นธรรมในทางปฏิบัติ หากข้อมูลที่ใช้ฝึกโมเดลสะท้อนความลำเอียงที่มีอยู่เดิมในสังคม

ค่าความแม่นยำสูงไม่ได้รับประกันความเป็นธรรม ต้องวัดแยกตามกลุ่มประชากรเสมอ

ความโปร่งใสและความสามารถในการอธิบาย – มิติที่ 7

Transparency


เปิดเผยว่าระบบ AI ทำงานอย่างไร

Explainability


อธิบายได้ว่าเหตุใดจึงให้ผลลัพธ์เช่นนั้นในกรณีเฉพาะ

เมื่อ AI ตัดสินใจเรื่องสำคัญ ต้องอธิบายให้ผู้ได้รับผลกระทบเข้าใจได้ และเปิดช่องทางให้ขอทบทวน

รูปที่ 10.3 เปรียบเทียบความสามารถในการอธิบาย (Explainability)



โครงข่ายประสาทเทียมเชิงลึก (Deep NN)
อธิบายได้ยาก - เป็นกล่องดำ (Black Box)



รูปที่ 10.3 เปรียบเทียบความสามารถในการอธิบาย (Explainability)

ความเป็นส่วนตัวและความปลอดภัย – มิตินี้ 5 และ 2

ประเด็นที่นักพัฒนาต้องดูแลตลอดวงจรชีวิตของข้อมูล และภัยที่มุ่งเป้าไปที่โมเดลโดยตรง

ความเป็นส่วนตัว (มิตินี้ 5)

- 1 การเก็บข้อมูล**
เก็บเท่าที่จำเป็น ขอความยินยอมตาม PDPA
- 2 การส่งข้อมูล**
เข้ารหัสระหว่างส่งผ่านเครือข่าย
- 3 ข้อมูลฝึกโมเดล**
ไม่มีข้อมูลระบุตัวตน หรือทำ Anonymization
- 4 การป้อนคำสั่ง**
ระวังข้อมูลสำคัญในพรอมต์ที่อาจรั่วไหล

ความปลอดภัย (มิตินี้ 2)

- **Adversarial Attack**
สร้างข้อมูลหลอกให้โมเดลตัดสินใจผิด
- **Model Poisoning**
แทรกข้อมูลอันตรายในชุดข้อมูลฝึก
- **Model Stealing**
สร้างสำเนาโมเดลโดยไม่ได้รับอนุญาต
- **Privacy Attack**
ดึงข้อมูลส่วนบุคคลออกจากโมเดลที่ฝึกแล้ว

ความรับผิดชอบและการกำกับดูแลโดยมนุษย์ – มิติที่ 8 และ 6

AI ไม่สามารถเป็นผู้รับผิดชอบได้ ความรับผิดชอบจึงต้องผูกพันกับมนุษย์เสมอ

1

ผู้พัฒนาโมเดล

Model Developer

ผู้ออกแบบและฝึกโมเดล

2

ผู้พัฒนาระบบ

System Developer

ผู้พัฒนาระบบที่นำโมเดลไปใช้
งาน

3

องค์กรผู้นำไปใช้

Organization

องค์กรที่นำ AI ไปใช้งานจริง

4

ผู้ใช้งาน

User


ผู้มีส่วนในการตัดสินใจขั้น
สุดท้าย

หากขอบเขตความรับผิดชอบไม่ชัดเจน จะเกิดช่องว่างในการกำกับดูแล ทำให้การร้องเรียน การแก้ไข หรือการเยียวยาผู้ได้รับผลกระทบทำได้ยาก

การให้มนุษย์อยู่ในกระบวนการ (Human-in-the-loop)

ให้มนุษย์ตรวจสอบและตัดสินใจขั้นสุดท้าย แทนการปล่อยให้ระบบตัดสินใจโดยอัตโนมัติทั้งหมด

รูปที่ 10.4 แนวคิด Human-in-the-loop ในระบบ AI



สำคัญอย่างยิ่งในระบบที่มีผลกระทบสูง เช่น การวินิจฉัยโรค และการอนุมัติสินเชื่อ

ความยั่งยืนของระบบปัญญาประดิษฐ์ – มิติที่ 4

หลักการที่มักถูกมองข้าม แต่สำคัญมากขึ้นในยุคโมเดลขนาดใหญ่

ผลกระทบด้านสิ่งแวดล้อม

การฝึกโมเดลภาษาขนาดใหญ่ใช้พลังงานไฟฟ้าและน้ำหล่อเย็นในศูนย์ข้อมูลจำนวนมาก และการให้บริการยังใช้พลังงานต่อเนื่อง

แนวปฏิบัติที่ช่วยลดผลกระทบ

- เลือกโมเดลขนาดเหมาะสมกับงาน
- ลดขนาดโมเดล: Quantization, Pruning
- ใช้ Transfer Learning แทนการฝึกใหม่
- วัดและรายงานคาร์บอนฟุตพริ้นต์

ผลกระทบด้านสังคมและเศรษฐกิจ

การนำ AI มาใช้อาจส่งผลกระทบต่อโครงสร้างการจ้างงาน โดยเฉพาะงานที่มีลักษณะทำซ้ำ

สิ่งที่องค์กรควรดำเนินการ

- วางแผนพัฒนาทักษะใหม่ให้บุคลากร
- ดำเนินการควบคู่กับการนำเทคโนโลยีมาใช้
- พิจารณาช่องว่างทางดิจิทัล ไม่ให้กลุ่มที่เข้าไม่ถึงเทคโนโลยีเสียโอกาสมากขึ้น

ความตระหนักรู้และการกำกับดูแลแบบมีส่วนร่วม – มิตินี้ 9 และ 10

สองมิตินี้สะท้อนที่ "คน" และ "กระบวนการ" มากกว่าตัวเทคโนโลยี

Automation Bias

ผู้ใช้งานที่ขาดความเข้าใจข้อจำกัดของ AI มักยอมรับผลลัพธ์โดยไม่ตรวจสอบ แม้ในกรณีที่ผลลัพธ์นั้นผิดพลาดอย่างเห็นได้ชัด

แนวทางแก้ไข

จัดฝึกอบรมให้ผู้ใช้งานเข้าใจว่าระบบทำอะไรได้และทำอะไรไม่ได้ รวมถึงรู้ว่าควรตรวจสอบผลลัพธ์เมื่อใด

ขั้นตอนการประเมินตามคู่มือ ETDA

- 1 กำหนดผู้รับผิดชอบโครงการ
- 2 จัดตั้งทีมประเมินที่มีความหลากหลาย
- 3 ประเมินตามความเชี่ยวชาญของแต่ละคน
- 4 จัดประชุมเชิงปฏิบัติการร่วมกัน
- 5 เปิดให้ผู้มีส่วนได้ส่วนเสียมีส่วนร่วม
- 6 สรุปผลและกำหนดแนวทางดำเนินงาน

Responsible AI ตลอดวงจรชีวิตการพัฒนา

หลักการทั้งสิบมิติต้องถูกตั้งเป็นคำถามในทุกขั้นตอน ไม่ใช่ตรวจสอบเพียงครั้งเดียวเมื่อระบบเสร็จ

● ความสมเหตุสมผล จำเป็นและได้สัดส่วนกับวัตถุประสงค์หรือไม่	● ความเป็นธรรม กระทบกลุ่มใดอย่างไม่เป็นธรรมหรือไม่
● ความโปร่งใส ผู้ได้รับผลกระทบทราบและเข้าใจหรือไม่	● ความเป็นส่วนตัว ข้อมูลได้รับการปกป้องตามกฎหมายหรือไม่
● ความปลอดภัย ป้องกันการโจมตีและการใช้ผิดหรือไม่	● ความรับผิดชอบ มีผู้รับผิดชอบและตรวจสอบย้อนกลับได้หรือไม่
● การกำกับดูแลโดยมนุษย์ มนุษย์ควบคุมในระดับที่เหมาะสมหรือไม่	● ความยั่งยืน ใช้ทรัพยากรและพลังงานเหมาะสมหรือไม่

"ความรับผิดชอบของ AI เริ่มตั้งแต่วันแรกที่คุณนิยามปัญหา ไม่ใช่หลังจากโมเดลสร้างเสร็จ"

ส่วนที่ 2


การประเมินผลกระทบทางจริยธรรม

Ethical Impact Assessment (EIA)

กระบวนการประเมินผลกระทบทางจริยธรรม (EIA)

ไม่ได้ตัดสินว่าระบบ "ผ่าน" หรือ "ไม่ผ่าน" แต่ช่วยให้เห็นภาพอย่างเป็นระบบเพื่อประกอบการตัดสินใจ

รูปที่ 10.5 กระบวนการประเมินผลกระทบทางจริยธรรมปัญญาประดิษฐ์
(Ethical Impact Assessment: EIA) ตามคู่มือของ ETDA



รูปที่ 10.5 กระบวนการประเมินผลกระทบทางจริยธรรมปัญญาประดิษฐ์ (EIA)

เกณฑ์การวิเคราะห์ผลกระทบ 5 ด้าน

ใช้เปรียบเทียบผลกระทบและบันทึกเหตุผล ไม่ได้นำไปคำนวณเป็นคะแนนรวม

เกณฑ์	แนวทางการพิจารณา	ระดับที่ใช้ประเมิน
ระดับของผลกระทบ (Scale)	เกิดประโยชน์หรือความเสียหาย มากเพียงใด	บวก: สูงมาก / สูง / ปานกลาง / เล็กน้อย ลบ: ร้ายแรงอย่างยิ่ง / วิกฤต / รุนแรง / เล็กน้อย
ผู้ได้รับผลกระทบ (Impacted Parties)	ใครได้รับผล ไม่ใช่เฉพาะผู้ใช้ โดยตรง	โดยตรง / โดยอ้อม / ไม่ได้คาดการณ์ไว้
ระยะเวลา (Timescale)	เริ่มปรากฏเมื่อใด และคงอยู่นาน เพียงใด	ระยะสั้น / ระยะกลาง / ระยะยาว / ข้ามรุ่น
ความสามารถในการเยียวยา (Remediability)	ย้อนกลับหรือเยียวยาได้เพียงใด (เฉพาะผลกระทบเชิงลบ)	ต่ำมาก / ต่ำ / ปานกลาง / สูง
โอกาสเกิด (Likelihood)	มีแนวโน้มเกิดขึ้นมากน้อยเพียงใด	สูงมาก / สูง / ปานกลาง / ต่ำ

เมื่อใดควรดำเนินการ EIA

ไม่ใช่กิจกรรมครั้งเดียว แต่ต้องทบทวนตลอดวงจรชีวิตของระบบ AI

1

ก่อนนำไปใช้งาน

Before Deployment

ช่วงที่แนะนำมากที่สุด โดยเฉพาะระหว่างการ
ออกแบบพัฒนา การจัดหา และก่อนใช้จริง

2

ระหว่างและหลังใช้งาน

During and Post Deployment

ติดตามผลกระทบที่เกิดขึ้นจริง และตรวจสอบ
ว่าสมมติฐานยังสอดคล้องกับบริบท

3

เมื่อบริบทเปลี่ยนแปลง

When Context Changes

เปลี่ยนวัตถุประสงค์ แหล่งข้อมูล กลุ่มผู้ใช้งาน
หรือมีกฎหมายใหม่

ประเมินตั้งแต่ต้น ย่อมจัดการผลกระทบได้ดีกว่าการแก้ปัญหาหลังเกิดขึ้นแล้ว

กรณีศึกษา: ระบบ AI ช่วยคัดกรองผู้ป่วยนอก

กรณีสมมติเพื่อสาธิตการนำกระบวนการ EIA ไปใช้ ไม่ได้อ้างอิงระบบหรือโครงการจริง

ส่วนที่ 1 การกำหนดขอบเขต

- **วัตถุประสงค์:** ลดเวลารอคอยของผู้ป่วยเรื้อรัง ไม่ใช่เพื่อวินิจฉัยโรค
- **ผู้ใช้งานโดยตรง:** พยาบาลคัดกรอง
- **ผู้ได้รับผลโดยตรง:** ผู้ป่วยที่เข้ารับบริการทุกราย
- **ผู้ได้รับผลโดยอ้อม:** ญาติผู้ป่วย แพทย์เวร ผู้ป่วยรายอื่น
- **กลุ่มเปราะบาง:** ผู้สูงอายุ ผู้สื่อสารภาษาไทยไม่ได้ แรงงานข้ามชาติ ผู้พิการ

ส่วนที่ 2 ช่องว่างที่พบ

- **ความเป็นธรรม:** ข้อมูลฝึกมาจากโรงพยาบาลเดียว สัดส่วนผู้สูงอายุน้อย
- **ความโปร่งใส:** ยังไม่แจ้งผู้ป่วยว่ามีการใช้ AI
- **การอธิบาย:** แสดงเฉพาะระดับความเร่งด่วน ไม่แสดงเหตุผล
- **ความรับผิดชอบ:** ยังไม่กำหนดผู้รับผิดชอบเมื่อคัดกรองผิดพลาด
- **ความตระหนักรู้:** ยังไม่มีแผนอบรมพยาบาลเรื่องข้อจำกัดของระบบ

กรณีศึกษา: ผลกระทบเชิงลบและมาตรการรองรับ

คอลัมน์การประเมินเรียงตามลำดับ ระดับผลกระทบ / โอกาสเกิด / ความสามารถในการเยียวยา

มิติ	ผลกระทบเชิงลบ	การประเมิน	มาตรการเพิ่มเติม
ความเป็นธรรม	ผู้สูงอายุและผู้สื่อสารภาษาไทยไม่ได้ ถูกจัดระดับเร่งด่วนต่ำกว่าจริง	วิกฤต / ปานกลาง / ต่ำ	ทดสอบความแม่นยำแยกตามกลุ่มประชากร เพิ่มข้อมูลฝึกจากโรงพยาบาลอื่น
การกำกับดูแลโดยมนุษย์	พยาบาลเชื่อคำแนะนำของระบบโดยไม่ตรวจสอบ	วิกฤต / สูง / ปานกลาง	อบรมพยาบาล บันทึกกรณีที่เกิดผลของระบบ ทบทวนรายเดือน
ความโปร่งใส	ผู้ป่วยไม่ทราบว่ามีการใช้ AI และขอคำอธิบายไม่ได้	รุนแรง / สูง / สูง	ติดป้ายแจ้งการใช้ AI ณ จุดคัดกรอง แสดงปัจจัยหลัก 3 อันดับ
ความรับผิดชอบ	ระบบผู้รับผิดชอบเมื่อคัดกรองผิดพลาดไม่ได้	รุนแรง / ปานกลาง / ปานกลาง	ให้พยาบาลรับผิดชอบการตัดสินใจขั้นสุดท้าย เปิดช่องร้องเรียน

ข้อสรุป: ยังไม่ควรใช้งานเต็มรูปแบบ จนกว่าจะดำเนินมาตรการข้างต้น แล้วทดลองใช้ในวงจำกัดพร้อมติดตามผล

สรุปบทที่ 10

1

หลักการ 10 มิติ

กรอบ UNESCO ที่ประเทศไทยนำมาปรับใช้ผ่านคู่มือของ ETDA

2

กระบวนการ EIA 3 ส่วน

กำหนดขอบเขต ประเมินตามหลักการ และวิเคราะห์ผลกระทบ พร้อมเกณฑ์วิเคราะห์ 5 ด้าน

3

ประเมินทั้งบวกและลบ

ประโยชน์ที่ระบบสร้างขึ้นเป็นข้อมูลสำคัญในการชั่งน้ำหนักเช่นกัน

4

ความรับผิดชอบเริ่มตั้งแต่วันแรก

ไม่ได้เริ่มหลังโมเดลสร้างเสร็จ แต่เริ่มตั้งแต่วันที่นิยามปัญหา

"ความรับผิดชอบของ AI เริ่มตั้งแต่วันที่คุณนิยามปัญหา ไม่ใช่หลังจากโมเดลสร้างเสร็จ"