

## บทที่ 6

### การเรียนรู้ของเครื่อง

การเรียนรู้ของเครื่อง (Machine Learning: ML) เป็นสาขาหนึ่งของปัญญาประดิษฐ์ (Artificial Intelligence: AI) ที่มุ่งเน้นการพัฒนาอัลกอริทึมและแบบจำลอง (Models) เพื่อให้ระบบคอมพิวเตอร์สามารถเรียนรู้จากข้อมูล และปรับปรุงประสิทธิภาพของตนเองได้โดยไม่ต้องเขียนโปรแกรมกำหนดกฎทุกขั้นตอนอย่างชัดเจน (Explicitly Programmed)

โมเดลที่ได้จากการเรียนรู้สามารถนำไปใช้ในการทำนาย (Prediction) การจำแนกประเภท (Classification) หรือการตัดสินใจ (Decision Making) สำหรับข้อมูลใหม่ที่ไม่เคยพบมาก่อน โดยอาศัยรูปแบบ (Patterns) และความสัมพันธ์ที่เรียนรู้จากข้อมูลในอดีต

ปัจจุบัน Machine Learning เป็นเทคโนโลยีสำคัญที่อยู่เบื้องหลังระบบต่าง ๆ มากมาย เช่น

- ระบบแนะนำสินค้า (Recommendation Systems)
- ระบบกรองอีเมลขยะ (Spam Filtering)
- การรู้จำใบหน้า (Face Recognition)
- การแปลภาษาอัตโนมัติ (Machine Translation)
- รถยนต์ไร้คนขับ (Self-driving Cars)
- ระบบวินิจฉัยโรคทางการแพทย์ (Medical Diagnosis)
- โมเดลภาษาขนาดใหญ่ (Large Language Models: LLMs)

การเรียนรู้ของเครื่องไม่ขึ้นอยู่กับภาษาโปรแกรมภาษาใดภาษาหนึ่ง สามารถพัฒนาได้ด้วยภาษา Matlab, C++, Java, R หรือ Python ซึ่งภาษา Python ได้รับความนิยมสูงเนื่องจากมีไลบรารีสำหรับ Machine Learning และ Deep Learning จำนวนมาก เช่น Scikit-Learn, TensorFlow และ PyTorch

จุดมุ่งหมายสำคัญของ Machine Learning คือการสร้างโมเดลที่สามารถค้นหารูปแบบจากข้อมูล (Pattern Recognition) และนำความรู้ที่ได้ไปใช้พยากรณ์หรือตัดสินใจได้โดยมีการแทรกแซงจากมนุษย์ให้น้อยที่สุด (Minimal Human Intervention)

#### 6.1 แนวคิดพื้นฐานของการเรียนรู้ของเครื่อง

การเรียนรู้ของเครื่อง (Machine Learning: ML) เป็นสาขาหนึ่งของปัญญาประดิษฐ์ (Artificial Intelligence: AI) ที่มุ่งเน้นการพัฒนาอัลกอริทึมและแบบจำลอง (Model) เพื่อให้คอมพิวเตอร์สามารถเรียนรู้รูปแบบหรือความสัมพันธ์จากข้อมูล และนำความรู้ที่ได้ไปใช้ในการทำนาย (Prediction) หรือการตัดสินใจ (Decision Making) กับข้อมูลใหม่ที่ไม่เคยพบมาก่อนได้

แนวคิดสำคัญของ Machine Learning แตกต่างจากการเขียนโปรแกรมแบบดั้งเดิม (Traditional Programming) ในการเขียนโปรแกรมทั่วไป ผู้พัฒนาจะกำหนดกฎ (Rules) และขั้นตอนการทำงานให้กับคอมพิวเตอร์อย่างชัดเจน จากนั้นระบบจะนำกฎดังกล่าวไปประมวลผลข้อมูลเพื่อสร้างผลลัพธ์

ในทางตรงกันข้าม Machine Learning ไม่จำเป็นต้องกำหนดกฎสำหรับข้อมูลทุกกรณีโดยตรง แต่ให้ระบบเรียนรู้ความสัมพันธ์จากข้อมูลตัวอย่าง แล้วสร้างเป็นโมเดลที่สามารถนำไปใช้กับข้อมูลใหม่ได้

ตัวอย่างเช่น หากต้องการสร้างระบบจำแนกภาพว่าเป็น "สุนัข" หรือ "แมว" การเขียนโปรแกรมแบบดั้งเดิมอาจพยายามกำหนดกฎ เช่น รูปร่างของหู ขนาดของจมูก รูปร่างของใบหน้า หรือสีของขน แต่การกำหนดกฎให้ครอบคลุมภาพสุนัขและแมวทุกลักษณะเป็นเรื่องยาก

Machine Learning จึงใช้ภาพตัวอย่างจำนวนมาก พร้อมข้อมูลที่เกี่ยวข้อง เพื่อให้โมเดลเรียนรู้ลักษณะที่สามารถใช้แยกสุนัขออกจากแมวได้

#### 6.1.1. การเรียนรู้ของเครื่องในมุมมองของปัญหาการหาค่าเหมาะสม

แนวคิดของ Machine Learning สามารถเชื่อมโยงกับเนื้อหาเรื่องปัญหาการหาค่าเหมาะสม (Optimization Problem) ที่ได้ศึกษาในบทที่ 4 โดยในบทที่ 4 ได้กล่าวถึงการค้นหาคำตอบที่ดีที่สุดจากชุดคำตอบที่เป็นไปได้ และการใช้ฟังก์ชันวัตถุประสงค์ (Objective Function) เพื่อประเมินคุณภาพของคำตอบ

ใน Machine Learning ตัวแปรที่ต้องการปรับคือพารามิเตอร์ของโมเดล (Model Parameters) และเป้าหมายคือการค้นหาค่าพารามิเตอร์ที่ทำให้โมเดลสามารถทำนายข้อมูลได้ดี

แนวคิดของการเรียนรู้ของเครื่องคือการทำให้ Loss Function มีค่าต่ำที่สุด

กล่าวอีกนัยหนึ่ง การฝึกโมเดลการเรียนรู้ของเครื่องสามารถมองได้ว่าเป็นปัญหา Optimization ที่ต้องค้นหาค่าพารามิเตอร์ที่เหมาะสมที่สุด

ตัวอย่างเช่น หากโมเดลมีพารามิเตอร์  $\theta$  เป้าหมายของการฝึก อาจเขียนได้เป็น

$$\theta^* = \arg \min_{\theta} L(\theta)$$

โดยที่

$\theta$  หมายถึง พารามิเตอร์ของโมเดล

$L(\theta)$  หมายถึง Loss Function ที่ใช้วัดความผิดพลาดของโมเดล

$\theta^*$  หมายถึงค่าพารามิเตอร์ที่ทำให้ Loss มีค่าต่ำที่สุด

แนวคิดนี้มีความสัมพันธ์โดยตรงกับเนื้อหาเรื่อง Gradient และ Steepest Descent ที่ได้ศึกษาในบทที่ 4 ซึ่งเป็นแนวคิดพื้นฐานที่นำไปสู่การฝึกโมเดล Machine Learning และ Deep Learning ในบทต่อ ๆ ไป

### 6.1.2. Loss Function

Loss Function หรือฟังก์ชันสูญเสีย เป็นฟังก์ชันที่ใช้วัดว่าผลลัพธ์ที่โมเดลทำนายแตกต่างจากผลลัพธ์ที่ต้องการมากน้อยเพียงใด หากโมเดลทำนายได้ใกล้เคียงกับค่าจริง Loss จะมีค่าต่ำ ในทางกลับกัน หากโมเดลทำนายผิดมาก Loss จะมีค่าสูง ดังนั้นในกระบวนการฝึกโมเดล เป้าหมายโดยทั่วไปคือการปรับพารามิเตอร์ให้ Loss ลดลง สำหรับปัญหา Regression ตัวอย่าง Loss Function ที่นิยมใช้คือ Mean Squared Error (MSE)

$$MSE = (1/n) \sum (y_i - \hat{y}_i)^2$$

โดยที่

$y_i$  คือค่าจริง

$\hat{y}_i$  คือค่าที่โมเดลทำนาย

$n$  คือจำนวนข้อมูล

ในปัญหา Classification อาจใช้ Cross-Entropy Loss ซึ่งจะกล่าวถึงในรายละเอียดเมื่อศึกษาการเรียนรู้แบบมีผู้สอน

### 6.1.3. จาก Gradient Descent สู่การฝึกโมเดล

จากบทที่ 4 ผู้เรียนได้ศึกษาการหาค่าที่เหมาะสมด้วย Gradient และ Steepest Descent โดยหลักการสำคัญคือการเคลื่อนที่ไปในทิศทางที่ทำให้ค่าของฟังก์ชันลดลง

แนวคิดดังกล่าวสามารถนำมาใช้ในการฝึก Machine Learning ได้

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta \nabla L(\theta)$$

โดยที่

$\theta_{\text{new}}$  คือค่าพารามิเตอร์ใหม่

$\theta_{\text{old}}$  คือค่าพารามิเตอร์เดิม

$\eta$  คือ Learning Rate

$\nabla L(\theta)$  คือ Gradient ของ Loss Function

สมการนี้แสดงให้เห็นว่าการฝึกโมเดลไม่ได้เป็นเพียงการ "จดจำข้อมูล" แต่เป็นกระบวนการปรับพารามิเตอร์ของโมเดลอย่างต่อเนื่อง เพื่อให้ค่าความสูญเสียลดลง

ดังนั้น ความรู้เรื่อง Optimization ในบทที่ 4 จึงเป็นพื้นฐานสำคัญสำหรับทำความเข้าใจ Machine Learning และ Deep Learning

## 6.2 ประเภทของการเรียนรู้ของเครื่อง

การเรียนรู้ของเครื่องสามารถแบ่งออกเป็นหลายประเภทตามลักษณะของข้อมูลและวิธีการเรียนรู้ของโมเดล โดยประเภทที่สำคัญและได้รับความนิยมมากที่สุดประกอบด้วย

### 6.2.1. การเรียนรู้แบบมีผู้สอน (Supervised Learning)

เป็นวิธีการเรียนรู้ที่ใช้ข้อมูลที่มีป้ายกำกับ (Labeled Data) หรือมีคำตอบที่ถูกต้องกำกับไว้แล้ว โดยโมเดลจะเรียนรู้ความสัมพันธ์ระหว่างข้อมูลอินพุต (Input) และเอาต์พุต (Output) เพื่อสร้างฟังก์ชันสำหรับทำนายข้อมูลใหม่

การเรียนรู้ประเภทนี้เป็นวิธีที่ได้รับความนิยมมากที่สุด และสามารถแบ่งปัญหาออกได้เป็นสองลักษณะสำคัญได้แก่

- การจำแนกประเภท (Classification)
- การถดถอย (Regression)

ตัวอย่างการประยุกต์ใช้งาน ได้แก่

- การจำแนกภาพแมวและสุนัข
- การวินิจฉัยโรค
- การตรวจจับอีเมลขยะ
- การพยากรณ์ราคาบ้าน
- การคาดการณ์ยอดขายสินค้า

### 6.2.2. การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)

เป็นวิธีการเรียนรู้ที่ใช้ข้อมูลที่ไม่มีป้ายกำกับ (Unlabeled Data) โดยโมเดลจะพยายามค้นหารูปแบบหรือโครงสร้างที่ซ่อนอยู่ภายในข้อมูลด้วยตนเอง

งานที่สำคัญของการเรียนรู้ประเภทนี้ ได้แก่

- การจัดกลุ่มข้อมูล (Clustering)
- การลดมิติข้อมูล (Dimensionality Reduction)
- การค้นหาความสัมพันธ์ระหว่างข้อมูล (Association Rule Learning)

ตัวอย่างการประยุกต์ใช้งาน ได้แก่

- การแบ่งกลุ่มลูกค้า
- ระบบแนะนำสินค้า
- การวิเคราะห์พฤติกรรมผู้ใช้งาน
- การตรวจจับความผิดปกติของข้อมูล

### 6.2.3. การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning)

การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning) เป็นการเรียนรู้ที่ตัวแทน (Agent) เรียนรู้จากการโต้ตอบกับสภาพแวดล้อม (Environment) ผ่านกระบวนการลองผิดลองถูก (Trial and Error) เมื่อ Agent

ทำการกระทำ (Action) อย่างไรอย่างหนึ่ง ระบบจะตอบกลับด้วยรางวัล (Reward) หรือค่าลงโทษ (Penalty) จากนั้น Agent จะปรับกลยุทธ์ของตนเพื่อให้ได้รับผลตอบแทนสะสมสูงสุด

องค์ประกอบสำคัญของ Reinforcement Learning ประกอบด้วย

- Agent
- Environment
- State
- Action
- Reward

ตัวอย่างการประยุกต์ใช้งาน ได้แก่

- การควบคุมหุ่นยนต์
- การเล่นเกมหมากรุกและโกะ
- รถยนต์ไร้คนขับ
- การบริหารทรัพยากรในระบบเครือข่าย
- การตัดสินใจในระบบอัตโนมัติ

นอกจากการเรียนรู้ทั้งสามประเภทหลักแล้ว ปัจจุบันยังมีรูปแบบการเรียนรู้อื่น ๆ ที่ได้รับความสนใจเพิ่มขึ้น เช่น Semi-supervised Learning, Self-supervised Learning, Few-shot Learning, One-shot Learning และ Zero-shot Learning ซึ่งถูกนำไปประยุกต์ใช้อย่างแพร่หลายในงานด้านปัญญาประดิษฐ์ยุคใหม่และโมเดลภาษาขนาดใหญ่

### 6.3 ชุดข้อมูลและกระบวนการเรียนรู้ของโมเดล

การสร้างโมเดล Machine Learning ไม่ได้เริ่มต้นจากการเลือกอัลกอริทึมทันที แต่ต้องเริ่มจากการกำหนดปัญหา รวบรวมข้อมูล เตรียมข้อมูล และออกแบบกระบวนการเรียนรู้ให้เหมาะสม กระบวนการทั้งหมดสามารถสรุปได้ดังนี้

- 1) กำหนดปัญหาและวัตถุประสงค์
- 2) รวบรวมข้อมูล
- 3) ตรวจสอบและทำความสะอาดข้อมูล
- 4) เตรียมข้อมูล
- 5) แบ่งข้อมูล
- 6) เลือกโมเดล
- 7) ฝึกโมเดล
- 8) ปรับ Hyperparameters

- 9) ตรวจสอบโมเดล
- 10) ทดสอบโมเดล
- 11) วิเคราะห์ผลลัพธ์
- 12) ปรับปรุงโมเดล
- 13) นำโมเดลไปใช้งานจริง

### 6.3.1. ขั้นตอนที่ 1 การกำหนดปัญหา

ก่อนสร้างโมเดลต้องกำหนดก่อนว่าต้องการให้ระบบแก้ปัญหาอะไร ตัวอย่าง ต้องการสร้างระบบที่สามารถจำแนกภาพออกเป็น

- Class 0 = สุนัข
- Class 1 = แมว

ปัญหานี้เป็น Supervised Learning และเป็น Classification

สิ่งที่โมเดลได้รับคือภาพ และสิ่งที่ต้องการคือคลาสของภาพ

### 6.3.2. ขั้นตอนที่ 2 การรวบรวมข้อมูล

ขั้นตอนต่อมาคือการรวบรวมข้อมูลที่เหมาะสมกับปัญหา สำหรับตัวอย่างสุนัขและแมว อาจรวบรวมภาพจากแหล่งข้อมูลที่ได้รับอนุญาต โดยแต่ละภาพต้องมี Label ที่ระบุว่าเป็นสุนัขหรือแมว ข้อมูลที่รวบรวมควรมีความหลากหลาย เช่น

- สุนัขหลายสายพันธุ์
- แมวหลายสายพันธุ์
- ภาพหลายมุม
- ภาพในสภาพแสงต่างกัน
- พื้นหลังแตกต่างกัน
- ขนาดและท่าทางแตกต่างกัน

ความหลากหลายของข้อมูลมีความสำคัญต่อ Generalization เพราะหากข้อมูลฝึกมีรูปแบบจำกัด โมเดลอาจเรียนรู้เฉพาะลักษณะที่ปรากฏในข้อมูลฝึกเท่านั้น

### 6.3.3. ขั้นตอนที่ 3 การตรวจสอบและทำความสะอาดข้อมูล

ข้อมูลที่รวบรวมมาอาจมีปัญหา เช่น

- ภาพเสีย
- ภาพซ้ำ
- Label ผิด

- ภาพที่ไม่เกี่ยวข้อง
- ภาพที่มีคุณภาพต่ำ
- จำนวนข้อมูลของแต่ละคลาสแตกต่างกันมาก

จึงต้องตรวจสอบและแก้ไขข้อมูลก่อนนำไปฝึก ตัวอย่างเช่น หากภาพหนึ่งเป็นภาพแมวแต่ถูกกำหนด Label เป็นสุนัข โมเดลอาจเรียนรู้ความสัมพันธ์ที่ผิดพลาดจากข้อมูลดังกล่าว

#### 6.3.4. ขั้นตอนที่ 4 การเตรียมข้อมูล

ข้อมูลอาจต้องผ่านกระบวนการ Preprocessing ก่อนนำเข้าสู่มอเดล เช่น

- ปรับขนาดภาพ
- ปรับค่าพิกเซล
- Normalize ข้อมูล
- เปลี่ยนรูปแบบข้อมูล
- Data Augmentation

ตัวอย่างเช่น กำหนดให้ภาพทุกภาพมีขนาด  $224 \times 224$  pixels เพื่อให้สามารถนำเข้าสู่มอเดลที่กำหนดไว้ได้

Data Augmentation อาจสร้างข้อมูลรูปแบบใหม่จากภาพเดิม เช่น

- การหมุนภาพ
- การกลับภาพ
- การเปลี่ยนขนาด
- การเปลี่ยนตำแหน่ง
- การเปลี่ยนความสว่าง

อย่างไรก็ตาม Data Augmentation ต้องถูกออกแบบให้เหมาะกับปัญหา และไม่ควรสร้างข้อมูลที่ผิดจากลักษณะจริงของปัญหา

#### 6.3.5. ขั้นตอนที่ 5 การแบ่งชุดข้อมูล

ข้อมูลจะถูกแบ่งออกเป็นชุดข้อมูลสำหรับวัตถุประสงค์ที่แตกต่างกัน

- **Training Dataset** ใช้สำหรับฝึกโมเดล
- **Validation Dataset** ใช้สำหรับเลือกโมเดลและปรับ Hyperparameters
- **Testing Dataset** ใช้ประเมินโมเดลขั้นสุดท้ายกับข้อมูลที่ไม่ได้ใช้ในการฝึกหรือปรับโมเดล

ตัวอย่างเช่น หากมีภาพทั้งหมด 10,000 ภาพ อาจแบ่งเป็น

| Dataset    | จำนวนภาพ | หน้าที่              |
|------------|----------|----------------------|
| Training   | 8,000    | ฝึกโมเดล             |
| Validation | 1,000    | ปรับโมเดล            |
| Testing    | 1,000    | ประเมินผลขั้นสุดท้าย |

สัดส่วนดังกล่าวเป็นเพียงตัวอย่าง ไม่ใช่ข้อกำหนดตายตัว สิ่งสำคัญคือ Testing Dataset ต้องถูกเก็บไว้จนกว่าจะถึงขั้นตอนการประเมินขั้นสุดท้าย เพราะหากนำข้อมูลทดสอบไปใช้เลือกโมเดลหรือปรับ Hyperparameters ผลการทดสอบอาจมีความลำเอียง

### 6.3.6. ขั้นตอนที่ 6 การเลือกโมเดล

หลังจากเตรียมข้อมูลแล้ว ต้องเลือกอัลกอริทึมหรือโมเดลที่เหมาะสมกับปัญหา สำหรับ Classification สามารถเลือกใช้ เช่น

- Logistic Regression
- Decision Tree
- Random Forest
- Support Vector Machine
- K-Nearest Neighbors
- Neural Network

ในตัวอย่างหมาและแมว หากข้อมูลเป็นภาพจำนวนมาก สามารถเลือกใช้ Convolutional Neural Network หรือโมเดล Deep Learning ที่เหมาะกับงานภาพ

### 6.3.7. ขั้นตอนที่ 7 การฝึกโมเดล

เมื่อเลือกโมเดลแล้วจึงนำ Training Dataset เข้าสู่กระบวนการฝึกในแต่ละรอบ โมเดลจะ

1. รับข้อมูล Input
2. คำนวณผลลัพธ์
3. เปรียบเทียบผลลัพธ์กับ Target
4. คำนวณ Loss
5. คำนวณ Gradient
6. ปรับ Parameters
7. ทำซ้ำกับข้อมูลชุดต่อไป

กระบวนการนี้ทำซ้ำหลายรอบจนโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้ สำหรับโมเดลที่ใช้ Gradient-based Optimization การปรับ Parameters สามารถอธิบายด้วย

$$\theta_{\text{new}} = \theta_{\text{old}} - \alpha \nabla L(\theta)$$

ซึ่งเป็นการประยุกต์แนวคิด Steepest Descent หรือ Gradient Descent ที่ได้ศึกษาในบทที่ 4

### 6.3.8. ตัวอย่างการฝึกโมเดลด้วยข้อมูลหมาและแมว

สมมติว่ามีภาพสำหรับฝึกจำนวน 8,000 ภาพ

- สุนัข 4,000 ภาพ
- แมว 4,000 ภาพ

ในแต่ละภาพมี Label กำกับ ตัวอย่าง

| ภาพ      | Label |
|----------|-------|
| ภาพที่ 1 | สุนัข |
| ภาพที่ 2 | แมว   |
| ภาพที่ 3 | สุนัข |
| ภาพที่ 4 | แมว   |

เมื่อภาพถูกส่งเข้าโมเดล โมเดลอาจทำนายออกมาเป็นค่าความน่าจะเป็น เช่น

| ภาพ      | ค่าจริง | ผลการทำนาย |
|----------|---------|------------|
| ภาพสุนัข | สุนัข   | 0.92 สุนัข |
| ภาพแมว   | แมว     | 0.81 แมว   |
| ภาพสุนัข | สุนัข   | 0.47 แมว   |
| ภาพแมว   | แมว     | 0.95 แมว   |

เมื่อโมเดลทำนายผิด จะเกิด Loss และกระบวนการฝึกจะปรับ Parameters เพื่อให้การทำนายในครั้งต่อไปดีขึ้น

### 6.3.9 ขั้นตอนที่ 8 การปรับ Hyperparameters

Parameters เป็นค่าที่โมเดลเรียนรู้ระหว่างการฝึก ส่วน Hyperparameters เป็นค่าที่ผู้พัฒนา กำหนดหรือปรับก่อนหรือระหว่างการทดลอง เช่น


- Learning Rate
- Batch Size
- จำนวน Epoch
- จำนวนชั้นของโมเดล
- จำนวน Neurons
- Regularization

ตัวอย่างเช่น ทดลอง Learning Rate 0.001, 0.0001 และ 0.00001 แล้วใช้ Validation Dataset เปรียบเทียบว่าแบบใดให้ผลดีที่สุด

### 6.3.9. ขั้นตอนที่ 9 การตรวจสอบโมเดลด้วย Validation Dataset

หลังจากฝึกโมเดลในแต่ละช่วง สามารถนำ Validation Dataset มาตรวจสอบว่าโมเดลสามารถทำงานกับข้อมูลที่ไม่ได้ใช้ในการปรับ Parameters ได้ดีเพียงใด  
สมมติว่าได้ผลดังนี้

| Epoch | Training Accuracy | Validation Accuracy |
|-------|-------------------|---------------------|
| 10    | 75%               | 73%                 |
| 20    | 84%               | 81%                 |
| 30    | 91%               | 88%                 |
| 40    | 96%               | 89%                 |
| 50    | 99%               | 84%                 |



จากตัวอย่างพบว่า Training Accuracy ยังคงเพิ่มขึ้น แต่ Validation Accuracy ลดลงหลัง Epoch ที่ 40 ลักษณะดังกล่าวเป็นสัญญาณว่าโมเดลอาจเริ่มเกิด Overfitting ดังนั้นอาจเลือกโมเดลจากช่วง Epoch ที่ 40 แทนที่จะเลือกโมเดลที่มี Training Accuracy สูงที่สุด

### 6.3.10. ขั้นตอนที่ 10 การทดสอบโมเดล

เมื่อเลือกโมเดลและ Hyperparameters จาก Training และ Validation Dataset แล้ว จึงนำโมเดลที่ได้ไปทดสอบกับ Testing Dataset สมมติว่าโมเดลสามารถจำแนกภาพใน Testing Dataset ได้ถูกต้อง 92%

ผลดังกล่าวถือว่าโมเดลสามารถทำงานได้ในระดับหนึ่ง แต่ไม่ควรสรุปเพียงว่า "92% ดี" โดยไม่พิจารณาลักษณะของข้อมูลและตัวชี้วัดอื่น

ตัวอย่างเช่น หากข้อมูลมีจำนวนสูงและแม่นยำ Accuracy 92% อาจเป็นตัวชี้วัดที่มีประโยชน์พอสมควร แต่ถ้าข้อมูลมีความไม่สมดุลกันมาก การใช้ Accuracy เพียงอย่างเดียวอาจทำให้เข้าใจประสิทธิภาพของโมเดลผิดได้

รายละเอียดเกี่ยวกับการประเมินประสิทธิภาพจะกล่าวในหัวข้อ 6.5

### 6.3.11. ขั้นตอนที่ 11 การวิเคราะห์ผลและปรับปรุงโมเดล

หากผลการทดสอบไม่เป็นไปตามวัตถุประสงค์ อาจต้องกลับไปปรับปรุงขั้นตอนก่อนหน้า

ตัวอย่างเช่น หากโมเดลหยาบและแม่นยำมีประสิทธิภาพเพียง 65% อาจพิจารณา

- ตรวจสอบ Label
- เพิ่มข้อมูล
- เพิ่มความหลากหลายของข้อมูล
- ปรับ Preprocessing
- ปรับ Hyperparameters
- เปลี่ยนโมเดล
- ใช้ Data Augmentation
- ตรวจสอบ Overfitting และ Underfitting

จากนั้นจึงฝึกโมเดลใหม่และประเมินผลอีกครั้ง

กระบวนการ Machine Learning จึงไม่ใช่กระบวนการแบบเส้นตรงที่ทำเพียงครั้งเดียว แต่เป็นกระบวนการวนซ้ำ (Iterative Process)

กำหนดปัญหา → รวบรวมข้อมูล → เตรียมข้อมูล → ฝึกโมเดล → ตรวจสอบ → ปรับปรุง → ทดสอบ → วิเคราะห์ → ปรับปรุงอีกครั้ง

### 6.3.12. ขั้นตอนที่ 12 การนำโมเดลไปใช้งาน

เมื่อโมเดลผ่านการประเมินและมีประสิทธิภาพตามวัตถุประสงค์แล้ว จึงสามารถนำไปใช้งานจริง (Deployment)

ตัวอย่างเช่น ระบบจำแนกภาพหมาและแมวอาจถูกนำไปติดตั้งใน

- เว็บไซต์
- Mobile Application
- ระบบ Cloud

- ระบบตรวจสอบภาพอัตโนมัติ

อย่างไรก็ตาม หลังจากนำโมเดลไปใช้งานแล้ว ยังต้องมีการติดตามประสิทธิภาพ เพราะข้อมูลในโลกจริงอาจเปลี่ยนแปลงไปจากข้อมูลที่ใช้ฝึก ซึ่งอาจทำให้ประสิทธิภาพของโมเดลลดลงได้

## 6.4 ปัญหาที่พบในการเรียนรู้ของเครื่อง

เป้าหมายสำคัญของการเรียนรู้ของเครื่อง คือ การสร้างโมเดลที่สามารถเรียนรู้รูปแบบหรือความสัมพันธ์จากข้อมูลฝึก (Training Dataset) และนำความรู้ที่ได้ไปใช้กับข้อมูลใหม่ที่ไม่เคยพบมาก่อนได้อย่างถูกต้อง ความสามารถดังกล่าวเรียกว่า ความสามารถในการสรุปผลทั่วไป (Generalization)

อย่างไรก็ตาม ในทางปฏิบัติ โมเดลที่สร้างขึ้นอาจไม่สามารถเรียนรู้ได้อย่างเหมาะสมเสมอไป โดยปัญหาที่พบได้บ่อยที่สุดมีอยู่สองลักษณะ คือ Underfitting และ Overfitting ซึ่งส่งผลโดยตรงต่อประสิทธิภาพของโมเดลในการทำนายข้อมูลใหม่

### 6.4.1. Underfitting

Underfitting เป็นปัญหาที่เกิดขึ้นเมื่อโมเดลไม่สามารถเรียนรู้รูปแบบของข้อมูลได้อย่างเพียงพอ หรือกล่าวอีกนัยหนึ่งคือ โมเดลมีความเรียบง่ายมากเกินไป (Model Too Simple) ทำให้ไม่สามารถอธิบายความสัมพันธ์ที่แท้จริงของข้อมูลได้

ลักษณะสำคัญของ Underfitting คือ โมเดลมีประสิทธิภาพต่ำทั้งบนข้อมูลฝึก (Training Dataset) และข้อมูลทดสอบ (Testing Dataset) กล่าวคือ แม้แต่ข้อมูลที่ใช้ในการฝึกโมเดลเอง โมเดลก็ยังไม่สามารถทำนายได้อย่างถูกต้อง

สาเหตุที่ทำให้เกิด Underfitting ได้แก่

- โมเดลมีความซับซ้อนน้อยเกินไป
- จำนวนรอบการฝึกสอน (Epoch) มีน้อยเกินไป
- ข้อมูลที่ใช้ในการฝึกมีปริมาณไม่เพียงพอ
- การเลือกคุณลักษณะ (Feature Selection) ไม่เหมาะสม
- มีการกำหนดข้อจำกัดของโมเดลมากเกินไป (Over-Regularization)

ตัวอย่างเช่น การใช้สมการเชิงเส้นตรงในการประมาณความสัมพันธ์ของข้อมูลที่มีลักษณะเป็นเส้นโค้งที่ซับซ้อน จะทำให้โมเดลไม่สามารถอธิบายรูปแบบของข้อมูลได้อย่างถูกต้อง

แนวทางในการแก้ปัญหา Underfitting ได้แก่

- เลือกใช้โมเดลที่มีความซับซ้อนมากขึ้น
- เพิ่มจำนวนรอบการฝึกสอน
- เพิ่มจำนวนคุณลักษณะของข้อมูล
- เพิ่มปริมาณข้อมูลสำหรับการฝึก

- ลดข้อจำกัดหรือพารามิเตอร์ที่ใช้ควบคุมโมเดล

#### 6.4.2. Overfitting

Overfitting เป็นปัญหาที่เกิดขึ้นเมื่อโมเดลเรียนรู้รายละเอียดของข้อมูลฝึกมากเกินไป รวมถึงเรียนรู้สัญญาณรบกวน (Noise) หรือข้อมูลที่เกิดขึ้นเฉพาะในชุดข้อมูลฝึก ส่งผลให้โมเดลสามารถทำนายข้อมูลฝึกได้อย่างแม่นยำมาก แต่ไม่สามารถนำความรู้ดังกล่าวไปใช้กับข้อมูลใหม่ได้อย่างมีประสิทธิภาพ

ลักษณะสำคัญของ Overfitting คือ โมเดลมีความแม่นยำสูงบนข้อมูลฝึก แต่มีประสิทธิภาพลดลงอย่างมากเมื่อประเมินกับข้อมูลตรวจสอบ (Validation Dataset) หรือข้อมูลทดสอบ (Testing Dataset)

ตัวอย่างเช่น

Training Accuracy = 99%

Validation Accuracy = 84%

Testing Accuracy = 82%

กรณีนี้ควรสงสัยว่าโมเดลเกิด Overfitting

สาเหตุที่ทำให้เกิด Overfitting ได้แก่

- โมเดลมีความซับซ้อนมากเกินไป
- จำนวนพารามิเตอร์ของโมเดลมีมากเกินไป
- ฝึกโมเดลเป็นเวลานานเกินไป
- ชุดข้อมูลมีขนาดเล็ก
- มีสัญญาณรบกวน (Noise) ปะปนอยู่ในข้อมูล

ตัวอย่างเช่น โมเดลอาจสามารถจดจำข้อมูลภาพทุกภาพในชุดข้อมูลฝึกได้อย่างถูกต้อง แต่เมื่อได้รับภาพใหม่ที่ไม่เคยพบมาก่อนกลับไม่สามารถจำแนกได้อย่างถูกต้อง

แนวทางในการลดปัญหา Overfitting ได้แก่

- เพิ่มปริมาณข้อมูลฝึก
- ใช้เทคนิค Data Augmentation
- ลดความซับซ้อนของโมเดล
- ใช้เทคนิค Regularization เช่น L1 และ L2 Regularization
- ใช้เทคนิค Dropout สำหรับโครงข่ายประสาทเทียม
- ใช้ Early Stopping เพื่อหยุดการฝึกเมื่อประสิทธิภาพบนข้อมูลตรวจสอบเริ่มลดลง
- ใช้วิธี Cross Validation เพื่อประเมินประสิทธิภาพของโมเดล

## 6.5 การวัดประสิทธิภาพของโมเดล

หลังจากผ่านกระบวนการฝึกสอนโมเดล (Training) แล้ว ขั้นตอนสำคัญที่ต้องดำเนินการต่อ คือ การประเมินประสิทธิภาพของโมเดล (Model Evaluation) เพื่อพิจารณาว่าโมเดลสามารถเรียนรู้รูปแบบจากข้อมูลได้ดีเพียงใด และที่สำคัญคือ โมเดลสามารถนำความรู้ที่เรียนรู้มาให้กับข้อมูลใหม่ที่ไม่เคยพบมาก่อนได้ดีเพียงใด

การประเมินประสิทธิภาพมีความสำคัญมาก เพราะการที่โมเดลสามารถทำนายข้อมูลที่ใช้ในการฝึกได้ถูกต้องจำนวนมาก ไม่ได้หมายความว่าโมเดลจะสามารถทำงานกับข้อมูลใหม่ได้ดีเสมอไป ดังที่ได้กล่าวถึงในหัวข้อ Underfitting และ Overfitting

ตัวอย่างเช่น โมเดลหนึ่งอาจมีความถูกต้องบน Training Dataset เท่ากับ 99% แต่เมื่อนำไปทดสอบกับ Testing Dataset กลับมีความถูกต้องเพียง 75% กรณีนี้แสดงให้เห็นว่าโมเดลอาจเกิด Overfitting และไม่สามารถสรุปความรู้ไปยังข้อมูลใหม่ได้ดี

ดังนั้น การประเมินโมเดลจึงควรใช้ข้อมูลที่ไม่ได้ถูกนำมาใช้ในการฝึกโมเดล โดยเฉพาะ Testing Dataset เพื่อให้ได้ผลการประเมินที่สะท้อนความสามารถในการใช้งานกับข้อมูลใหม่

การเลือกวิธีวัดประสิทธิภาพขึ้นอยู่กับลักษณะของงาน ในบทนี้จะเน้นงานที่พบได้บ่อยในการเรียนรู้แบบมีผู้สอน (Supervised Learning) ได้แก่

1. การจำแนกประเภท (Classification)
2. การถดถอย (Regression)

ส่วนการจัดกลุ่มข้อมูล (Clustering) ซึ่งเป็นงานของ Unsupervised Learning จะกล่าวถึงในภาพรวมในตอนท้ายของหัวข้อนี้ เนื่องจากไม่มีคำตอบที่ถูกต้อง (Ground Truth) สำหรับข้อมูลแต่ละตัวอย่างในลักษณะเดียวกับ Classification และ Regression

### 6.5.1. การวัดประสิทธิภาพสำหรับงานจำแนกประเภท (Classification)

- **ลักษณะของงาน Classification**

Classification เป็นงานที่โมเดลต้องทำนายว่าข้อมูลอินพุตอยู่ในคลาสใดจากคลาสที่กำหนดไว้

ตัวอย่างเช่น ระบบจำแนกภาพสัตว์อาจกำหนดให้มี 2 คลาส ได้แก่

- สุนัข (Dog)
- แมว (Cat)

เมื่อได้รับภาพใหม่ โมเดลต้องตัดสินใจว่าภาพดังกล่าวเป็นสุนัขหรือแมว

ในกรณีที่มีเพียง 2 คลาส เรียกว่า Binary Classification ส่วนกรณีที่มีมากกว่า 2 คลาส เรียกว่า Multiclass Classification ตัวอย่างของ Classification ได้แก่

- จำแนกภาพสุนัขและแมว

- จำแนกอีเมลเป็น Spam หรือ Not Spam
- จำแนกภาพทางการแพทย์ว่าเป็นโรคหรือไม่เป็นโรค
- จำแนกประเภทสินค้า
- จำแนกข้อความตามหัวข้อ

หัวใจสำคัญของการประเมิน Classification คือ การเปรียบเทียบผลที่โมเดลทำนายกับคำตอบจริง หรือ Ground Truth

#### 6.5.1.1 Balanced Dataset และ Imbalanced Dataset

ก่อนเลือกตัวชี้วัดประสิทธิภาพ ควรพิจารณาลักษณะการกระจายของข้อมูลในแต่ละคลาสก่อน เนื่องจากจำนวนข้อมูลของแต่ละคลาสมีผลต่อความหมายของ Accuracy

- **Balanced Dataset**

Balanced Dataset คือชุดข้อมูลที่มีจำนวนข้อมูลในแต่ละคลาสมีจำนวนใกล้เคียงกัน

ตัวอย่างเช่น ชุดข้อมูลภาพสุนัขและแมวจำนวน 1,000 ภาพ

- สุนัข 500 ภาพ
- แมว 500 ภาพ

ข้อมูลลักษณะนี้ถือว่าค่อนข้างสมดุล

หากโมเดลทำนายถูกต้อง 900 ภาพจาก 1,000 ภาพ ค่า Accuracy เท่ากับ 90% และโดยทั่วไปค่าดังกล่าวสามารถใช้เป็นตัวชี้วัดภาพรวมได้ค่อนข้างดี

อย่างไรก็ตาม แม้ข้อมูลจะสมดุล ก็ยังควรตรวจสอบ Confusion Matrix และ Metric อื่นร่วมด้วย เพื่อให้ทราบว่าโมเดลผิดพลาดกับคลาสใดมากกว่ากัน

- **Imbalanced Dataset**

Imbalanced Dataset คือชุดข้อมูลที่มีจำนวนข้อมูลในแต่ละคลาสแตกต่างกันมาก ตัวอย่างเช่น ระบบตรวจหาภาพผู้ป่วยที่เป็นโรคจากภาพทางการแพทย์จำนวน 1,000 ภาพ อาจมี

- ภาพผู้ป่วยที่เป็นโรค 50 ภาพ
- ภาพที่ไม่เป็นโรค 950 ภาพ

สาเหตุหนึ่งคือโรคบางชนิดพบไม่บ่อย และการรวบรวมข้อมูลผู้ป่วยที่เป็นโรคอาจทำได้ยากกว่าการรวบรวมข้อมูลปกติ กรณีนี้หากโมเดลทำนายว่าทุกภาพ "ไม่เป็นโรค" จะมีผลดังนี้

- ทำนายถูก 950 ภาพ
- ทำนายผิด 50 ภาพ

ดังนั้น Accuracy จะเท่ากับ

$$\text{Accuracy} = 950 / 1000 = 95\%$$

แม้โมเดลจะมี Accuracy สูงถึง 95% แต่โมเดลไม่สามารถตรวจพบผู้ป่วยที่เป็นโรคได้เลย  
ตัวอย่างนี้แสดงให้เห็นว่า Accuracy เพียงอย่างเดียวอาจทำให้เข้าใจประสิทธิภาพของโมเดลผิด  
โดยเฉพาะเมื่อข้อมูลมีความไม่สมดุล

ดังนั้นจึงต้องพิจารณา Confusion Matrix, Precision, Recall และ F1-score ร่วมด้วย

#### 6.5.1.2 Confusion Matrix

Confusion Matrix เป็นตารางที่ใช้แสดงความสัมพันธ์ระหว่างค่าจริง (Actual Class) กับค่าที่โมเดลทำนาย (Predicted Class)

สำหรับ Binary Classification ประกอบด้วยผลลัพธ์ 4 ประเภท ได้แก่

| Actual / Predicted | Positive            | Negative            |
|--------------------|---------------------|---------------------|
| Positive           | True Positive (TP)  | False Negative (FN) |
| Negative           | False Positive (FP) | True Negative (TN)  |

- **True Positive (TP)**

เป็นกรณีที่ข้อมูลเป็น Positive จริง และโมเดลทำนายว่าเป็น Positive

ตัวอย่างเช่น ภาพเป็นภาพสุนัขจริง และโมเดลทำนายว่าเป็นสุนัข

- **True Negative (TN)**

เป็นกรณีที่ข้อมูลเป็น Negative จริง และโมเดลทำนายว่าเป็น Negative

ตัวอย่างเช่น ภาพเป็นแมวจริง และโมเดลทำนายว่าไม่ใช่สุนัข

- **False Positive (FP)**

เป็นกรณีที่ข้อมูลเป็น Negative แต่โมเดลทำนายว่าเป็น Positive

ตัวอย่างเช่น ภาพเป็นแมว แต่โมเดลทำนายว่าเป็นสุนัข

- **False Negative (FN)**

เป็นกรณีที่ข้อมูลเป็น Positive แต่โมเดลทำนายว่าเป็น Negative

ตัวอย่างเช่น ภาพเป็นสุนัข แต่โมเดลทำนายว่าเป็นแมว

สำหรับงานทางการแพทย์ FP และ FN มีความหมายที่แตกต่างกันอย่างมากระหว่าง FN หมายถึงผู้ป่วยที่เป็นโรคจริงแต่โมเดลไม่สามารถตรวจพบ ซึ่งอาจมีผลกระทบสูงกว่าการแจ้งเตือนผิดว่าเป็นโรค

Confusion Matrix จึงเป็นพื้นฐานสำคัญสำหรับการคำนวณ Accuracy, Precision, Recall และ F1-score

#### 6.5.1.3 Accuracy

Accuracy คือสัดส่วนของจำนวนข้อมูลที่โมเดลทำนายได้ถูกต้องเมื่อเทียบกับข้อมูลทั้งหมด

$$\text{Accuracy} = (\text{TP} + \text{TN}) / (\text{TP} + \text{TN} + \text{FP} + \text{FN})$$

ค่า Accuracy มีค่าระหว่าง 0 ถึง 1 หรือสามารถแสดงเป็นเปอร์เซ็นต์ได้

- ตัวอย่าง **Balanced Dataset: สุนัขและแมว**

สมมติว่ามีภาพทดสอบ 1,000 ภาพ

- สุนัข 500 ภาพ
- แมว 500 ภาพ

กำหนดให้สุนัขเป็น Positive

| Actual / Predicted | สุนัข | แมว |
|--------------------|-------|-----|
| สุนัข              | 460   | 40  |
| แมว                | 60    | 440 |

ดังนั้น

$$\text{TP} = 460$$

$$\text{TN} = 440$$

$$\text{FP} = 60$$

$$\text{FN} = 40$$

คำนวณ Accuracy ได้ดังนี้

$$\text{Accuracy} = (460 + 440) / 1000$$

$$\text{Accuracy} = 0.90$$

$$\text{ดังนั้น Accuracy} = 90\%$$

โมเดลสามารถจำแนกภาพได้ถูกต้อง 900 จาก 1,000 ภาพ

เนื่องจากข้อมูลสุนัขและแมวมีจำนวนใกล้เคียงกัน ค่า Accuracy จึงสามารถสะท้อนภาพรวมของโมเดลได้ค่อนข้างดี

อย่างไรก็ตาม หากต้องการทราบรายละเอียดว่าโมเดลมีปัญหาเกี่ยวกับคลาสใด จะต้องพิจารณา Precision, Recall และ F1-score เพิ่มเติม

#### 6.5.1.4 Precision

Precision ใช้ตอบคำถามว่า "จากข้อมูลที่โมเดลทำนายว่าเป็น Positive มีจำนวนเท่าใดที่เป็น Positive จริง"

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

จากตัวอย่างสุนัขและแมว

$$\text{Precision} = 460 / (460 + 60)$$

$$\text{Precision} = 460 / 520$$

$$\text{Precision} \approx 0.8846$$

$$\text{ดังนั้น Precision} \approx 88.46\%$$

หมายความว่า จากภาพทั้งหมดที่โมเดลทำนายว่าเป็นสุนัข มีประมาณ 88.46% ที่เป็นสุนัขจริง

Precision มีความสำคัญเมื่อ False Positive มีต้นทุนสูง เช่น ระบบตรวจจับธุรกรรมผิดปกติ หรือระบบคัดกรองโรคที่ไม่ต้องการให้คนปกติถูกแจ้งเตือนว่าเป็นผู้ป่วยมากเกินไป

#### 6.5.1.5 Recall

Recall หรือ Sensitivity ใช้ตอบคำถามว่า "จากข้อมูล Positive ที่มีอยู่จริงทั้งหมด โมเดลสามารถตรวจพบได้กี่เปอร์เซ็นต์"

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

จากตัวอย่าง

$$\text{Recall} = 460 / (460 + 40)$$

$$\text{Recall} = 460 / 500$$

$$\text{Recall} = 0.92$$

$$\text{ดังนั้น Recall} = 92\%$$

หมายความว่า จากภาพสุนัขจริง 500 ภาพ โมเดลสามารถตรวจพบได้ 460 ภาพ หรือ 92%

Recall มีความสำคัญมากในงานที่ไม่ต้องการให้เกิด False Negative เช่น การตรวจคัดกรองโรค เพราะการไม่สามารถตรวจพบผู้ป่วยที่เป็นโรคอาจมีผลกระทบสูง

#### 6.5.1.6 F1-score

F1-score เป็นค่าเฉลี่ยฮาร์โมนิกของ Precision และ Recall

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

จากตัวอย่าง

$$\text{Precision} \approx 0.8846$$

$$\text{Recall} = 0.92$$

ดังนั้น

$$F1 \approx 0.902$$

หรือประมาณ 90.2%

F1-score มีประโยชน์เมื่อ Precision และ Recall มีความสำคัญทั้งคู่ และเหมาะสำหรับการประเมินข้อมูลที่มีความไม่สมดุล โดยเฉพาะเมื่อ Accuracy ไม่สามารถสะท้อนประสิทธิภาพของโมเดลได้เพียงพอ

### 6.5.1.7 ตัวอย่างเปรียบเทียบ Accuracy, Precision, Recall และ F1-score

จากข้อมูลสุนัขและแมว สามารถสรุปได้ดังนี้

| Metric    | ค่า    |
|-----------|--------|
| Accuracy  | 90.00% |
| Precision | 88.46% |
| Recall    | 92.00% |
| F1-score  | 90.20% |

จะเห็นว่าตัวชี้วัดแต่ละตัวตอบคำถามแตกต่างกัน

Accuracy บอกภาพรวมว่าทายถูกเท่าใด

Precision บอกความน่าเชื่อถือเมื่อโมเดลทำนายว่าเป็น Positive

Recall บอกความสามารถในการค้นหา Positive ที่มีอยู่จริง

F1-score พิจารณาความสมดุลระหว่าง Precision และ Recall

### 6.5.1.8 ตัวอย่าง Imbalanced Dataset: การตรวจโรคทางการแพทย์

สมมติว่ามีภาพทางการแพทย์ 1,000 ภาพ ประกอบด้วย

- ภาพผู้ป่วยที่เป็นโรค 50 ภาพ
- ภาพที่ไม่เป็นโรค 950 ภาพ

สมมติผลการทำนายของโมเดลเป็นดังนี้

| Actual / Predicted | เป็นโรค | ไม่เป็นโรค |
|--------------------|---------|------------|
| เป็นโรค            | 30      | 20         |
| ไม่เป็นโรค         | 10      | 940        |

ดังนั้น

$$TP = 30$$

$$TN = 940$$

$$FP = 10$$

$$FN = 20$$

- **Accuracy**

$$Accuracy = (30 + 940) / 1000$$

Accuracy = 97%

หากพิจารณาเฉพาะ Accuracy จะดูเหมือนว่าโมเดลมีประสิทธิภาพสูงมาก แต่ลองพิจารณา Recall

$\text{Recall} = 30 / (30 + 20)$

Recall = 60%

หมายความว่า จากผู้ป่วยที่เป็นโรคจริง 50 ราย โมเดลสามารถตรวจพบเพียง 30 ราย และพลาดไปถึง 20 ราย

ดังนั้น Accuracy 97% ไม่ได้หมายความว่าโมเดลสามารถตรวจโรคได้ดี

- **Precision**

$\text{Precision} = 30 / (30 + 10)$

Precision = 75%

- **F1-score**

$F1 = 2 \times (0.75 \times 0.60) / (0.75 + 0.60)$

$F1 \approx 66.67\%$

สรุปได้ดังนี้

| Metric    | Balanced: หมา/แมว | Imbalanced: โรค |
|-----------|-------------------|-----------------|
| Accuracy  | 90.00%            | 97.00%          |
| Precision | 88.46%            | 75.00%          |
| Recall    | 92.00%            | 60.00%          |
| F1-score  | 90.20%            | 66.67%          |

ตัวอย่างนี้แสดงให้เห็นว่า Accuracy ที่สูงกว่าไม่ได้หมายความว่าโมเดลมีประสิทธิภาพดีกว่าเสมอไป โมเดลตรวจโรคมี Accuracy 97% ซึ่งสูงกว่าโมเดลจำแนกหมาและแมวที่มี Accuracy 90% แต่มี Recall เพียง 60% และ F1-score เพียง 66.67%

ในงานทางการแพทย์ ผลลัพธ์ดังกล่าวอาจไม่เพียงพอสำหรับการนำไปใช้งานจริง เพราะโมเดลยังพลาดผู้ป่วยที่เป็นโรคถึง 40% ของผู้ป่วยทั้งหมดในตัวอย่างนี้

### 6.5.2. ROC Curve และ AUC

ROC Curve (Receiver Operating Characteristic Curve) เป็นกราฟที่ใช้แสดงความสัมพันธ์ระหว่าง True Positive Rate (TPR) และ False Positive Rate (FPR) เมื่อเปลี่ยน Threshold ที่ใช้ในการตัดสินใจของโมเดล

True Positive Rate สามารถคำนวณได้จาก

$\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$

ซึ่งมีค่าเท่ากับ Recall

ส่วน False Positive Rate คำนวณได้จาก

$$FPR = FP / (FP + TN)$$

พื้นที่ใต้ ROC Curve เรียกว่า Area Under the Curve (AUC)

โดยทั่วไป

- AUC ใกล้ 1 หมายถึงโมเดลสามารถแยกคลาสได้ดี
- AUC ใกล้ 0.5 หมายถึงความสามารถในการแยกคลาสใกล้เคียงกับการสุ่ม
- AUC = 1 หมายถึงสามารถแยกคลาสได้สมบูรณ์ตามคะแนนที่ใช้สร้าง ROC

ROC-AUC มีประโยชน์ในการเปรียบเทียบความสามารถของโมเดลในการแยกคลาส โดยไม่จำกัดอยู่ที่ Threshold เพียงค่าเดียว

### 6.5.3. การวัดประสิทธิภาพสำหรับงานถดถอย (Regression)

- **ลักษณะของงาน Regression**

Regression เป็นงานที่โมเดลต้องทำนายค่าตัวเลขต่อเนื่อง (Continuous Numerical Value) แตกต่างจาก Classification ซึ่งผลลัพธ์เป็นคลาสหรือหมวดหมู่

ตัวอย่างเช่น

- ทำนายราคาบ้าน
- ทำนายอุณหภูมิ
- ทำนายยอดขาย
- ทำนายปริมาณการใช้ไฟฟ้า
- ทำนายอายุจากข้อมูลภาพหรือข้อมูลทางชีวภาพ

ตัวอย่างเช่น หากต้องการทำนายราคาบ้าน ค่าจริงอาจเป็น 3,000,000 บาท แต่โมเดลทำนาย 2,900,000 บาท เราสามารถคำนวณความคลาดเคลื่อนระหว่างค่าจริงกับค่าทำนายได้โดยตรง

ดังนั้น การประเมิน Regression จะไม่ได้ใช้ Accuracy, Precision หรือ Recall แต่จะพิจารณาขนาดของความคลาดเคลื่อนแทน

#### 6.5.3.1 Mean Absolute Error (MAE)

MAE เป็นค่าเฉลี่ยของค่าความคลาดเคลื่อนสัมบูรณ์ระหว่างค่าจริงและค่าที่โมเดลทำนาย

$$MAE = (1/n) \sum |y_i - \hat{y}_i|$$

ค่า MAE ยิ่งต่ำ แสดงว่าโมเดลมีความคลาดเคลื่อนน้อย

ข้อดีของ MAE คือสามารถตีความได้ง่าย เพราะมีหน่วยเดียวกับตัวแปรเป้าหมาย

#### 6.5.3.2 Mean Squared Error (MSE)

MSE เป็นค่าเฉลี่ยของกำลังสองของความคลาดเคลื่อน

$$MSE = (1/n) \sum (y_i - \hat{y}_i)^2$$

เนื่องจากการยกกำลังสอง ข้อผิดพลาดที่มีขนาดใหญ่มากจะมีผลต่อค่า MSE มากกว่าข้อผิดพลาดขนาดเล็ก

#### 6.5.3.3 Root Mean Squared Error (RMSE)

RMSE คือรากที่สองของ MSE

$$RMSE = \sqrt{(1/n) \sum (y_i - \hat{y}_i)^2}$$

ข้อดีคือผลลัพธ์มีหน่วยเดียวกับค่าที่ต้องการทำนาย ทำให้ตีความได้ง่ายกว่า MSE

#### 6.5.3.4 Coefficient of Determination ( $R^2$ )

$R^2$  เป็นตัวชี้วัดที่ใช้แสดงว่าโมเดลสามารถอธิบายความแปรปรวนของข้อมูลได้มากน้อยเพียงใด

$$R^2 = 1 - [\sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2]$$

โดยทั่วไปค่า  $R^2$  ที่สูงแสดงว่าโมเดลสามารถอธิบายข้อมูลได้ดีขึ้น แต่ไม่ควรใช้  $R^2$  เพียงตัวเดียวในการประเมินโมเดล

### 6.5.4. การประเมินงานที่ไม่มี Ground Truth

ในหัวข้อ 6.2 ได้กล่าวถึง Unsupervised Learning ซึ่งแตกต่างจาก Supervised Learning ตรงที่ข้อมูลฝึกไม่มี Label หรือคำตอบที่ถูกต้องกำกับไว้

ตัวอย่างที่สำคัญคือ Clustering

สมมติว่ามีข้อมูลลูกค้า 1,000 คน และต้องการแบ่งออกเป็น 3 กลุ่มโดยไม่ทราบล่วงหน้าว่าลูกค้าควรอยู่กลุ่มใด

เมื่อใช้ K-Means โมเดลอาจแบ่งข้อมูลออกเป็น 3 กลุ่มได้ แต่เราไม่สามารถกล่าวได้ทันทีว่าการจัดกลุ่มนั้นมี Accuracy 90% เพราะไม่มีคำตอบจริงให้เปรียบเทียบ

ดังนั้นจึงต้องใช้วิธีประเมินที่เหมาะสมกับ Unsupervised Learning เช่น Silhouette Score, Davies-Bouldin Index หรือ Calinski-Harabasz Index

อย่างไรก็ตาม รายละเอียดของตัวชี้วัดเหล่านี้อยู่นอกขอบเขตหลักของบทนี้ เนื่องจากบทนี้มุ่งเน้นการทำความเข้าใจการประเมินโมเดลสำหรับ Classification และ Regression ซึ่งเป็นงานหลักของ Supervised Learning

ในกรณีที่มีข้อมูล Label จากภายนอกสำหรับใช้ตรวจสอบผลการจัดกลุ่ม อาจใช้ตัวชี้วัดประเภทอื่นเพื่อเปรียบเทียบผลการจัดกลุ่มกับ Label ได้ แต่ไม่ควรถือว่า Clustering เป็นงานที่วัดด้วย Accuracy โดยตรงเช่นเดียวกับ Classification

#### 6.5.5. สรุปการเลือกตัวชี้วัด

การเลือกตัวชี้วัดต้องพิจารณาจากลักษณะของงานและผลกระทบของความผิดพลาด ไม่ควรเลือกตัวชี้วัดจากค่าที่สูงหรือต่ำเพียงอย่างเดียว

| ลักษณะงาน                                     | ตัวชี้วัดหลัก                            | ประเด็นสำคัญ                                                       |
|-----------------------------------------------|------------------------------------------|--------------------------------------------------------------------|
| Classification: ข้อมูลสมดุล                   | Accuracy, Precision, Recall, F1-score    | Accuracy สามารถใช้เป็นภาพรวมได้ แต่ควรดู Confusion Matrix ร่วมด้วย |
| Classification: ข้อมูลไม่สมดุล                | Precision, Recall, F1-score              | Accuracy เพียงอย่างเดียวอาจทำให้เข้าใจผิด                          |
| Classification: ต้องการลด False Positive      | Precision                                | ให้ความสำคัญกับความถูกต้องของ Positive ที่ทำนาย                    |
| Classification: ต้องการลด False Negative      | Recall                                   | ให้ความสำคัญกับการค้นหา Positive ให้ครบ                            |
| Classification: ต้องการสมดุล Precision/Recall | F1-score                                 | เหมาะเมื่อทั้งสองด้านมีความสำคัญ                                   |
| Regression                                    | MAE, MSE, RMSE, $R^2$                    | พิจารณาความคลาดเคลื่อนของค่าที่ทำนาย                               |
| Clustering                                    | Silhouette และตัวชี้วัดสำหรับ Clustering | ไม่มี Ground Truth โดยทั่วไป จึงไม่ใช้ Accuracy โดยตรง             |

ดังนั้น สำหรับบทนี้ การทำความเข้าใจ **Classification** และ **Regression** เป็นแกนหลักของการวัดประสิทธิภาพจะเหมาะสมกว่า เพราะทำให้ผู้เรียนสามารถเชื่อมโยงได้โดยตรงระหว่าง

Supervised Learning → Training Dataset → Model → Prediction → Ground Truth  
→ Error → Evaluation Metric

ในขณะที่ Clustering สามารถกล่าวถึงในฐานะงานของ Unsupervised Learning และอธิบายเพียงหลักการว่าการประเมินแตกต่างจาก Supervised Learning เนื่องจากไม่มี Ground Truth โดยทั่วไป

## แบบฝึกหัดท้ายบทที่ 6

1. จงอธิบายความหมายของการเรียนรู้ของเครื่อง (Machine Learning) และอธิบายความแตกต่างระหว่างการเขียนโปรแกรมแบบดั้งเดิมกับการเรียนรู้ของเครื่อง
2. จงยกตัวอย่างการประยุกต์ใช้การเรียนรู้ของเครื่องในชีวิตประจำวันหรือในงานด้านต่าง ๆ อย่างน้อย 5 ตัวอย่าง พร้อมอธิบายหลักการทำงานโดยสังเขป
3. องค์ประกอบสำคัญของระบบการเรียนรู้ของเครื่องประกอบด้วยอะไรบ้าง จงอธิบายหน้าที่ของแต่ละองค์ประกอบ
4. จงอธิบายประเภทของการเรียนรู้ของเครื่อง พร้อมเปรียบเทียบความแตกต่างระหว่าง
5. การเรียนรู้แบบมีผู้สอน (Supervised Learning)
6. การเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning)
7. การเรียนรู้แบบเสริมกำลัง (Reinforcement Learning)
8. จงยกตัวอย่างปัญหาที่เหมาะสมกับการเรียนรู้แบบมีผู้สอน การเรียนรู้แบบไม่มีผู้สอน และการเรียนรู้แบบเสริมกำลัง อย่างละ 3 ตัวอย่าง
9. การจำแนกประเภท (Classification) และการถดถอย (Regression) มีความแตกต่างกันอย่างไร จงยกตัวอย่างการประยุกต์ใช้งานของแต่ละประเภท
10. จงอธิบายความหมายของข้อมูลแบบมีป้ายกำกับ (Labeled Data) และข้อมูลแบบไม่มีป้ายกำกับ (Unlabeled Data)
11. จงอธิบายหน้าที่ของชุดข้อมูลฝึก (Training Dataset) ชุดข้อมูลตรวจสอบ (Validation Dataset) และชุดข้อมูลทดสอบ (Testing Dataset)
12. กระบวนการพัฒนาโมเดลการเรียนรู้ของเครื่อง (Machine Learning Pipeline) ประกอบด้วยขั้นตอนใดบ้าง จงอธิบายโดยสังเขป
13. ความสามารถในการสรุปผลทั่วไป (Generalization) คืออะไร และมีความสำคัญต่อการสร้างโมเดลอย่างไร
14. จงอธิบายความหมายของ Underfitting และ Overfitting พร้อมยกตัวอย่างประกอบ
15. ลักษณะของโมเดลที่เกิดปัญหา Underfitting และ Overfitting แตกต่างกันอย่างใด
16. จงอธิบายสาเหตุที่ทำให้เกิดปัญหา Overfitting และเสนอแนวทางในการลดปัญหาดังกล่าว
17. เพราะเหตุใดจึงไม่ควรใช้ข้อมูลชุดทดสอบ (Testing Dataset) ในการฝึกโมเดล
18. Confusion Matrix คืออะไร และประกอบด้วยองค์ประกอบใดบ้าง
19. จงอธิบายความหมายของ True Positive (TP), True Negative (TN), False Positive (FP) และ False Negative (FN)

20. Accuracy, Precision และ Recall แตกต่างกันอย่างไรร และควรเลือกใช้ในสถานการณ์ใด
21. เพราะเหตุใดการใช้ค่า Accuracy เพียงอย่างเดียวอาจไม่เพียงพอสำหรับการประเมินประสิทธิภาพของโมเดล
22. F1-score มีความสำคัญอย่างไร และเหมาะสมกับลักษณะของข้อมูลแบบใด
23. ROC Curve และค่า AUC มีหน้าที่อย่างไรในการประเมินประสิทธิภาพของโมเดลจำแนกประเภท
24. จงอธิบายความหมายของ Mean Absolute Error (MAE), Mean Squared Error (MSE) และ Root Mean Squared Error (RMSE)
25. ค่า Coefficient of Determination ( $R^2$ ) ใช้สำหรับวัดประสิทธิภาพของโมเดลประเภทใด และสามารถตีความค่าได้อย่างไร
26. เพราะเหตุใดการประเมินประสิทธิภาพของงานจัดกลุ่มข้อมูล (Clustering) จึงแตกต่างจากงานจำแนกประเภท
27. จงอธิบายหลักการทํางานของ Silhouette Score, Davies-Bouldin Index และ Calinski-Harabasz Index
28. จงเปรียบเทียบข้อดีและข้อจำกัดของตัวชี้วัดประสิทธิภาพที่ใช้ในงาน Classification, Regression และ Clustering
29. สมมติว่าต้องการสร้างระบบตรวจจับอีเมลขยะ (Spam Detection) จงตอบคำถามต่อไปนี้
  - ก) ปัญหาดังกล่าวจัดอยู่ในประเภทของการเรียนรู้แบบใด
  - ข) เป็นปัญหาแบบ Classification หรือ Regression
  - ค) ควรแบ่งข้อมูลออกเป็นกี่ส่วน และแต่ละส่วนมีหน้าที่อย่างไร
  - ง) ควรใช้ตัวชี้วัดใดในการประเมินประสิทธิภาพของโมเดล พร้อมอธิบายเหตุผล
30. สมมติว่าต้องการพยากรณ์ราคาบ้านจากพื้นที่ใช้สอย จำนวนห้องนอน และทำเลที่ตั้ง จงตอบคำถามต่อไปนี้
  - ก) ปัญหาดังกล่าวจัดอยู่ในประเภทใด
  - ข) ควรเลือกใช้ตัวชี้วัดใดในการประเมินผล
  - ค) หากโมเดลมีค่า MSE สูงมาก ควรตีความผลลัพธ์ดังกล่าวอย่างไร
31. หากโมเดลมีความแม่นยำบนข้อมูลฝึกเท่ากับ 99% แต่มีความแม่นยำบนข้อมูลทดสอบเพียง 75% ปัญหาดังกล่าวเรียกว่าอะไร และควรมีแนวทางแก้ไขอย่างไร
32. หากโมเดลมีความแม่นยำต่ำทั้งบนข้อมูลฝึกและข้อมูลทดสอบ ปัญหาดังกล่าวเรียกว่าอะไร และควรปรับปรุงโมเดลด้วยวิธีใด
33. จงสรุปแนวคิดสำคัญของการเรียนรู้ของเครื่องที่ได้รับจากบทนี้ พร้อมอธิบายว่าความรู้ดังกล่าวสามารถนำไปประยุกต์ใช้ในงานด้านใดได้บ้าง