

บทที่ 7

ต้นไม้ตัดสินใจ

7.1 ความหมายของต้นไม้ตัดสินใจ

ต้นไม้ตัดสินใจ (Decision Tree) เป็นอัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) ที่ได้รับความนิยมอย่างแพร่หลาย เนื่องจากมีหลักการทำงานที่เข้าใจง่าย สามารถแสดงผลลัพธ์ในรูปแบบของโครงสร้างต้นไม้ ซึ่งช่วยให้มนุษย์สามารถอธิบายเหตุผลของการตัดสินใจของโมเดลได้อย่างชัดเจน (Explainable AI)

ต้นไม้ตัดสินใจสามารถนำไปประยุกต์ใช้ได้ทั้งงานการจำแนกประเภทข้อมูล (Classification) และงานการพยากรณ์ค่าตัวเลข (Regression) โดยอาศัยการแบ่งข้อมูลออกเป็นกลุ่มย่อยตามเงื่อนไขของคุณลักษณะ (Feature) ที่มีอยู่ในชุดข้อมูล จนกระทั่งได้ผลลัพธ์สุดท้ายที่ต้องการ

โครงสร้างของต้นไม้ตัดสินใจมีลักษณะคล้ายต้นไม้กลับหัว โดยเริ่มต้นจากโหนดราก (Root Node) ซึ่งเป็นจุดเริ่มต้นของการตัดสินใจ จากนั้นข้อมูลจะถูกแบ่งออกเป็นกิ่ง (Branch) ตามเงื่อนไขต่าง ๆ ไปยังโหนดภายใน (Internal Node) และสิ้นสุดที่โหนดใบ (Leaf Node) ซึ่งแสดงผลลัพธ์การทำนาย ดังแสดงในรูปที่ 7.1

เมื่อมีข้อมูลใหม่เข้ามา โมเดลจะนำข้อมูลดังกล่าวไปผ่านเงื่อนไขของแต่ละโหนด ตั้งแต่โหนดรากไปจนถึงโหนดใบ เพื่อกำหนดว่าข้อมูลนั้นควรถูกจัดให้อยู่ในคลาสใด หรือควรมีค่าพยากรณ์เท่าใด

ตัวอย่างเช่น หากต้องการพิจารณาว่านักศึกษาคนหนึ่งจะสอบผ่านหรือไม่ โมเดลอาจพิจารณาจากจำนวนชั่วโมงการอ่านหนังสือ คะแนนเก็บ และจำนวนครั้งที่เข้าเรียน โดยสร้างเงื่อนไขการตัดสินใจในลักษณะของต้นไม้ เช่น

- หากจำนวนชั่วโมงการอ่านหนังสือมากกว่า 10 ชั่วโมงต่อสัปดาห์ ให้พิจารณาจากคะแนนเก็บ
- หากคะแนนเก็บมากกว่า 60 คะแนน ให้ทำนายว่า "สอบผ่าน"
- หากคะแนนเก็บน้อยกว่าหรือเท่ากับ 60 คะแนน ให้ทำนายว่า "สอบไม่ผ่าน"

ด้วยลักษณะการทำงานดังกล่าว ทำให้ ต้นไม้ตัดสินใจเป็นอัลกอริทึมที่ได้รับความนิยมในงานที่ต้องการความสามารถในการอธิบายผลการตัดสินใจ เช่น งานด้านการแพทย์ การเงิน การวิเคราะห์ความเสี่ยง และระบบสนับสนุนการตัดสินใจ

7.1.1. องค์ประกอบของต้นไม้ตัดสินใจ

ต้นไม้ตัดสินใจประกอบด้วยองค์ประกอบสำคัญ 4 ส่วน ดังนี้

1) โหนดราก (Root Node)

โหนดรากเป็นจุดเริ่มต้นของต้นไม้ ใช้สำหรับรับข้อมูลทั้งหมดเข้าสู่กระบวนการตัดสินใจ และเป็นโหนดแรกที่ทำหน้าที่แบ่งข้อมูลออกเป็นกลุ่มย่อยตามคุณลักษณะที่เหมาะสมที่สุด

2) โหนดภายใน (Internal Node)

โหนดภายในเป็นจุดที่ใช้สร้างเงื่อนไขในการแบ่งข้อมูล โดยแต่ละโหนดจะพิจารณาคุณลักษณะหนึ่งของข้อมูล เช่น อายุ รายได้ หรือระดับการศึกษา เพื่อนำข้อมูลไปยังเส้นทางที่เหมาะสม

3) กิ่ง (Branch)

กิ่งเป็นเส้นเชื่อมระหว่างโหนดต่าง ๆ โดยแต่ละกิ่งแสดงถึงผลลัพธ์ของเงื่อนไขที่เกิดขึ้น เช่น

- อายุ > 30 ปี
- รายได้ $\leq 20,000$ บาท

4) โหนดใบ (Leaf Node)

โหนดใบเป็นจุดสิ้นสุดของต้นไม้ ซึ่งแสดงผลลัพธ์ของการทำนาย โดยในงาน Classification จะเป็นคลาสของข้อมูล ส่วนในงาน Regression จะเป็นค่าตัวเลขที่โมเดลพยากรณ์

7.2 โครงสร้างของต้นไม้ตัดสินใจ

ต้นไม้ตัดสินใจ (Decision Tree) มีโครงสร้างลักษณะคล้ายต้นไม้กลับหัว ประกอบด้วยโหนด (Node) และกิ่ง (Branch) ที่เชื่อมต่อกันเป็นลำดับชั้น โดยแต่ละโหนดทำหน้าที่เป็นจุดตัดสินใจสำหรับแบ่งข้อมูลออกเป็นกลุ่มย่อยตามเงื่อนไขของคุณลักษณะ (Feature) ที่กำหนด จนกระทั่งได้ผลลัพธ์สุดท้ายที่ต้องการ

โครงสร้างของต้นไม้ตัดสินใจสามารถแบ่งออกเป็น 4 ส่วนสำคัญ ได้แก่ โหนดราก (Root Node) โหนดภายใน (Internal Node) กิ่ง (Branch) และโหนดใบ (Leaf Node) ดังแสดงในรูปที่ 7.2

7.2.1. โหนดราก (Root Node)

โหนดรากเป็นจุดเริ่มต้นของต้นไม้ตัดสินใจ โดยทำหน้าที่รับข้อมูลทั้งหมดเข้าสู่กระบวนการเรียนรู้ และเลือกคุณลักษณะที่เหมาะสมที่สุดสำหรับการแบ่งข้อมูลครั้งแรก

ตัวอย่างเช่น หากต้องการทำนายว่านักศึกษาจะสอบผ่านหรือไม่ อาจเลือก "จำนวนชั่วโมงการอ่านหนังสือต่อสัปดาห์" เป็นเงื่อนไขแรกของต้นไม้ ดังนั้นโหนดรากอาจกำหนดเงื่อนไขว่า

- จำนวนชั่วโมงการอ่านหนังสือ > 10 ชั่วโมง
- จำนวนชั่วโมงการอ่านหนังสือ ≤ 10 ชั่วโมง

การเลือกคุณลักษณะในโหนดรากถือเป็นขั้นตอนที่สำคัญ เนื่องจากมีผลกระทบต่อประสิทธิภาพของต้นไม้ทั้งหมด

7.2.2. โหนดภายใน (Internal Node)

โหนดภายในเป็นโหนดที่ใช้สำหรับสร้างเงื่อนไขเพิ่มเติมเพื่อแบ่งข้อมูลออกเป็นกลุ่มย่อยที่มีความคล้ายคลึงกันมากขึ้น โดยแต่ละโหนดจะพิจารณาคุณลักษณะหนึ่งของข้อมูล

ตัวอย่างเช่น หลังจากแบ่งข้อมูลตามจำนวนชั่วโมงการอ่านหนังสือแล้ว อาจพิจารณาคะแนนเก็บของนักศึกษาเป็นเงื่อนไขถัดไป ดังนี้

- คะแนนเก็บ > 60 คะแนน
- คะแนนเก็บ ≤ 60 คะแนน

ต้นไม้ตัดสินใจสามารถมีโหนดภายในได้หลายระดับ ขึ้นอยู่กับความซับซ้อนของข้อมูลและเงื่อนไขที่ใช้ในการแบ่งข้อมูล

7.2.3. กิ่ง (Branch)

กิ่งเป็นเส้นเชื่อมระหว่างโหนดต่าง ๆ โดยแต่ละกิ่งแสดงผลลัพธ์ของเงื่อนไขที่ใช้ในการแบ่งข้อมูล

ตัวอย่างเช่น

- อายุ > 30 ปี
- รายได้ $\leq 20,000$ บาท
- คะแนนเก็บ > 60 คะแนน

กิ่งแต่ละเส้นแสดงเส้นทางที่ข้อมูลจะถูกส่งต่อไปยังโหนดถัดไป จนกระทั่งถึงโหนดใบ

7.2.4. โหนดใบ (Leaf Node)

โหนดใบเป็นโหนดสุดท้ายของต้นไม้ ซึ่งแสดงผลลัพธ์ของการทำนาย โดยไม่มีการแบ่งข้อมูลเพิ่มเติม

สำหรับงาน Classification โหนดใบจะแสดงคลาสของข้อมูล เช่น


- ผ่าน
- ไม่ผ่าน
- แมว
- สุนัข
- ดอกกุหลาบ

ส่วนในงาน Regression โหนดใบจะแสดงค่าตัวเลขที่โมเดลพยากรณ์ เช่น

- ราคา 3,500,000 บาท
- อุณหภูมิ 32.5 องศาเซลเซียส
- ปริมาณฝน 120 มิลลิเมตร

ตัวอย่างโครงสร้างของต้นไม้ตัดสินใจ

พิจารณาการทำนายผลการสอบของนักศึกษาโดยใช้จำนวนชั่วโมงการอ่านหนังสือและคะแนนเก็บเป็นตัวแปรในการตัดสินใจ



จากตัวอย่างข้างต้น

- โหนดราก คือ "ชั่วโมงการอ่านหนังสือ > 10 ?"
- โหนดภายใน คือ "คะแนนเก็บ > 60 ?"
- กิ่ง คือ เส้นทาง "ใช่" และ "ไม่ใช่"
- โหนดใบ คือ "ผ่าน" และ "ไม่ผ่าน"

ความลึกของต้นไม้ (Tree Depth)

ความลึกของต้นไม้ (Tree Depth) หมายถึงจำนวนระดับของโหนดจากโหนดรากไปจนถึงโหนดใบที่ลึกที่สุด

ต้นไม้ที่มีความลึกมากจะสามารถเรียนรู้รูปแบบที่ซับซ้อนของข้อมูลได้ดีขึ้น แต่หากมีความลึกมากเกินไปอาจทำให้เกิดปัญหา Overfitting ซึ่งหมายถึงการที่โมเดลจดจำข้อมูลฝึกมากเกินไป ส่งผลให้ประสิทธิภาพในการทำนายข้อมูลใหม่ลดลง

ดังนั้น การกำหนดความลึกของต้นไม้ให้เหมาะสมจึงเป็นปัจจัยสำคัญที่ส่งผลต่อประสิทธิภาพของโมเดล

7.3 การจำแนกประเภทด้วยต้นไม้ตัดสินใจ (Decision Tree Classification)

การจำแนกประเภท (Classification) เป็นกระบวนการเรียนรู้ของเครื่องที่มีวัตถุประสงค์เพื่อทำนายว่าข้อมูลตัวอย่างหนึ่งควรอยู่ในกลุ่มหรือคลาสใด โดยอาศัยข้อมูลที่ได้จากการเรียนรู้จากชุดข้อมูลฝึก (Training Set) ที่มีการกำหนดผลลัพธ์ที่ถูกต้องไว้ล่วงหน้า

ต้นไม้ตัดสินใจเป็นหนึ่งในอัลกอริทึมที่นิยมใช้สำหรับงาน Classification เนื่องจากสามารถสร้างกฎการตัดสินใจในลักษณะของต้นไม้ที่เข้าใจได้ง่าย และสามารถอธิบายเหตุผลของการทำนายได้อย่างชัดเจน

หลักการทำงานของต้นไม้ตัดสินใจในงาน Classification คือการแบ่งข้อมูลออกเป็นกลุ่มย่อยอย่างต่อเนื่องตามเงื่อนไขของคุณลักษณะ (Feature) ต่าง ๆ จนกระทั่งข้อมูลภายในแต่ละกลุ่มมีความคล้ายคลึงกันมากที่สุด จากนั้นโหนดปลาย (Leaf Node) จะถูกกำหนดให้เป็นคลาสของข้อมูลที่พบมากที่สุดภายในกลุ่มนั้น ตัวอย่างการประยุกต์ใช้งาน Decision Tree Classification ได้แก่

- การจำแนกอีเมลว่าเป็นอีเมลปกติหรืออีเมลสแปม
- การวินิจฉัยโรคจากอาการของผู้ป่วย
- การจำแนกชนิดของดอกไม้
- การประเมินความเสี่ยงในการให้สินเชื่อ
- การทำนายว่านักศึกษาจะสอบผ่านหรือไม่

โดยทั่วไป การจำแนกประเภทสามารถแบ่งออกได้เป็น 2 ลักษณะ ได้แก่ การจำแนกแบบสองคลาส (Binary Classification) และการจำแนกแบบหลายคลาส (Multiclass Classification)

7.3.1. การจำแนกแบบสองคลาส (Binary Classification)

การจำแนกแบบสองคลาส (Binary Classification) เป็นการจำแนกข้อมูลออกเป็นสองกลุ่มหรือสองคลาสเท่านั้น โดยผลลัพธ์ของการทำนายจะมีเพียงสองค่าที่เป็นไปได้

ตัวอย่างของปัญหาแบบ Binary Classification ได้แก่


- ผ่าน / ไม่ผ่าน
- ป่วย / ไม่ป่วย
- อีเมลปกติ / อีเมลสแปม
- อนุมัติสินเชื่อ / ไม่อนุมัติสินเชื่อ
- ซื้อสินค้า / ไม่ซื้อสินค้า

ตัวอย่างเช่น หากต้องการสร้างระบบทำนายผลการสอบของนักศึกษาโดยใช้จำนวนชั่วโมงการอ่านหนังสือต่อสัปดาห์เป็นข้อมูลนำเข้า อาจได้กฎการตัดสินใจดังนี้

- หากจำนวนชั่วโมงการอ่านหนังสือมากกว่า 10 ชั่วโมง ให้ทำนายว่า "สอบผ่าน"

- หากจำนวนชั่วโมงการอ่านหนังสือน้อยกว่าหรือเท่ากับ 10 ชั่วโมง ให้ทำนายว่า "สอบไม่ผ่าน" สามารถแสดงโครงสร้างของต้นไม้ตัดสินใจได้ดังนี้

ชั่วโมงการอ่านหนังสือ > 10 ?



ในกรณีนี้ โมเดลจะต้องเลือกเพียงหนึ่งในสองคลาสเท่านั้น ทำให้ปัญหาดังกล่าวจัดอยู่ในประเภท Binary Classification


7.3.2. การจำแนกแบบหลายคลาส (Multiclass Classification)

การจำแนกแบบหลายคลาส (Multiclass Classification) เป็นการจำแนกข้อมูลออกเป็นมากกว่าสองคลาส โดยจำนวนคลาสอาจมีตั้งแต่ 3 คลาสขึ้นไป

ตัวอย่างของปัญหาแบบ Multiclass Classification ได้แก่

- การจำแนกชนิดของดอกไม้เป็น Setosa, Versicolor และ Virginica
- การจำแนกชนิดของผลไม้เป็น แอปเปิล ส้ม กล้วย และมะม่วง
- การจำแนกตัวเลขลายมือจาก 0 ถึง 9
- การจำแนกชนิดของสัตว์เป็น แมว สุนัข กระต่าย และนก

ตัวอย่างเช่น หากต้องการจำแนกประเภทผลไม้โดยพิจารณาจากสีและขนาดของผลไม้ อาจได้ต้นไม้ตัดสินใจดังนี้



จากตัวอย่างข้างต้น ผลลัพธ์ของการทำนายมีทั้งหมด 3 คลาส ได้แก่

- กลัวย
- ส้ม
- แอปเปิล

ดังนั้น ปัญหานี้จึงเป็นปัญหาแบบ Multiclass Classification

7.3.3. ตัวอย่างการจำแนกประเภทด้วยต้นไม้ตัดสินใจ

พิจารณาข้อมูลการพิจารณาอนุมัติสินเชื่อของลูกค้าจำนวน 8 ราย ดังตารางที่ 7.1

อายุ	รายได้	อนุมัติสินเชื่อ
25	ต่ำ	ไม่อนุมัติ
30	ต่ำ	ไม่อนุมัติ
35	สูง	อนุมัติ
40	สูง	อนุมัติ
28	ต่ำ	ไม่อนุมัติ
50	สูง	อนุมัติ
45	สูง	อนุมัติ
32	ต่ำ	ไม่อนุมัติ

เมื่อทำการเรียนรู้ข้อมูลดังกล่าว โมเดลอาจสร้างต้นไม้ตัดสินใจได้ดังนี้



เมื่อมีลูกค้ารายใหม่ที่มีรายได้สูงเข้ามา โมเดลจะนำข้อมูลดังกล่าวผ่านเงื่อนไขของต้นไม้ และทำนายว่าลูกค้ารายนั้นควรได้รับการอนุมัติสินเชื่อ

จากตัวอย่างจะเห็นว่า ต้นไม้ตัดสินใจทำหน้าที่เสมือนชุดของกฎการตัดสินใจ (Decision Rules) ซึ่งสามารถตีความและอธิบายผลลัพธ์ได้ง่ายกว่าวิธีการเรียนรู้ของเครื่องหลายประเภท

7.4 ตัวอย่างการสร้างต้นไม้ตัดสินใจสำหรับการจำแนกประเภท

ในหัวข้อที่ผ่านมาได้กล่าวถึงการจำแนกประเภทด้วยต้นไม้ตัดสินใจทั้งแบบสองคลาสและหลายคลาสแล้ว ในหัวข้อนี้จะนำเสนอตัวอย่างการสร้างต้นไม้ตัดสินใจเพื่อแสดงให้เห็นถึงหลักการแบ่งข้อมูลและการเลือกคุณลักษณะที่เหมาะสมในการสร้างกฎการตัดสินใจ

สมมติว่ามีข้อมูลวัตถุที่ประกอบด้วยสองประเภท ได้แก่

- วงกลม (Circle)
- สี่เหลี่ยมผืนผ้า (Rectangle)

โดยแต่ละวัตถุมีคุณลักษณะ 2 ค่า คือ

- ความกว้าง (Width)
- ความสูง (Height)

ดังตารางที่ 7.2

ความกว้าง (Width)	ความสูง (Height)	รูปร่าง
4	4	Circle
5	5	Circle
3	4	Circle
8	4	Rectangle
10	5	Rectangle
9	4	Rectangle

วัตถุประสงค์คือการสร้างต้นไม้ตัดสินใจเพื่อจำแนกว่าข้อมูลใหม่ควรเป็นวงกลมหรือสี่เหลี่ยมผืนผ้า

7.4.1. การเลือกคุณลักษณะสำหรับแบ่งข้อมูล

ขั้นตอนสำคัญของการสร้างต้นไม้ตัดสินใจ คือการเลือกคุณลักษณะ (Feature) ที่สามารถแบ่งข้อมูลออกเป็นกลุ่มที่มีความคล้ายคลึงกันมากที่สุด

จากข้อมูลในตารางจะพบว่า


- วงกลมมีค่าความกว้างอยู่ในช่วง 3–5
- สี่เหลี่ยมผืนผ้ามีค่าความกว้างอยู่ในช่วง 8–10

ดังนั้น คุณลักษณะ "ความกว้าง" สามารถใช้เป็นตัวแปรสำหรับแบ่งข้อมูลได้อย่างชัดเจน

หากกำหนดจุดแบ่งที่

- ความกว้างมากกว่า 6
จะได้ว่า
- $\text{Width} > 6 \rightarrow \text{Rectangle}$
- $\text{Width} \leq 6 \rightarrow \text{Circle}$

สามารถเขียนต้นไม้ตัดสินใจได้ดังนี้



จากต้นไม้ดังกล่าว หากมีข้อมูลใหม่ที่มีค่าความกว้างเท่ากับ 9 หน่วย ระบบจะทำนายว่าเป็นสีเหลืองผืนผ้า ในขณะที่ข้อมูลที่มีค่าความกว้างเท่ากับ 4 หน่วย จะถูกจัดให้อยู่ในกลุ่มวงกลม


7.4.2. การแบ่งข้อมูลหลายระดับ

ในบางกรณี ข้อมูลอาจไม่สามารถแยกออกจากกันได้ด้วยคุณลักษณะเพียงตัวเดียว จึงจำเป็นต้องแบ่งข้อมูลหลายระดับ

พิจารณาข้อมูลดังตารางที่ 7.3 ในการขออนุมัติสินเชื่อโดยตัดสินใจจากอายุ และ รายได้

อายุ	รายได้	การอนุมัติสินเชื่อ
25	ต่ำ	ไม่อนุมัติ
30	ต่ำ	ไม่อนุมัติ
35	สูง	อนุมัติ
40	สูง	อนุมัติ
28	ปานกลาง	ไม่อนุมัติ
45	สูง	อนุมัติ
50	ปานกลาง	อนุมัติ

สมมติว่าระบบเลือก "รายได้" เป็นเงื่อนไขแรกของต้นไม้ จากนั้นจึงพิจารณาอายุเพิ่มเติมในกรณีที่รายได้อยู่ในระดับปานกลาง
ต้นไม้ตัดสินใจอาจมีลักษณะดังนี้



จะเห็นว่าต้นไม้ตัดสินใจสามารถแบ่งข้อมูลหลายระดับ เพื่อเพิ่มความสามารถในการจำแนกข้อมูลที่มีความซับซ้อนมากขึ้น

7.4.3. หลักการของการแบ่งข้อมูล

เป้าหมายของการสร้างต้นไม้ตัดสินใจ คือการแบ่งข้อมูลให้ข้อมูลภายในแต่ละกลุ่มมีความคล้ายคลึงกันมากที่สุด หรือกล่าวอีกนัยหนึ่งคือ ทำให้ข้อมูลในแต่ละโหนดมีความบริสุทธิ์ (Purity) สูงที่สุด

ตัวอย่างเช่น หากโหนดหนึ่งมีข้อมูล

- Circle 3 ตัวอย่าง

- Rectangle 3 ตัวอย่าง

โหนดดังกล่าวยังมีความไม่แน่นอนสูง เนื่องจากมีข้อมูลทั้งสองคลาสปะปนกัน

แต่หากแบ่งข้อมูลจนได้

โหนดที่ 1

- Circle 3 ตัวอย่าง

โหนดที่ 2

- Rectangle 3 ตัวอย่าง

จะถือว่าโหนดทั้งสองมีความบริสุทธิ์สูง เนื่องจากแต่ละโหนดประกอบด้วยข้อมูลเพียงคลาสเดียว

ดังนั้น การสร้างต้นไม้ตัดสินใจจึงเป็นกระบวนการค้นหาเงื่อนไขการแบ่งข้อมูลที่ทำให้แต่ละโหนดมีความบริสุทธิ์มากที่สุด

7.4.4. การทำนายข้อมูลใหม่

เมื่อได้ต้นไม้ตัดสินใจที่ผ่านการเรียนรู้แล้ว ข้อมูลใหม่จะถูกส่งผ่านเงื่อนไขของแต่ละโหนดตั้งแต่โหนดรากจนถึงโหนดใบ

ตัวอย่างเช่น หากมีข้อมูลใหม่ที่มี Width = 8 และ Height = 4 ระบบจะตรวจสอบเงื่อนไข Width > 6 ใช่หรือไม่ เนื่องจากเงื่อนไขเป็นจริง จึงเดินตามกิ่งด้านซ้าย และสรุปผลว่าเป็น Rectangle

กระบวนการดังกล่าวเรียกว่า การอนุมาน (Inference) หรือ การทำนาย (Prediction)

7.5 ข้อดีและข้อจำกัดของต้นไม้ตัดสินใจ (Advantages and Limitations of Decision Tree)

ต้นไม้ตัดสินใจ (Decision Tree) เป็นอัลกอริทึมที่ได้รับความนิยมอย่างแพร่หลายในงานด้านการเรียนรู้ของเครื่อง เนื่องจากมีหลักการทำงานที่ไม่ซับซ้อนและสามารถอธิบายผลการตัดสินใจได้อย่างชัดเจน อย่างไรก็ตาม เช่นเดียวกับอัลกอริทึมอื่น ๆ ต้นไม้ตัดสินใจมีทั้งข้อดีและข้อจำกัดที่ควรพิจารณาก่อนนำไปประยุกต์ใช้งาน

7.5.1. ข้อดีของต้นไม้ตัดสินใจ

ต้นไม้ตัดสินใจมีข้อดีหลายประการ ดังนี้

1) เข้าใจและตีความผลลัพธ์ได้ง่าย

ต้นไม้ตัดสินใจสามารถแสดงกระบวนการตัดสินใจในรูปแบบของโครงสร้างต้นไม้ ทำให้ผู้ใช้งานสามารถติดตามขั้นตอนการทำนายของโมเดลได้อย่างชัดเจน จึงจัดเป็นโมเดลที่มีความสามารถในการอธิบายผลลัพธ์ (Explainable Model)

ตัวอย่างเช่น หากระบบทำนายว่าลูกค้าจะได้รับการอนุมัติสินเชื่อ ผู้ใช้งานสามารถตรวจสอบได้ว่าผลลัพธ์ดังกล่าวเกิดจากเงื่อนไขใดบ้าง เช่น รายได้ อายุ หรือประวัติทางการเงิน

2) ไม่จำเป็นต้องปรับสเกลข้อมูล

อัลกอริทึมหลายประเภทในกลุ่มการเรียนรู้ของเครื่อง (Machine Learning) จำเป็นต้องทำ Normalization หรือ Standardization ก่อนการเรียนรู้ แต่สำหรับต้นไม้ตัดสินใจ สามารถทำงานกับข้อมูลต้นฉบับได้โดยตรง จึงช่วยลดขั้นตอนในการเตรียมข้อมูล

3) รองรับข้อมูลที่มีความสัมพันธ์แบบไม่เป็นเชิงเส้น

ต้นไม้ตัดสินใจสามารถสร้างขอบเขตการตัดสินใจที่ซับซ้อนได้ ทำให้สามารถเรียนรู้ข้อมูลที่มีความสัมพันธ์แบบไม่เป็นเชิงเส้น (Non-linear Relationship) ได้ดี

ดังนั้น จึงสามารถประยุกต์ใช้กับปัญหาที่มีรูปแบบข้อมูลหลากหลายได้อย่างมีประสิทธิภาพ

4) รองรับข้อมูลหลายประเภท

ต้นไม้ตัดสินใจสามารถทำงานได้ทั้งกับ

- ข้อมูลเชิงตัวเลข (Numerical Data)
- ข้อมูลเชิงหมวดหมู่ (Categorical Data)

ทำให้สามารถนำไปประยุกต์ใช้กับข้อมูลในหลายลักษณะโดยไม่จำเป็นต้องปรับเปลี่ยนรูปแบบของข้อมูลมากนัก

5) ใช้งานได้ทั้ง Classification และ Regression

ต้นไม้ตัดสินใจสามารถนำไปใช้ได้ทั้ง

- การจำแนกประเภทข้อมูล (Classification)
- การพยากรณ์ค่าตัวเลข (Regression)

จึงเป็นอัลกอริทึมที่มีความยืดหยุ่นสูงและสามารถประยุกต์ใช้ได้กับปัญหาหลายประเภท

6) ใช้เวลาในการฝึกสอนค่อนข้างรวดเร็ว

เมื่อเปรียบเทียบกับอัลกอริทึมที่มีความซับซ้อนสูง เช่น Neural Network หรือ Ensemble Methods บางประเภท ต้นไม้ตัดสินใจมักใช้เวลาในการฝึกสอนน้อยกว่า และสามารถนำไปใช้งานได้อย่างรวดเร็ว

7.5.2. ข้อจำกัดของต้นไม้ตัดสินใจ

แม้ว่าต้นไม้ตัดสินใจจะมีข้อดีหลายประการ แต่ก็มีข้อจำกัดที่สำคัญ ดังนี้

1) มีโอกาสเกิด Overfitting ได้ง่าย

ต้นไม้ตัดสินใจสามารถสร้างต้นไม้ที่มีความลึกมากเกินไป ทำให้โมเดลจดจำรายละเอียดของข้อมูลฝึกมากเกินไปจนเกินไป ส่งผลให้มีประสิทธิภาพสูงกับข้อมูลฝึก แต่มีความสามารถในการทำนายข้อมูลใหม่ลดลง

ปัญหาดังกล่าวเรียกว่า Overfitting ซึ่งเป็นข้อจำกัดที่สำคัญของอัลกอริทึมชนิดนี้

2) มีความไม่เสถียร (Instability)

การเปลี่ยนแปลงข้อมูลเพียงเล็กน้อยอาจส่งผลให้โครงสร้างของต้นไม้เปลี่ยนแปลงไปอย่างมาก

ตัวอย่างเช่น การเพิ่มหรือลบข้อมูลเพียงไม่กี่ตัวอย่าง อาจทำให้คุณลักษณะที่ถูกเลือกในโน้ตดรากเปลี่ยนไป ส่งผลให้ต้นไม้ทั้งต้นมีโครงสร้างแตกต่างจากเดิม

ดังนั้น ต้นไม้ตัดสินใจจึงจัดเป็นโมเดลที่มีความไวต่อข้อมูล (Sensitive to Data)

3) มีแนวโน้มเอนเอียงไปยังคลาสที่มีจำนวนข้อมูลมากกว่า

หากจำนวนข้อมูลในแต่ละคลาสไม่สมดุล (Imbalanced Dataset) โมเดลอาจให้ความสำคัญกับคลาสที่มีจำนวนข้อมูลมากกว่า ส่งผลให้ความสามารถในการจำแนกคลาสที่มีจำนวนข้อมูลน้อยลดลง

ตัวอย่างเช่น หากข้อมูลมี

- คลาส A จำนวน 95%
- คลาส B จำนวน 5%

โมเดลอาจเรียนรู้ที่จะทำนายคลาส A เป็นส่วนใหญ่ ทำให้ประสิทธิภาพโดยรวมดูสูง แต่มีความสามารถในการจำแนกคลาส B ต่ำ

4) อาจไม่สามารถค้นหาความสัมพันธ์ที่ซับซ้อนมากได้

แม้ว่า ต้นไม้ตัดสินใจจะรองรับความสัมพันธ์แบบไม่เป็นเชิงเส้น แต่สำหรับข้อมูลที่มีรูปแบบซับซ้อนมาก อัลกอริทึมอื่น เช่น Random Forest หรือ Neural Network อาจให้ผลลัพธ์ที่ดีกว่า

5) ขอบเขตการตัดสินใจมีลักษณะเป็นขั้นบันได

เนื่องจากการแบ่งข้อมูลของ ต้นไม้ตัดสินใจเกิดจากการสร้างเงื่อนไขแบบแบ่งช่วง (Threshold) ทำให้ขอบเขตการตัดสินใจมีลักษณะไม่ต่อเนื่อง ส่งผลให้การประมาณค่าบางปัญหา โดยเฉพาะงาน Regression อาจไม่ราบรื่นเท่ากับวิธีการอื่น

ตารางที่ 7.4 สรุปข้อดีและข้อจำกัดของ Decision Tree

ข้อดี	ข้อจำกัด
เข้าใจและอธิบายผลลัพธ์ได้ง่าย	เกิด Overfitting ได้ง่าย
ไม่จำเป็นต้องปรับสเกลข้อมูล	มีความไม่เสถียรต่อการเปลี่ยนแปลงของข้อมูล
รองรับข้อมูลแบบ Non-linear	มีแนวโน้มเอนเอียงไปยังคลาสที่มีข้อมูลจำนวนมาก
รองรับข้อมูลทั้งเชิงตัวเลขและเชิงหมวดหมู่	อาจไม่เหมาะกับปัญหาที่มีความซับซ้อนสูง
ใช้ได้ทั้ง Classification และ Regression	ขอบเขตการตัดสินใจไม่ต่อเนื่อง
ใช้เวลาในการฝึกสอนค่อนข้างรวดเร็ว	-

7.6 ขั้นตอนการสร้างโมเดลต้นไม้ตัดสินใจ (Decision Tree Modeling Process)

การสร้างโมเดลต้นไม้ตัดสินใจประกอบด้วยหลายขั้นตอน ตั้งแต่การสำรวจข้อมูล การเตรียมข้อมูล การสร้างโมเดล ไปจนถึงการประเมินประสิทธิภาพของโมเดล เพื่อให้สามารถนำไปใช้งานจริงได้อย่างมีประสิทธิภาพ

โดยทั่วไป ขั้นตอนการสร้างโมเดล ต้นไม้ตัดสินใจสามารถแบ่งออกได้เป็น 5 ขั้นตอน ดังรูปที่ 7.5

1. สำรวจข้อมูล (Data Exploration)
2. เตรียมข้อมูล (Data Preprocessing)
3. สร้างโมเดลต้นไม้ตัดสินใจ (Decision Tree Modeling)

4. ฝึกสอนโมเดล (Model Training)
5. ประเมินประสิทธิภาพของโมเดล (Model Evaluation)

7.6.1. การสำรวจข้อมูล (Data Exploration)

ก่อนสร้างโมเดล จำเป็นต้องทำความเข้าใจลักษณะของข้อมูลที่จะนำมาใช้งาน ซึ่งประกอบด้วยการตรวจสอบข้อมูลเบื้องต้น เช่น

- จำนวนตัวอย่างข้อมูล
- จำนวนคุณลักษณะ (Features)
- ชนิดของข้อมูล
- การกระจายตัวของข้อมูล
- ค่าที่สูญหาย (Missing Values)

นอกจากนี้ยังสามารถใช้การแสดงผลข้อมูล (Visualization) เพื่อศึกษาความสัมพันธ์ระหว่างคุณลักษณะและตัวแปรเป้าหมาย (Target Variable) ซึ่งช่วยให้เข้าใจลักษณะของข้อมูลมากยิ่งขึ้น

ตัวอย่างเช่น

- การสร้างกราฟ Histogram
- การสร้าง Scatter Plot
- การสร้าง Box Plot

การสำรวจข้อมูลถือเป็นขั้นตอนสำคัญ เนื่องจากคุณภาพของข้อมูลส่งผลโดยตรงต่อประสิทธิภาพของโมเดลที่สร้างขึ้น

7.6.2. การเตรียมข้อมูล (Data Preprocessing)

หลังจากสำรวจข้อมูลแล้ว ขั้นตอนถัดไปคือการเตรียมข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการสร้างโมเดล

กระบวนการที่นิยมดำเนินการในขั้นตอนนี้ ได้แก่

การจัดการข้อมูลที่สูญหาย (Missing Values)

หากพบข้อมูลที่หายไป สามารถจัดการได้หลายวิธี เช่น

- ลบตัวอย่างข้อมูลดังกล่าว
- แทนค่าที่หายไปด้วยค่าเฉลี่ย (Mean)
- แทนค่าด้วยค่ามัธยฐาน (Median)
- แทนค่าด้วยค่าที่พบมากที่สุด (Mode)

การแปลงข้อมูลเชิงหมวดหมู่ให้เป็นตัวเลข

อัลกอริทึมส่วนใหญ่ไม่สามารถประมวลผลข้อมูลประเภทข้อความได้โดยตรง จึงจำเป็นต้องแปลงข้อมูลให้อยู่ในรูปตัวเลข เช่น

เพศ	หลังการแปลง
ชาย	0
หญิง	1

หรือใช้เทคนิค One-Hot Encoding สำหรับข้อมูลที่มีหลายกลุ่ม

การแบ่งชุดข้อมูล

ข้อมูลมักถูกแบ่งออกเป็นสองส่วน ได้แก่

- ชุดข้อมูลฝึก (Training Set)
- ชุดข้อมูลทดสอบ (Testing Set)

โดยทั่วไปนิยมแบ่งข้อมูลในสัดส่วน 80:20 หรือ 90:10 เพื่อใช้ชุดข้อมูลฝึกในการเรียนรู้ และใช้ชุดข้อมูลทดสอบสำหรับประเมินประสิทธิภาพของโมเดล

7.6.3. การสร้างโมเดลต้นไม้ตัดสินใจ (Decision Tree Modeling)

หลังจากเตรียมข้อมูลเรียบร้อยแล้ว จึงเข้าสู่ขั้นตอนการสร้างโมเดล สำหรับงาน Classification โมเดลจะเรียนรู้เพื่อจำแนกข้อมูลออกเป็นคลาสต่าง ๆ ส่วนงาน Regression โมเดลจะเรียนรู้เพื่อพยากรณ์ค่าตัวเลข

ในขั้นตอนนี้ โมเดลจะทำการเลือกคุณลักษณะที่เหมาะสมที่สุดสำหรับใช้แบ่งข้อมูลในแต่ละโหนด โดยอาศัยฟังก์ชันเกณฑ์ (Criterion Function) เช่น

- Gini Impurity
- Entropy
- Mean Squared Error (MSE)

กระบวนการแบ่งข้อมูลจะเกิดขึ้นซ้ำไปเรื่อย ๆ จนกระทั่งถึงเงื่อนไขหยุดการแบ่ง หรือได้โหนดใบ (Leaf Node)

7.6.4. การฝึกสอนโมเดล (Model Training)

การฝึกสอนโมเดลเป็นกระบวนการที่ใช้ข้อมูลจากชุดข้อมูลฝึก (Training Set) เพื่อสร้างต้นไม้ตัดสินใจในแต่ละโหนด โมเดลจะพิจารณาคุณลักษณะต่าง ๆ และเลือกจุดแบ่งที่ทำให้ข้อมูลภายในแต่ละกลุ่มมีความบริสุทธิ์มากที่สุด

กระบวนการดังกล่าวจะดำเนินต่อเนื่องแบบลำดับขั้นจากโหนดรากไปยังโหนดใบ จนได้ต้นไม้ตัดสินใจที่สามารถอธิบายรูปแบบของข้อมูลได้ดีที่สุด เมื่อการฝึกสอนเสร็จสิ้น โมเดลจะสามารถนำไปใช้ทำนายข้อมูลใหม่ได้

7.6.5. การประเมินประสิทธิภาพของโมเดล (Model Evaluation)


หลังจากสร้างโมเดลแล้ว จำเป็นต้องประเมินประสิทธิภาพของโมเดลด้วยข้อมูลที่ไม่เคยถูกใช้ในการฝึกสอนมาก่อน

สำหรับงาน Classification นิยมใช้ตัวชี้วัด เช่น Accuracy Precision Recall และ F1-score เป็นต้น ส่วนงาน Regression นิยมใช้ตัวชี้วัด เช่น

- Mean Squared Error (MSE)
- Mean Absolute Error (MAE)
- Root Mean Squared Error (RMSE)

หากผลการประเมินไม่เป็นที่น่าพอใจ อาจต้องปรับแต่งพารามิเตอร์ของโมเดล หรือปรับปรุงคุณภาพของข้อมูลก่อนทำการฝึกสอนใหม่อีกครั้ง

แผนภาพขั้นตอนการสร้างโมเดล Decision Tree



7.7 ฟังก์ชันเกณฑ์ (Criterion Function)

การเรียนรู้ของอัลกอริทึมการเรียนรู้ของเครื่อง (Machine Learning) จำเป็นต้องมีเกณฑ์ในการประเมินว่าโมเดลสามารถเรียนรู้ข้อมูลได้ดีเพียงใด เพื่อใช้เป็นแนวทางในการปรับปรุงประสิทธิภาพของโมเดลให้มีความถูกต้องมากขึ้น

สำหรับโครงข่ายประสาทเทียม (Neural Network) จะใช้ฟังก์ชันสูญเสีย (Loss Function) เช่น Mean Squared Error (MSE) หรือ Cross Entropy ดังสมการที่ 1 เพื่อวัดความแตกต่างระหว่างค่าที่ทำนายได้กับค่าจริง และใช้ขั้นตอน Gradient Descent เพื่อปรับค่าพารามิเตอร์ของโมเดลให้มีความผิดพลาดลดลง

ในทางตรงกันข้าม ต้นไม้ตัดสินใจไม่มีการใช้ Gradient Descent ในการเรียนรู้ แต่จะใช้ฟังก์ชันที่เรียกว่า **ฟังก์ชันเกณฑ์ (Criterion Function)** เพื่อใช้ประเมินคุณภาพของการแบ่งข้อมูลในแต่ละโหนด โดยมีวัตถุประสงค์เพื่อให้ข้อมูลภายในแต่ละกลุ่มมีความคล้ายคลึงกันมากที่สุด หรือมีความบริสุทธิ์ (Purity) สูงที่สุด

กล่าวอีกนัยหนึ่ง ฟังก์ชันเกณฑ์มีหน้าที่ช่วยตอบคำถามว่า

"ควรเลือกคุณลักษณะใดและควรแบ่งข้อมูลที่ตำแหน่งใด จึงจะทำให้การแบ่งข้อมูลมีประสิทธิภาพดีที่สุด"

ดังนั้น ทุกครั้งที่มีการสร้างโหนดใหม่ ต้นไม้ตัดสินใจจะคำนวณค่าของฟังก์ชันเกณฑ์สำหรับคุณลักษณะต่าง ๆ และเลือกคุณลักษณะที่ให้ผลลัพธ์ดีที่สุดสำหรับการแบ่งข้อมูล

7.7.1. หลักการทำงานของ Criterion Function

สมมติว่าต้องการจำแนกข้อมูลออกเป็นสองคลาส ได้แก่ Circle และ Rectangle และมีคุณลักษณะให้เลือกใช้ในการแบ่งข้อมูลหลายตัว เช่น Width Height Area

ต้นไม้ตัดสินใจ จะคำนวณค่าของฟังก์ชันเกณฑ์สำหรับคุณลักษณะแต่ละตัว แล้วเลือกคุณลักษณะที่สามารถแยกข้อมูลออกจากกันได้ดีที่สุด

หลังจากแบ่งข้อมูลครั้งแรกแล้ว ระบบจะทำกระบวนการเดียวกันนี้ซ้ำในแต่ละโหนด จนกระทั่งได้ต้นไม้ตัดสินใจที่สมบูรณ์

กระบวนการดังกล่าวเรียกว่า **Recursive Partitioning** หรือการแบ่งข้อมูลแบบลำดับขั้น

7.7.2. Criterion Function สำหรับงาน Classification

สำหรับการจำแนกประเภท (Classification) ฟังก์ชันเกณฑ์ที่นิยมใช้งาน ได้แก่

1) Gini Impurity

ใช้วัดระดับความไม่บริสุทธิ์ของข้อมูลภายในโหนด หากข้อมูลภายในโหนดเป็นคลาสเดียวกันทั้งหมด ค่า Gini Impurity จะมีค่าต่ำที่สุด

อัลกอริทึม CART (Classification and Regression Tree) นิยมใช้วิธีนี้ และเป็นค่าเริ่มต้นของไลบรารี Scikit-Learn

2) Entropy

เป็นตัววัดระดับความไม่แน่นอนของข้อมูล โดยมีพื้นฐานมาจากทฤษฎีสารสนเทศ (Information Theory) ค่า Entropy ที่ต่ำ หมายถึงข้อมูลภายในโหนดมีความเป็นระเบียบและมีความบริสุทธิ์สูง

3) Information Gain

เป็นค่าที่ใช้วัดปริมาณข้อมูลที่ได้รับจากการแบ่งข้อมูลด้วยคุณลักษณะหนึ่ง
ต้นไม้มัดตสันใจ จะเลือกคุณลักษณะที่ทำให้ค่า Information Gain มีค่ามากที่สุด

4) Gain Ratio

เป็นการปรับปรุง Information Gain เพื่อแก้ปัญหาการเอนเอียงไปยังคุณลักษณะที่มีจำนวนค่ามาก

5) Misclassification Error

เป็นตัววัดอัตราการทำนายผิดพลาดของข้อมูลในแต่ละโหนด

6) Log Loss

ใช้วัดความไม่แน่นอนของการทำนาย และจะให้ค่าความผิดพลาดสูงเมื่อโมเดลทำนายผิดด้วยความมั่นใจสูง

7.7.3. Criterion Function สำหรับงาน Regression

สำหรับการพยากรณ์ค่าตัวเลข (Regression) จะใช้ฟังก์ชันเกณฑ์ที่แตกต่างจากงาน Classification เนื่องจากผลลัพธ์เป็นค่าต่อเนื่อง

ฟังก์ชันที่นิยมใช้ ได้แก่

1) Mean Squared Error (MSE)

วัดค่าเฉลี่ยของกำลังสองของความคลาดเคลื่อนระหว่างค่าจริงกับค่าที่ทำนายได้

2) Mean Absolute Error (MAE)

วัดค่าเฉลี่ยของค่าสัมบูรณ์ของความคลาดเคลื่อน

3) Friedman's Mean Squared Error

เป็นการปรับปรุง MSE ให้เหมาะสมกับการสร้างต้นไม้ในบางกรณี

4) Poisson Deviance

นิยมใช้กับข้อมูลที่เป็นจำนวนครั้งหรือจำนวนเหตุการณ์

5) Reduction in Variance

ใช้วัดปริมาณการลดลงของความแปรปรวนภายในโหนดหลังจากแบ่งข้อมูล

7.7.4. ความแตกต่างระหว่าง Loss Function และ Criterion Function


แม้ว่าทั้งสองแนวคิดจะมีจุดประสงค์ในการลดความผิดพลาดของโมเดล แต่หลักการทำงานแตกต่างกัน ดังแสดงในตารางที่ 7.5

หัวข้อ	Loss Function	Criterion Function
อัลกอริทึมที่ใช้	Neural Network	Decision Tree
วัตถุประสงค์	ลดความคลาดเคลื่อนของผลลัพธ์	เลือกการแบ่งข้อมูลที่ดีที่สุด
วิธีการเรียนรู้	Gradient Descent	Recursive Partitioning
การปรับพารามิเตอร์	ปรับน้ำหนัก (Weights)	เลือก Feature และจุดแบ่ง
ตัวอย่าง	Cross Entropy, MSE	Gini, Entropy, MSE

จะเห็นได้ว่า Criterion Function ไม่ได้ทำหน้าที่ปรับค่าพารามิเตอร์เหมือน Neural Network แต่ทำหน้าที่เลือกการแบ่งข้อมูลที่เหมาะสมที่สุดในแต่ละโหนด

7.7.5. ภาพรวมของการเลือกคุณลักษณะด้วย Criterion Function

กระบวนการสร้างต้นไม้ตัดสินใจสามารถสรุปได้ดังนี้



7.8 การเกิด Overfitting และการตัดแต่งกิ่ง (Pruning)

หนึ่งในข้อจำกัดที่สำคัญของต้นไม้ตัดสินใจ คือการเกิดปัญหาโอเวอร์ฟิตติง (Overfitting) ซึ่งเกิดขึ้นเมื่อโมเดลเรียนรู้รายละเอียดของข้อมูลฝึกมากเกินไป ทำให้สามารถทำนายข้อมูลที่ใช้ในการฝึกสอนได้อย่างถูกต้อง แต่มีประสิทธิภาพลดลงเมื่อนำไปใช้กับข้อมูลใหม่ที่ไม่เคยพบมาก่อน

ปัญหาดังกล่าวพบได้บ่อยในต้นไม้ตัดสินใจ เนื่องจากอัลกอริทึมสามารถแบ่งข้อมูลออกเป็นโหนดย่อยได้อย่างต่อเนื่อง ส่งผลให้ต้นไม้มีความซับซ้อนมากเกินไปจนความจำเป็น

7.8.1. การเกิด Overfitting ในต้นไม้ตัดสินใจ

โดยทั่วไป ต้นไม้ที่มีความลึกมากจะสามารถเรียนรู้รายละเอียดของข้อมูลได้ดีขึ้น แต่หากมีความลึกมากเกินไป โมเดลอาจจดจำข้อมูลฝึกและสัญญาณรบกวน (Noise) ที่เกิดขึ้นในชุดข้อมูล ส่งผลให้ความสามารถในการทำนายข้อมูลใหม่ลดลง

รูปที่ 7.xx แสดงความแตกต่างระหว่างต้นไม้ที่มีความลึกเหมาะสมและต้นไม้ที่มีความลึกมากเกินไป

ลักษณะของโมเดลที่เกิด Overfitting ได้แก่

- มีความถูกต้องบนข้อมูลฝึก (Training Accuracy) สูงมาก
- มีความถูกต้องบนข้อมูลทดสอบ (Testing Accuracy) ต่ำ
- โครงสร้างของต้นไม้มีความลึกมากและมีจำนวนโหนดจำนวนมาก
- โมเดลมีความไวต่อการเปลี่ยนแปลงของข้อมูล

ดังนั้น การสร้างต้นไม้ที่มีความซับซ้อนมากเกินไปอาจไม่ได้ทำให้ประสิทธิภาพของโมเดลดีขึ้นเสมอไป

7.8.2. การตัดแต่งกิ่ง (Pruning)

การตัดแต่งกิ่ง (Pruning) เป็นกระบวนการลดความซับซ้อนของต้นไม้ตัดสินใจ โดยการลดจำนวนโหนดหรือจำกัดความลึกของต้นไม้ เพื่อป้องกันการเกิด Overfitting และช่วยให้โมเดลสามารถทำนายข้อมูลใหม่ได้ดีขึ้น

แนวคิดของการตัดแต่งกิ่งเปรียบได้กับการตัดกิ่งไม้ที่ไม่จำเป็นออก เพื่อให้ต้นไม้มีโครงสร้างที่เรียบง่ายและมีประสิทธิภาพมากขึ้น

โดยทั่วไป การตัดแต่งกิ่งสามารถแบ่งออกเป็น 2 วิธี ได้แก่

1) Pre-pruning

Pre-pruning หรือ Early Stopping เป็นการกำหนดเงื่อนไขหยุดการสร้างต้นไม้ตั้งแต่เริ่มต้น เช่น

- จำกัดความลึกสูงสุดของต้นไม้
- กำหนดจำนวนข้อมูลขั้นต่ำที่ใช้ในการแบ่งโหนด
- กำหนดจำนวนข้อมูลขั้นต่ำในโหนดใบ

วิธีนี้ช่วยลดเวลาในการฝึกสอนและลดโอกาสการเกิด Overfitting

2) Post-pruning

Post-pruning เป็นการสร้างต้นไม้ให้สมบูรณ์ก่อน จากนั้นจึงทำการตัดกิ่งที่ไม่จำเป็นออก โดยพิจารณาจากประสิทธิภาพของโมเดล

วิธีนี้สามารถสร้างโมเดลที่มีความแม่นยำสูง แต่มีขั้นตอนการคำนวณที่ซับซ้อนมากกว่า Pre-pruning ในทางปฏิบัติ ไลบรารีส่วนใหญ่มักใช้แนวคิดของ Pre-pruning เนื่องจากใช้งานได้ง่ายและมีประสิทธิภาพเพียงพอสำหรับปัญหาส่วนใหญ่

7.8.3. Hyperparameters ที่สำคัญของต้นไม้ตัดสินใจ

การควบคุมความซับซ้อนของต้นไม้ตัดสินใจสามารถทำได้ผ่านการกำหนดค่า Hyperparameters ซึ่งเป็นพารามิเตอร์ที่ผู้ใช้งานกำหนดก่อนการฝึกสอนโมเดล

ความลึกสูงสุดของต้นไม้ (max_depth)

พารามิเตอร์ max_depth ใช้กำหนดความลึกสูงสุดของต้นไม้

- ค่า max_depth มาก ทำให้ต้นไม้มีความซับซ้อนมากขึ้น
- ค่า max_depth น้อย ช่วยลดโอกาสการเกิด Overfitting

ตัวอย่างเช่น

```
DecisionTreeClassifier(max_depth=3)
```

หมายถึงต้นไม้จะมีความลึกไม่เกิน 3 ระดับ

จำนวนข้อมูลขั้นต่ำที่ใช้ในการแบ่งโหนด (min_samples_split)

พารามิเตอร์ min_samples_split ใช้กำหนดจำนวนข้อมูลขั้นต่ำที่จำเป็นสำหรับการแบ่งโหนด

```
DecisionTreeClassifier(min_samples_split=5)
```

หมายความว่าโหนดใดที่มีจำนวนข้อมูลน้อยกว่า 5 ตัวอย่าง จะไม่ถูกแบ่งออกเป็นโหนดย่อยเพิ่มเติม

จำนวนข้อมูลขั้นต่ำในโหนดใบ (min_samples_leaf)

พารามิเตอร์ min_samples_leaf ใช้กำหนดจำนวนข้อมูลขั้นต่ำที่ต้องมีในโหนดใบ

```
DecisionTreeClassifier(min_samples_leaf=2)
```

การกำหนดค่า min_samples_leaf ช่วยลดผลกระทบจากข้อมูลผิดปกติ (Outlier) และช่วยเพิ่มความสามารถในการทำนายข้อมูลใหม่

จำนวนโหนดใบสูงสุด (max_leaf_nodes)

พารามิเตอร์ max_leaf_nodes ใช้จำกัดจำนวนโหนดใบสูงสุดของต้นไม้

```
DecisionTreeClassifier(max_leaf_nodes=10)
```

การกำหนดค่า max_leaf_nodes ช่วยควบคุมขนาดของต้นไม้และลดความซับซ้อนของโมเดล

เกณฑ์ในการแบ่งข้อมูล (criterion)

พารามิเตอร์ criterion ใช้กำหนดฟังก์ชันเกณฑ์ที่ใช้ในการแบ่งข้อมูล เช่น

`DecisionTreeClassifier(criterion='gini')`

หรือ

`DecisionTreeClassifier(criterion='entropy')`

ซึ่งผู้ใช้งานสามารถเลือกให้เหมาะสมกับลักษณะของปัญหาได้

ต้นไม้ตัดสินใจมีแนวโน้มเกิดปัญหา Overfitting ได้ง่าย เนื่องจากสามารถสร้างโครงสร้างที่ซับซ้อนได้มาก การตัดแต่งกิ่งและการกำหนดค่า Hyperparameters ที่เหมาะสมจึงมีบทบาทสำคัญในการลดความซับซ้อนของโมเดล และช่วยให้โมเดลสามารถทำนายข้อมูลใหม่ได้อย่างมีประสิทธิภาพ

7.9 การถดถอยด้วยต้นไม้ตัดสินใจ (Decision Tree Regression)

นอกจากการนำต้นไม้ตัดสินใจมาใช้ในการจำแนกประเภทข้อมูลแล้ว ยังสามารถประยุกต์ใช้สำหรับการพยากรณ์ค่าตัวเลขได้ ซึ่งเรียกว่า การถดถอยด้วยต้นไม้ตัดสินใจ (Decision Tree Regression)

ผลลัพธ์ของ Regression เป็นค่าตัวเลขที่มีลักษณะต่อเนื่อง (Continuous Value) ซึ่งแตกต่างจากงาน Classification ที่ผลลัพธ์เป็นคลาสหรือกลุ่มข้อมูลที่มีจำนวนจำกัด

7.9.1. ความหมายของ Regression

Regression เป็นกระบวนการพยากรณ์ค่าตัวเลขจากข้อมูลที่มีอยู่ โดยค่าที่พยากรณ์สามารถเป็นจำนวนจริงใด ๆ ได้

ตัวอย่างของปัญหา Regression ได้แก่

- การพยากรณ์ราคาบ้าน
- การพยากรณ์อุณหภูมิ
- การพยากรณ์ปริมาณน้ำฝน
- การพยากรณ์ราคาทองคำ
- การพยากรณ์ปริมาณการใช้พลังงานไฟฟ้า

ดังนั้น Regression จึงเป็นปัญหาที่มีผลลัพธ์เป็นค่าต่อเนื่อง ไม่ใช่การจำแนกข้อมูลออกเป็นคลาสต่าง

ๆ

7.9.2. ความแตกต่างระหว่าง Classification และ Regression

แม้ว่าทั้งสองวิธีจะใช้หลักการสร้างต้นไม้ตัดสินใจเหมือนกัน แต่ผลลัพธ์ที่ได้แตกต่างกัน ดังแสดงในตารางที่ 7.xx

หัวข้อเปรียบเทียบ	Classification	Regression
ผลลัพธ์	คลาสของข้อมูล	ค่าตัวเลข
ลักษณะผลลัพธ์	ไม่ต่อเนื่อง	ต่อเนื่อง
ตัวอย่าง	ผ่าน / ไม่ผ่าน	ราคาบ้าน
อัลกอริทึม	DecisionTreeClassifier	DecisionTreeRegressor

7.9.3. หลักการทำงานของ Decision Tree Regression

Decision Tree Regression มีหลักการทำงานคล้ายกับ Decision Tree Classification โดยอัลกอริทึมจะทำการแบ่งข้อมูลออกเป็นกลุ่มย่อยหลายระดับ เพื่อให้ข้อมูลภายในแต่ละกลุ่มมีลักษณะใกล้เคียงกันมากที่สุด

เมื่อมีข้อมูลใหม่เข้ามา ระบบจะนำข้อมูลดังกล่าวไปผ่านเงื่อนไขของต้นไม้จนถึงโหนดใบ และใช้ค่าเฉลี่ยของข้อมูลที่อยู่ภายในโหนดใบนั้นเป็นผลลัพธ์ของการพยากรณ์

ดังนั้น ค่าเอาต์พุตของ Decision Tree Regression จะเป็นค่าตัวเลข ไม่ใช่ชื่อคลาส

7.9.4. ตัวอย่างการประยุกต์ใช้งาน

Decision Tree Regression ถูกนำไปใช้งานในหลายด้าน เช่น

การพยากรณ์ราคาบ้าน

ใช้ข้อมูล เช่น

- พื้นที่ใช้สอย
- จำนวนห้องนอน
- ทำเลที่ตั้ง

เพื่อพยากรณ์ราคาของบ้าน

การพยากรณ์สภาพอากาศ

ใช้ข้อมูลทางอุตุนิยมวิทยาเพื่อพยากรณ์

- อุณหภูมิ
- ปริมาณน้ำฝน
- ค่า PM2.5

การพยากรณ์ทางการเงิน

ใช้ข้อมูลในอดีตเพื่อประมาณ

- ราคาหุ้น
- ราคาทองคำ

- ยอดขายสินค้า

การพยากรณ์ปริมาณการใช้พลังงาน

ใช้ข้อมูลการใช้พลังงานในอดีตเพื่อประมาณความต้องการพลังงานในอนาคต

ต้นไม้ตัดสินใจไม่ได้จำกัดเฉพาะงานจำแนกประเภทข้อมูลเท่านั้น แต่ยังสามารถนำมาประยุกต์ใช้สำหรับการพยากรณ์ค่าตัวเลขได้อีกด้วย โดยเรียกว่า Decision Tree Regression ซึ่งมีหลักการทำงานคล้ายกับ Classification แต่ผลลัพธ์ที่ได้จะเป็นค่าตัวเลขที่มีลักษณะต่อเนื่อง และสามารถนำไปประยุกต์ใช้ในงานด้านเศรษฐศาสตร์ การเงิน การแพทย์ และการพยากรณ์ข้อมูลต่าง ๆ ได้อย่างกว้างขวาง

7.10 ตัวอย่างการสร้างโมเดล Decision Tree สำหรับการจำแนกเกรด

Decision Tree สามารถนำมาประยุกต์ใช้กับข้อมูลผลการเรียนของนักศึกษาได้ โดยในตัวอย่างนี้จะใช้ข้อมูลผลการเรียนของนักศึกษาที่เรียนรายวิชาปัญญาประดิษฐ์ (Artificial Intelligence: AI) ในปีที่ผ่านมาจำนวน 88 คน เพื่อสร้างโมเดลสำหรับจำแนกเกรดของนักศึกษา

ตัวอย่างนี้มีวัตถุประสงค์เพื่อให้นักศึกษาเห็นภาพการนำ Decision Tree ไปใช้กับปัญหาจริง ตั้งแต่การเตรียมข้อมูล การแบ่งข้อมูลสำหรับการเรียนรู้และการตรวจสอบ การสร้างโมเดล ไปจนถึงการนำโมเดลไปใช้คาดการณ์เกรดของนักศึกษาคนใหม่

7.10.1. ข้อมูลที่ใช้ในการสร้างโมเดล

ข้อมูลของนักศึกษาประกอบด้วยคะแนนจากการเรียนในรายวิชา AI ดังนี้

- Attend คือ คะแนนการเข้าเรียน
- Quiz คือ คะแนนแบบทดสอบ
- Csystem คือ คะแนน Csystem
- Midterm คือ คะแนนสอบกลางภาค
- LAB คือ คะแนนปฏิบัติการ
- Final คือ คะแนนสอบปลายภาค
- Grade คือ เกรดที่นักศึกษาได้รับ

ในการสร้างโมเดล Decision Tree จะกำหนดให้ **Grade เป็น Target** หรือผลลัพธ์ที่ต้องการให้โมเดลเรียนรู้ ส่วนคะแนน Attend, Quiz, Csystem, Midterm, LAB และ Final จะทำหน้าที่เป็น **Features** หรือข้อมูลนำเข้า ดังนั้น กระบวนการเรียนรู้สามารถแสดงได้ดังนี้

ข้อมูลนำเข้า (Features)

Attend, Quiz, Csystem, Midterm, LAB, Final



Decision Tree



Grade ผลลัพธ์ (Target)

ตัวอย่างเช่น นักศึกษาคนหนึ่งมีคะแนนดังนี้

Attend	Quiz	Csystem	Midterm	LAB	Final	Grade
10	12.43	10	15.5	10	14.5	B

โมเดลจะนำข้อมูลของนักศึกษาจำนวนมากมาเรียนรู้รูปแบบความสัมพันธ์ระหว่างคะแนนต่าง ๆ กับ Grade เพื่อสร้างกฎสำหรับจำแนกนักศึกษาคนใหม่

7.10.2. การเตรียมข้อมูล

ก่อนสร้างโมเดล จำเป็นต้องตรวจสอบข้อมูลว่ามีข้อมูลสูญหายหรือข้อมูลที่ไม่สามารถนำไปใช้ได้หรือไม่

จากข้อมูลตัวอย่างพบว่า นักศึกษา ID 46 ไม่มีคะแนน LAB

ID	Attend	Quiz	Csystem	Midterm	LAB	Final	Grade
46	0.833333	3.545455	7.5	7	ไม่มีข้อมูล	4	F

ข้อมูลที่หายไปเรียกว่า **Missing Value**

ในกรณีนี้จำเป็นต้องจัดการ Missing Value ก่อนนำข้อมูลไปสร้างโมเดล เช่น การแทนค่าที่หายไปด้วยค่าทางสถิติที่เหมาะสม

นอกจากนี้ ID ของนักศึกษาไม่ควรนำมาใช้เป็น Feature เนื่องจาก ID มีหน้าที่เพียงระบุบุคคล ไม่ได้แสดงถึงความสามารถหรือผลการเรียนของนักศึกษา

ดังนั้น Features ที่ใช้ในการสร้างโมเดลจึงประกอบด้วย

Attend, Quiz, Csystem, Midterm, LAB และ Final

ส่วน ID จะไม่ถูกนำมาใช้ในการเรียนรู้

7.10.3. การกำหนด Target

ในตัวอย่างนี้ Grade ของนักศึกษาจะถูกใช้เป็น Target โดยมีทั้งหมด 8 ระดับ ได้แก่

- A
- B+

- B
- C+
- C
- D+
- D
- F

ดังนั้นปัญหานี้เป็น **Multiclass Classification** เนื่องจากโมเดลต้องจำแนกข้อมูลออกเป็นมากกว่า 2 คลาส

ตัวอย่างเช่น นักศึกษามีคะแนน Attend = 10, Quiz = 13, Csystem = 10, Midterm = 14, LAB = 10 และ Final = 13.5 โมเดลต้องตัดสินใจว่าข้อมูลของนักศึกษาคนดังกล่าวควรอยู่ในคลาสใด เช่น A, B+, B, C+, C, D+, D หรือ F

7.10.4. การแบ่งข้อมูล Training และ Validation

ข้อมูลทั้งหมดมีจำนวน 88 คน จึงไม่ควรนำข้อมูลทั้งหมดไปใช้ในการฝึกโมเดล เพราะจะทำให้ไม่สามารถตรวจสอบได้ว่าโมเดลสามารถทำนายข้อมูลที่ไม่เคยเห็นมาก่อนได้ดีเพียงใด

ดังนั้นจึงแบ่งข้อมูลออกเป็น 2 ส่วน ได้แก่

Training Set

ใช้สำหรับให้โมเดลเรียนรู้รูปแบบจากข้อมูลในอดีต

Validation Set

ใช้สำหรับตรวจสอบประสิทธิภาพของโมเดลหลังจากเรียนรู้จาก Training Set แล้ว

ในตัวอย่างนี้กำหนดสัดส่วนประมาณ 80:20

- Training Set จำนวนประมาณ 70 คน
- Validation Set จำนวนประมาณ 18 คน

การแบ่งข้อมูลในลักษณะนี้ทำให้ข้อมูลบางส่วนถูกเก็บไว้สำหรับตรวจสอบโมเดลโดยไม่ได้ใช้ในการฝึก

7.10.5. ปัญหา Class Imbalance

เมื่อพิจารณาข้อมูลทั้ง 88 คน พบว่าจำนวนของนักศึกษาในแต่ละ Grade ไม่เท่ากัน

Grade	จำนวน
A	1
B+	1
B	10

Grade	จำนวน
C+	7
C	15
D+	39
D	14
F	1

จากตารางจะเห็นว่า Grade D+ มีจำนวนมากที่สุด ในขณะที่ Grade A, B+ และ F มีข้อมูลเพียงอย่างละ 1 คน

ลักษณะดังกล่าวเรียกว่า **Class Imbalance** หมายถึงแต่ละคลาสมีจำนวนข้อมูลไม่สมดุลกัน

ปัญหานี้มีผลต่อการสร้างโมเดล เนื่องจากโมเดลจะมีข้อมูลสำหรับเรียนรู้ Grade D+ มากกว่า Grade ที่มีข้อมูลจำนวนน้อย

ตัวอย่างเช่น โมเดลอาจสามารถเรียนรู้รูปแบบของนักศึกษาที่ได้ D+ ได้ดี แต่ไม่สามารถเรียนรู้รูปแบบของนักศึกษาที่ได้ A หรือ B+ ได้อย่างเพียงพอ เนื่องจากมีข้อมูลเพียงคนเดียว

ดังนั้น ผลลัพธ์จากตัวอย่างนี้ควรใช้เพื่อศึกษาหลักการของ Decision Tree มากกว่าการนำไปใช้เป็นระบบคาดการณ์เกรดจริง

7.10.6. การสร้างโมเดล Decision Tree

หลังจากเตรียมข้อมูลและแบ่งข้อมูลแล้ว ขั้นตอนต่อไปคือการสร้างโมเดล Decision Tree

ในขั้นตอนนี้โมเดลจะเรียนรู้จากข้อมูลของนักศึกษาที่อยู่ใน Training Set โดยพิจารณาความสัมพันธ์ระหว่างคะแนนต่าง ๆ กับ Grade

กระบวนการสามารถอธิบายได้ดังนี้

ข้อมูล Training



เลือก Feature ที่เหมาะสมสำหรับการแบ่งข้อมูล



สร้าง Node และแบ่งข้อมูล



แบ่งข้อมูลออกเป็นกลุ่มย่อย



ทำซ้ำจนได้โครงสร้างของ Decision Tree



ได้โมเดลสำหรับจำแนก Grade

ในการสร้างโมเดลสามารถกำหนด Criterion เป็น **Gini Impurity** และกำหนดความลึกของต้นไม้ด้วย max_depth

สำหรับตัวอย่างนี้กำหนดความลึกของต้นไม้ไว้ที่ระดับ 3 เพื่อควบคุมความซับซ้อนของโมเดล

การกำหนดความลึกไม่ให้มากเกินไปมีส่วนช่วยลดปัญหา **Overfitting** ซึ่งเป็นปัญหาที่โมเดลเรียนรู้ข้อมูล Training มากเกินไปจนไม่สามารถทำนายข้อมูลใหม่ได้ดี

7.10.7. การประเมินโมเดลด้วย Validation Set

หลังจากสร้างโมเดลจาก Training Set แล้ว จะนำข้อมูลจาก Validation Set ที่โมเดลไม่เคยใช้ในการเรียนรู้มาก่อนเข้าสู่โมเดล

โมเดลจะทำการคาดการณ์ Grade ของนักศึกษาแต่ละคน จากนั้นนำ Grade ที่โมเดลคาดการณ์ได้มาเปรียบเทียบกับ Grade จริง

ตัวอย่างเช่น

Grade จริง	Grade ที่โมเดลทำนาย
C	C
D+	D+
B	C
D	D
C+	C
D+	D+

กรณีที่ Grade จริงและ Grade ที่โมเดลทำนายตรงกัน ถือว่าโมเดลจำแนกข้อมูลได้ถูกต้อง ในทางกลับกัน หาก Grade จริงเป็น B แต่โมเดลทำนายเป็น C จะถือว่าโมเดลจำแนกข้อมูลผิด สามารถใช้ **Accuracy** เป็นตัวชี้วัดเบื้องต้นสำหรับประเมินประสิทธิภาพของโมเดลได้ อย่างไรก็ตาม เนื่องจากข้อมูลตัวอย่างมี Class Imbalance การพิจารณา Accuracy เพียงค่าเดียวอาจไม่เพียงพอ โดยเฉพาะเมื่อสนใจประสิทธิภาพของโมเดลใน Grade ที่มีจำนวนข้อมูลน้อย

7.10.8. การคาดการณ์เกรดของนักศึกษาจากข้อมูลของตนเอง

เมื่อโมเดลผ่านการฝึกสอนแล้ว สามารถนำมาใช้คาดการณ์ Grade ของนักศึกษาคนใหม่ได้

แนวคิดสำคัญคือ นักศึกษาสามารถนำคะแนนของตนเองเข้าสู่โมเดล แล้วให้ Decision Tree คาดการณ์ว่า Grade ที่มีแนวโน้มจะได้รับคืออะไร

ตัวอย่างข้อมูลของนักศึกษา

คะแนน	ค่า
Attend	10
Quiz	13
Csystem	10
Midterm	14
LAB	10
Final	13.5

ข้อมูลดังกล่าวจะถูกส่งเข้าสู่โมเดล

Attend = 10

Quiz = 13

Csystem = 10

Midterm = 14

LAB = 10

Final = 13.5

↓

Decision Tree

↓

Predicted Grade = C

ผลลัพธ์ที่ได้จากโมเดลคือ C

อย่างไรก็ตาม ผลลัพธ์ดังกล่าวเป็นเพียงการคาดการณ์จากรูปแบบของข้อมูลในปีที่ผ่านมา ไม่ใช่การคำนวณเกรดตามเกณฑ์จริงของรายวิชา และไม่สามารถรับประกันว่านักศึกษาจะได้รับ Grade ดังกล่าวจริง

7.10.9. การคาดการณ์เกรดก่อนสอบ Final

การประยุกต์ใช้งานที่น่าสนใจคือการคาดการณ์เกรดก่อนที่นักศึกษาจะสอบ Final

หากนักศึกษายังไม่มีคะแนน Final ไม่ควรนำ Final มาเป็นข้อมูลนำเข้า เพราะคะแนนดังกล่าวยังไม่เกิดขึ้นจริง

ดังนั้นควรสร้างโมเดลอีกชุดหนึ่งโดยใช้เฉพาะคะแนนที่นักศึกษามีอยู่ในขณะนั้น ได้แก่

- Attend
- Quiz
- Csystem

- Midterm

- LAB

จากนั้นให้โมเดลคาดการณ์ Grade

กระบวนการทำงานเป็นดังนี้

คะแนนปัจจุบันของนักศึกษา



Attend + Quiz + Csystem + Midterm + LAB



Decision Tree



Predicted Grade

ตัวอย่างเช่น นักศึกษากรอกข้อมูล

คะแนน	ค่า
Attend	10
Quiz	13
Csystem	10
Midterm	14
LAB	10

โมเดลจะใช้ข้อมูลดังกล่าวเพื่อคาดการณ์ Grade โดยไม่ใช้คะแนน Final

แนวทางนี้สามารถนำไปพัฒนาเป็นโปรแกรมขนาดเล็กที่ให้นักศึกษากรอกคะแนนของตนเองและดู Grade ที่โมเดลคาดการณ์ได้

7.10.10. ข้อควรระวังในการคาดการณ์เกรด

การใช้ Decision Tree เพื่อคาดการณ์เกรดจากข้อมูลนักศึกษาปีที่ผ่านมาเป็นตัวอย่างที่ช่วยให้เข้าใจ Machine Learning ได้ง่าย แต่มีข้อจำกัดหลายประการ

1. จำนวนข้อมูลมีน้อย

ข้อมูลมีเพียง 88 คน ซึ่งอาจไม่เพียงพอสำหรับการเรียนรู้รูปแบบของนักศึกษาทุกระดับเกรด

2. จำนวนข้อมูลแต่ละ Grade ไม่สมดุล

Grade D+ มีข้อมูลจำนวนมาก ในขณะที่ Grade A, B+ และ F มีข้อมูลเพียงอย่างละ 1 คน ทำให้โมเดลมีโอกาสเรียนรู้คลาสที่มีข้อมูลมากได้ดีกว่าคลาสที่มีข้อมูลน้อย

3. ผลการคาดการณ์ขึ้นอยู่กับข้อมูลในอดีต

Decision Tree เรียนรู้จากข้อมูลนักศึกษาปีที่ผ่านมา หากรูปแบบการเรียนรู้ การสอบ หรือการให้คะแนนในปีปัจจุบันแตกต่างจากปีที่ผ่านมา ผลการคาดการณ์อาจมีความคลาดเคลื่อน

4. ไม่ควรใช้ ID เป็น Feature

ID เป็นเพียงหมายเลขประจำตัวนักศึกษา ไม่ได้แสดงความสัมพันธ์กับผลการเรียน

5. ต้องระวัง Data Leakage

หากต้องการคาดการณ์เกรดก่อนสอบ Final ไม่ควรใช้ Final เป็น Feature เนื่องจากคะแนน Final ยังไม่เกิดขึ้นจริง

6. ผลการคาดการณ์ไม่ใช่เกรดจริง

Grade ที่โมเดลคาดการณ์เป็นผลลัพธ์จากการเรียนรู้รูปแบบของข้อมูลในอดีต ไม่ใช่ผลการตัดเกรดอย่างเป็นทางการ

7.10.11. สรุปตัวอย่าง

ตัวอย่างการจำแนกเกรดด้วย Decision Tree แสดงให้เห็นการนำ Machine Learning มาแก้ปัญหาที่สามารถพบได้ในชีวิตจริง โดยใช้ข้อมูลผลการเรียนของนักศึกษาวิชา AI ในปีที่ผ่านมา จำนวน 88 คนเป็นข้อมูลสำหรับสร้างโมเดล

กระบวนการเริ่มจากการกำหนด Features และ Target ตรวจสอบและเตรียมข้อมูล แบ่งข้อมูลเป็น Training Set และ Validation Set จากนั้นสร้าง Decision Tree และประเมินผลด้วยข้อมูลที่ไม่ได้ใช้ในการฝึก

เมื่อโมเดลถูกสร้างขึ้นแล้ว สามารถนำคะแนนของนักศึกษาคนใหม่เข้าสู่โมเดลเพื่อคาดการณ์ Grade ได้ นอกจากนี้ยังสามารถสร้างโมเดลสำหรับคาดการณ์เกรดก่อนสอบ Final โดยใช้เฉพาะคะแนนที่มีอยู่ในขณะนั้น

ตัวอย่างนี้ยังแสดงให้เห็นประเด็นสำคัญของการทำ Machine Learning ได้แก่ **Missing Value, Training Set, Validation Set, Class Imbalance, Overfitting และ Data Leakage** ซึ่งเป็นสิ่งที่ต้องพิจารณาออกเหนือจากการเลือกอัลกอริทึม

สำหรับการเรียนในรายวิชานี้ นักศึกษาไม่จำเป็นต้องเขียนอัลกอริทึม Decision Tree ขึ้นมาเอง แต่สามารถใช้ไลบรารี เช่น **Scikit-learn** เพื่อสร้างและทดลองโมเดลได้ โดยเน้นทำความเข้าใจว่า **ข้อมูลอะไรควรนำเข้า โมเดลทำงานอย่างไร ผลลัพธ์หมายถึงอะไร และควรประเมินความน่าเชื่อถือของผลลัพธ์อย่างไร**

แบบฝึกหัดท้ายบทที่ 7

1. จงอธิบายความหมายของต้นไม้ตัดสินใจ (Decision Tree) และยกตัวอย่างการประยุกต์ใช้งานอย่างน้อย 2 ตัวอย่าง
2. จงอธิบายองค์ประกอบสำคัญของต้นไม้ตัดสินใจ พร้อมอธิบายหน้าที่ขององค์ประกอบแต่ละส่วน
3. จงอธิบายความแตกต่างระหว่าง Root Node, Internal Node และ Leaf Node
4. จงอธิบายหลักการทำงานของต้นไม้ตัดสินใจในการจำแนกประเภทข้อมูล
5. จงอธิบายความแตกต่างระหว่าง Binary Classification และ Multiclass Classification พร้อมยกตัวอย่างประกอบ
6. เพราะเหตุใดต้นไม้ตัดสินใจจึงจัดเป็นโมเดลที่สามารถอธิบายผลลัพธ์ได้ง่าย (Explainable Model)
7. จงอธิบายข้อดีของต้นไม้ตัดสินใจอย่างน้อย 3 ข้อ
8. จงอธิบายข้อจำกัดของต้นไม้ตัดสินใจอย่างน้อย 3 ข้อ
9. จงอธิบายขั้นตอนการสร้างโมเดลต้นไม้ตัดสินใจตั้งแต่การสำรวจข้อมูลจนถึงการประเมินประสิทธิภาพของโมเดล
10. ฟังก์ชันเกณฑ์ (Criterion Function) มีหน้าที่สำคัญอย่างไรในการสร้างต้นไม้ตัดสินใจ
11. Gini Impurity และ Entropy มีวัตถุประสงค์ในการใช้งานอย่างไร
12. จงอธิบายความหมายของปัญหา Overfitting ที่เกิดขึ้นในต้นไม้ตัดสินใจ
13. เพราะเหตุใดต้นไม้ตัดสินใจที่มีความลึกมากเกินไปจึงอาจทำให้ประสิทธิภาพในการทำนายข้อมูลใหม่ลดลง
14. การตัดแต่งกิ่ง (Pruning) คืออะไร และมีประโยชน์อย่างไรต่อประสิทธิภาพของโมเดล
15. จงอธิบายความแตกต่างระหว่าง Pre-pruning และ Post-pruning
16. พารามิเตอร์ max_depth มีหน้าที่อย่างไร และมีผลต่อการเกิด Overfitting อย่างไร
17. พารามิเตอร์ min_samples_split และ min_samples_leaf มีหน้าที่อย่างไรในการควบคุมความซับซ้อนของต้นไม้ตัดสินใจ
18. จงอธิบายความหมายของ Decision Tree Regression
19. จงเปรียบเทียบความแตกต่างระหว่าง Decision Tree Classification และ Decision Tree Regression
20. จงยกตัวอย่างการประยุกต์ใช้งานของ Decision Tree Regression มาอย่างน้อย 3 ตัวอย่าง