

บทที่ 8

โครงข่ายประสาทเทียม

โครงข่ายประสาทเทียม หรือ Artificial Neural Network (ANN) เป็นหนึ่งในแบบจำลองสำคัญของการเรียนรู้ของเครื่องที่ใช้สำหรับเรียนรู้ความสัมพันธ์และรูปแบบจากข้อมูล แตกต่างจากระบบปัญญาประดิษฐ์ที่อาศัยการกำหนดกฎหรือเงื่อนไขโดยตรง โครงข่ายประสาทเทียมสามารถปรับค่าพารามิเตอร์ภายในแบบจำลองจากข้อมูลตัวอย่าง เพื่อให้สามารถสร้างผลลัพธ์ที่เหมาะสมกับปัญหาได้

เนื้อหาในบทที่ผ่านมาได้แสดงให้เห็นว่า ปัญญาประดิษฐ์สามารถแก้ปัญหาได้ด้วยหลายแนวทาง เช่น การค้นหา การแทนความรู้และการให้เหตุผล รวมถึงการเรียนรู้ของเครื่อง ในบทที่ 6 และบทที่ 7 ได้ศึกษาการสร้างแบบจำลองที่เรียนรู้จากข้อมูล โดยเฉพาะต้นไม้ตัดสินใจ ซึ่งสร้างกระบวนการตัดสินใจจากการแบ่งข้อมูลตามคุณลักษณะต่าง ๆ โครงข่ายประสาทเทียมเป็นอีกแนวทางหนึ่งของการเรียนรู้ของเครื่องที่เหมาะสมสำหรับการเรียนรู้ความสัมพันธ์ที่มีความซับซ้อนมากขึ้น

ความเข้าใจเกี่ยวกับนิวรอนเทียม การเชื่อมต่อเป็นชั้น และกระบวนการเรียนรู้ของโครงข่ายประสาทเทียมในบทนี้ จะเป็นพื้นฐานสำหรับการศึกษาปัญญาประดิษฐ์ยุคใหม่ในบทถัดไป โดยเฉพาะการประยุกต์ใช้โครงข่ายประสาทเทียมกับข้อมูลภาพในรูปแบบของ Convolutional Neural Network และแนวคิดของ Generative AI

8.1 แนวคิดพื้นฐานของโครงข่ายประสาทเทียม


แนวคิดของโครงข่ายประสาทเทียมได้รับแรงบันดาลใจจากระบบประสาทของสิ่งมีชีวิต โดยเฉพาะแนวคิดที่ว่าเซลล์ประสาทจำนวนมากสามารถรับ ส่ง และประมวลผลข้อมูลร่วมกัน เซลล์ประสาทแต่ละเซลล์ไม่ได้ทำหน้าที่แก้ปัญหาที่ซับซ้อนเพียงลำพัง แต่การเชื่อมต่อและการทำงานร่วมกันของเซลล์ประสาทจำนวนมากทำให้เกิดความสามารถในการประมวลผลข้อมูลที่ซับซ้อน

ในระบบประสาทชีวภาพ เซลล์ประสาทหรือ Neuron มีส่วนประกอบสำคัญ ได้แก่ เดนไดรต์ (Dendrite) ซึ่งทำหน้าที่รับสัญญาณจากเซลล์ประสาทอื่น ตัวเซลล์ (Cell Body) ซึ่งทำหน้าที่ประมวลผลสัญญาณที่ได้รับ และแอกซอน (Axon) ซึ่งทำหน้าที่ส่งสัญญาณต่อไปยังเซลล์ประสาทอื่น

แนวคิดดังกล่าวถูกนำมาประยุกต์ใช้ในการสร้างแบบจำลองทางคอมพิวเตอร์ที่เรียกว่า นิวรอนเทียม (Artificial Neuron) โดยนิวรอนเทียมจะรับข้อมูลจากอินพุตหลายตัว นำข้อมูลแต่ละตัวมาพิจารณาร่วมกับค่าที่แสดงระดับความสำคัญของข้อมูล จากนั้นจึงคำนวณและสร้างผลลัพธ์เพื่อส่งต่อไปยังนิวรอนอื่นหรือใช้เป็นผลลัพธ์ของแบบจำลอง

ดังแสดงในรูปที่ 1 แนวคิดของนิวรอนเทียมสามารถเปรียบเทียบกับเซลล์ประสาทชีวภาพได้ในระดับพื้นฐาน โดยส่วนที่ทำหน้าที่รับข้อมูลมีความคล้ายคลึงกับการรับสัญญาณผ่านเดนไดรต์ ข้อมูลที่ได้รับจะ

ถูกนำเข้าสู่กระบวนการคำนวณ ซึ่งสามารถเปรียบเทียบกับการประมวลผลของตัวเซลล์ และผลลัพธ์ที่ได้จะถูกส่งต่อไปยังหน่วยอื่นในลักษณะที่คล้ายกับการส่งสัญญาณผ่านแอกซอน



รูปที่ 1 การเปรียบเทียบแนวคิดระหว่างเซลล์ประสาทชีวภาพและนิวรอนเทียม

อย่างไรก็ตาม นิวรอนเทียมไม่ได้เป็นการจำลองโครงสร้างหรือการทำงานของเซลล์ประสาทชีวภาพอย่างละเอียด แต่เป็นแบบจำลองเชิงคณิตศาสตร์ที่นำแนวคิดของการรับข้อมูล การประมวลผล และการส่งผลลัพธ์มาใช้ ดังนั้น การศึกษานิวรอนเทียมจึงควรมุ่งเน้นไปที่องค์ประกอบทางการคำนวณและความสัมพันธ์ระหว่างข้อมูลนำเข้า พารามิเตอร์ และผลลัพธ์ของแบบจำลอง

นิวรอนเทียมหนึ่งหน่วยสามารถรับข้อมูลนำเข้าหลายค่า สมมติว่ามีข้อมูลนำเข้า

$$x_1, x_2, x_3, \dots, x_n \quad (1)$$

ข้อมูลแต่ละตัวจะมีค่าน้ำหนัก หรือ Weight กำกับอยู่ ได้แก่

$$w_1, w_2, w_3, \dots, w_n \quad (2)$$

ค่าน้ำหนักใช้กำหนดระดับอิทธิพลของข้อมูลนำเข้าแต่ละตัวต่อผลลัพธ์ของนิวรอน ตัวอย่างเช่น หากข้อมูลนำเข้าสองตัวมีความสำคัญต่อการตัดสินใจไม่เท่ากัน นิวรอนสามารถกำหนดค่าน้ำหนักที่แตกต่างกันให้กับข้อมูลทั้งสองตัวได้

ก่อนที่จะสร้างผลลัพธ์ นิวรอนจะคำนวณผลรวมแบบถ่วงน้ำหนัก หรือ Weighted Sum ของข้อมูลนำเข้า ซึ่งสามารถเขียนในรูปสมการได้ดังนี้

$$z = x_1 w_1 + x_2 w_2 + \dots + x_n w_n + b \quad (3)$$


หรือเขียนในรูปผลรวมได้ว่า

$$z = \sum_{i=1}^n x_i w_i + b \quad (4)$$

โดย (b) คือค่า Bias ซึ่งเป็นพารามิเตอร์เพิ่มเติมที่ช่วยเพิ่มความยืดหยุ่นให้กับแบบจำลอง จากนั้น ค่า (z) จะถูกส่งผ่านฟังก์ชันที่เรียกว่า ฟังก์ชันกระตุ้น (Activation Function) เพื่อสร้างผลลัพธ์สุดท้ายของนิวรอน ดังสมการ

$$y = f(z) \quad (5)$$

โดย (f) แทน ฟังก์ชันกระตุ้น (Activation Function) และ (y) คือผลลัพธ์ของนิวรอน กระบวนการทำงานดังกล่าวแสดงให้เห็นในรูปที่ 2 ซึ่งประกอบด้วยข้อมูลนำเข้าหลายตัว ได้แก่ $(x_1, x_2, \dots, x_n)$ แต่ละข้อมูลจะเชื่อมต่อเข้าสู่นิวรอนผ่านค่าน้ำหนักที่แตกต่างกัน จากนั้นระบบจะคำนวณผลรวมแบบถ่วงน้ำหนักร่วมกับค่า Bias ก่อนส่งค่าที่ได้ผ่าน ฟังก์ชันกระตุ้น (Activation Function) เพื่อสร้างผลลัพธ์



รูปที่ 2 โครงสร้างพื้นฐานและกระบวนการทำงานของนิวรอนเทียม

แนวคิดสำคัญของโครงข่ายประสาทเทียมอยู่ที่การกำหนดค่าของ Weight และ Bias หากค่าพารามิเตอร์เหล่านี้เปลี่ยนแปลง ผลลัพธ์ของนิวรอนก็สามารถเปลี่ยนแปลงได้เช่นกัน ดังนั้น ในกระบวนการเรียนรู้ของโครงข่ายประสาทเทียม เป้าหมายสำคัญจึงไม่ใช่เพียงการนำข้อมูลเข้าสู่แบบจำลองและคำนวณผลลัพธ์ แต่เป็นการปรับค่า Weight และ Bias ให้เหมาะสมกับข้อมูลและปัญหาที่กำลังศึกษา

แนวคิดนี้มีความสัมพันธ์โดยตรงกับการเรียนรู้ของเครื่องที่ได้กล่าวถึงในบทที่ 6 กล่าวคือ แบบจำลองจะใช้ข้อมูลตัวอย่างเพื่อเรียนรู้ความสัมพันธ์ระหว่างข้อมูลนำเข้าและผลลัพธ์ที่ต้องการ ในกรณีของโครงข่ายประสาทเทียม ความรู้ที่แบบจำลองเรียนรู้จะถูกเก็บไว้ในรูปของค่าพารามิเตอร์ต่าง ๆ โดยเฉพาะ Weight และ Bias

ตัวอย่างเช่น หากต้องการสร้างระบบเพื่อพิจารณาว่านักศึกษาควรผ่านรายวิชาหรือไม่ ระบบอาจใช้ข้อมูลหลายตัว เช่น คะแนนสอบ คะแนนงาน และอัตราการเข้าเรียน ข้อมูลแต่ละประเภทอาจมีผลต่อผลลัพธ์ในระดับที่แตกต่างกัน ในระหว่างกระบวนการเรียนรู้ แบบจำลองสามารถปรับค่าน้ำหนักเพื่อค้นหาความสัมพันธ์ระหว่างข้อมูลเหล่านี้กับผลลัพธ์ที่ต้องการ

เมื่อมีนิวรอนเทียมเพียงหนึ่งหน่วย ความสามารถของแบบจำลองจะยังมีข้อจำกัดในการเรียนรู้ปัญหาที่มีความซับซ้อน อย่างไรก็ตาม เมื่อนำ Artificial Neuron หลายหน่วยมาเชื่อมต่อกัน ผลลัพธ์จากนิวรอนหนึ่งสามารถส่งต่อไปยังนิวรอนอื่น ทำให้เกิดโครงสร้างที่สามารถประมวลผลข้อมูลเป็นลำดับและเรียนรู้ความสัมพันธ์ที่ซับซ้อนมากขึ้น การเชื่อมต่อนิวรอนจำนวนมากในลักษณะดังกล่าวจึงเรียกว่า โครงข่ายประสาทเทียม

ดังนั้น แนวคิดพื้นฐานของโครงข่ายประสาทเทียมสามารถสรุปได้ว่า แบบจำลองประกอบด้วยหน่วยประมวลผลที่เรียกว่านิวรอนเทียม นิวรอนแต่ละหน่วยรับข้อมูลจากอินพุตหรือจากนิวรอนอื่น ข้อมูลจะถูกคำนวณรวมกับค่าน้ำหนักและค่า Bias ก่อนผ่าน ฟังก์ชันกระตุ้น (Activation Function) เพื่อสร้างผลลัพธ์ เมื่อมีการเชื่อมต่อนิวรอนจำนวนมากและมีการปรับค่าพารามิเตอร์จากข้อมูล โครงข่ายจึงสามารถเรียนรู้รูปแบบและความสัมพันธ์ที่ซับซ้อนมากขึ้นได้


จากแนวคิดพื้นฐานนี้ หัวข้อถัดไปจะศึกษาหน้าที่ขององค์ประกอบต่าง ๆ ของนิวรอนเทียมและฟังก์ชันที่ใช้ในการสร้างผลลัพธ์ โดยเฉพาะบทบาทของ ฟังก์ชันกระตุ้น (Activation Function) ซึ่งเป็นองค์ประกอบสำคัญที่ทำให้โครงข่ายประสาทเทียมสามารถจัดการกับความสัมพันธ์ของข้อมูลที่มีความซับซ้อนได้

8.2 ฟังก์ชันกระตุ้น

จากหัวข้อ 8.1 ได้กล่าวถึงโครงสร้างพื้นฐานของนิวรอนเทียม ซึ่งเริ่มต้นจากการรับข้อมูลนำเข้าหลายค่า จากนั้นข้อมูลแต่ละค่าจะถูกนำมาคำนวณรวมกับค่าน้ำหนักและค่าไบแอสเพื่อสร้างค่าก่อนการกระตุ้น ดังสมการที่ 3

ค่าที่ได้จากการคำนวณดังกล่าวยังไม่ใช่ผลลัพธ์สุดท้ายของนิวรอน แต่จะถูกส่งต่อเข้าสู่ฟังก์ชันกระตุ้น (Activation Function) เพื่อแปลงค่าให้เป็นผลลัพธ์ของนิวรอน ดังความสัมพันธ์ที่แสดงในสมการที่ 5

ดังแสดงในรูปที่ 3 กระบวนการทำงานของนิวรอนเทียมสามารถแบ่งออกเป็นสองส่วนหลัก ได้แก่ ส่วนแรกคือการคำนวณผลรวมแบบถ่วงน้ำหนักร่วมกับค่าไบแอส เพื่อสร้างค่า (z) และส่วนที่สองคือการนำค่า (z) ผ่านฟังก์ชันกระตุ้นเพื่อสร้างผลลัพธ์ (y)



รูปที่ 3 บทบาทของฟังก์ชันกระตุ้นในการทำงานของนิวรอนเทียม

ฟังก์ชันกระตุ้นมีความสำคัญต่อโครงข่ายประสาทเทียม เนื่องจากช่วยกำหนดลักษณะของผลลัพธ์ที่นิวรอนจะส่งต่อไปยังนิวรอนอื่น หากโครงข่ายประสาทเทียมใช้เพียงการคำนวณแบบเชิงเส้นในทุกชั้น แม้จะมีนิวรอนจำนวนมากหรือมีหลายชั้น ผลลัพธ์ของโครงข่ายก็ยังสามารถอธิบายได้ด้วยความสัมพันธ์เชิงเส้น

การใช้ฟังก์ชันกระตุ้นที่มีลักษณะไม่เป็นเชิงเส้นจึงช่วยให้โครงข่ายประสาทเทียมสามารถเรียนรู้ความสัมพันธ์ของข้อมูลที่ซับซ้อนมากขึ้น ตัวอย่างเช่น ข้อมูลบางประเภทไม่สามารถแบ่งออกเป็นกลุ่มด้วยเส้นตรงเพียงเส้นเดียว การใช้ฟังก์ชันกระตุ้นรวมกับการเชื่อมต่อนิวรอนหลายชั้นช่วยให้แบบจำลองสามารถสร้างขอบเขตการตัดสินใจที่ซับซ้อนขึ้นได้

ฟังก์ชันกระตุ้นที่นิยมใช้มีหลายรูปแบบ โดยแต่ละฟังก์ชันมีลักษณะและการใช้งานที่แตกต่างกัน ในหัวข้อนี้จะกล่าวถึงฟังก์ชันพื้นฐาน ได้แก่ ฟังก์ชันขั้นบันได ฟังก์ชันซิกมอยด์ และฟังก์ชัน ReLU รวมถึงแนวคิดพื้นฐานในการเลือกใช้ฟังก์ชันกระตุ้น


8.2.1. ฟังก์ชันขั้นบันได

ฟังก์ชันขั้นบันได หรือ Step Function เป็นหนึ่งในฟังก์ชันกระตุ้นแบบพื้นฐาน ใช้สำหรับกำหนดผลลัพธ์เป็นค่าที่ไม่ต่อเนื่อง เช่น 0 หรือ 1

ตัวอย่างของฟังก์ชันขั้นบันไดสามารถกำหนดได้ดังนี้

$$f(z) = \begin{cases} 1 & \text{if } z \geq 0 \\ 0 & \text{if } z < 0 \end{cases} \quad (6)$$

กล่าวคือ หากค่าที่คำนวณได้มีค่ามากกว่าหรือเท่ากับศูนย์ ฟังก์ชันจะให้ผลลัพธ์เป็น 1 แต่หากมีค่าน้อยกว่าศูนย์จะให้ผลลัพธ์เป็น 0 ดังแสดงในรูปที่ 4 ฟังก์ชันขั้นบันไดมีลักษณะเป็นการเปลี่ยนค่าผลลัพธ์อย่างทันทีจาก 0 ไปเป็น 1 เมื่อค่าอินพุตผ่านค่าที่กำหนด ฟังก์ชันลักษณะนี้เหมาะสำหรับการอธิบายแนวคิดพื้นฐานของการตัดสินใจแบบสองทาง เช่น ใช่หรือไม่ใช่ เปิดหรือปิด หรืออยู่ในกลุ่มที่กำหนดหรือไม่



รูปที่ 4 ลักษณะการทำงานของฟังก์ชันขั้นบันได

ฟังก์ชันขั้นบันไดมีบทบาทสำคัญในการอธิบายการทำงานของ Perceptron ซึ่งจะศึกษาในหัวข้อถัดไป เนื่องจากสามารถใช้กำหนดผลลัพธ์ของนิวรอนให้เป็นการตัดสินใจแบบ 0 หรือ 1 ได้โดยตรง


อย่างไรก็ตาม ฟังก์ชันขั้นบันไดมีข้อจำกัดเมื่อนำไปใช้กับการฝึกโครงข่ายประสาทเทียมแบบหลายชั้น เนื่องจากค่าของฟังก์ชันเปลี่ยนแปลงอย่างไม่ต่อเนื่อง และไม่เหมาะสมสำหรับกระบวนการปรับค่าพารามิเตอร์ที่อาศัยการคำนวณ Gradient ดังนั้น โครงข่ายประสาทเทียมสมัยใหม่จึงนิยมใช้ฟังก์ชันกระตุ้นรูปแบบอื่น

8.2.2. ฟังก์ชันซิกมอยด์

ฟังก์ชันซิกมอยด์ หรือ Sigmoid Function เป็นฟังก์ชันที่ใช้แปลงข้อมูลอินพุตให้มีค่าผลลัพธ์อยู่ในช่วงระหว่าง 0 และ 1 สมการของ Sigmoid Function คือ

$$f(x) = \frac{1}{1 + e^{-x}} \quad (7)$$

เมื่อค่า (x) มีค่าสูงมาก ผลลัพธ์ของ Sigmoid จะเข้าใกล้ 1 ในทางตรงกันข้าม หาก (x) มีค่าติดลบมาก ผลลัพธ์จะเข้าใกล้ 0 และเมื่อ $x = 0$ จะได้ผลลัพธ์เท่ากับ $f(0) = 0.5$ ดังแสดงในรูปที่ 5 กราฟของ Sigmoid มีลักษณะเป็นเส้นโค้งรูปตัว S โดยค่าของฟังก์ชันเปลี่ยนแปลงอย่างต่อเนื่อง ทำให้เหมาะสำหรับใช้ในแบบจำลองที่ต้องการผลลัพธ์ในช่วง 0 ถึง 1



รูปที่ 5 ลักษณะของฟังก์ชันซิกมอยด์

เนื่องจากผลลัพธ์ของ Sigmoid อยู่ในช่วง 0 ถึง 1 จึงสามารถนำไปใช้ในปัญหาการจำแนกข้อมูลแบบสองกลุ่มได้ ตัวอย่างเช่น หากแบบจำลองสร้างผลลัพธ์เท่ากับ 0.85 อาจตีความได้ว่าแบบจำลองมีแนวโน้มที่จะจัดข้อมูลอยู่ในกลุ่มที่กำหนดเป็น 1 มากกว่ากลุ่ม 0 ทั้งนี้ การตีความผลลัพธ์เป็นค่าความน่าจะเป็นต้องพิจารณาวิธีการฝึกและการออกแบบแบบจำลองร่วมด้วย


แม้ Sigmoid จะเป็นฟังก์ชันที่มีความสำคัญในประวัติศาสตร์ของ Neural Network แต่เมื่อใช้ในโครงข่ายที่มีหลายชั้นมาก อาจเกิดปัญหาที่เรียกว่า Vanishing Gradient ซึ่งจะกล่าวถึงเพิ่มเติมในระดับที่สูงขึ้น ดังนั้น ใน Hidden Layer ของ Neural Network สมัยใหม่จึงนิยมใช้ฟังก์ชันอื่น เช่น ReLU

8.2.3. ฟังก์ชัน ReLU

ReLU ย่อมาจาก Rectified Linear Unit เป็นฟังก์ชันกระตุ้นที่ได้รับความนิยมอย่างมากในการสร้างโครงข่ายประสาทเทียมสมัยใหม่ สมการของ ReLU คือ

$$f(x) = \max(0, x) \quad (8)$$

กล่าวคือ หากค่าอินพุตมีค่าน้อยกว่า 0 ผลลัพธ์จะเป็น 0 แต่หากอินพุตมีค่ามากกว่าหรือเท่ากับ 0 ผลลัพธ์จะมีค่าเท่ากับอินพุต ตัวอย่างเช่น $f(-3) = 0$ และ $f(5) = 5$ ดังแสดงในรูปที่ 6 กราฟของ ReLU จะมีค่าเป็น 0 สำหรับข้อมูลในช่วงค่าติดลบ และเพิ่มขึ้นเป็นเส้นตรงเมื่อข้อมูลมีค่ามากกว่าหรือเท่ากับ 0



รูปที่ 6 ลักษณะของฟังก์ชัน ReLU

ข้อดีสำคัญของ ReLU คือมีรูปแบบการคำนวณที่ไม่ซับซ้อน และสามารถช่วยให้โครงข่ายประสาทเทียมเรียนรู้ได้อย่างมีประสิทธิภาพในหลายกรณี ด้วยเหตุนี้ ReLU จึงถูกนำมาใช้อย่างแพร่หลายใน Hidden Layer ของโครงข่ายประสาทเทียมสมัยใหม่

อย่างไรก็ตาม ReLU ก็มีข้อจำกัดเช่นกัน หากนิวรอนได้รับค่าติดลบอย่างต่อเนื่อง ผลลัพธ์อาจกลายเป็น 0 และนิวรอนนั้นอาจไม่สามารถเรียนรู้ได้อย่างเหมาะสม ปัญหานี้เป็นหนึ่งในประเด็นที่นำไปสู่การพัฒนาฟังก์ชันกระตุ้นรูปแบบอื่น เช่น Leaky ReLU ซึ่งจะไม่กล่าวรายละเอียดในบทนี้

8.2.4. การเลือกฟังก์ชันกระตุ้น

การเลือกฟังก์ชันกระตุ้นขึ้นอยู่กับตำแหน่งของนิวรอนในโครงข่ายและลักษณะของปัญหาที่ต้องการแก้ไข โดยทั่วไปฟังก์ชันที่ใช้ใน Hidden Layer มีหน้าที่สำคัญในการเพิ่มความสามารถในการเรียนรู้ความสัมพันธ์ที่ไม่เป็นเชิงเส้น ตัวอย่างที่นิยมใช้คือ ReLU

ส่วน Output Layer จะเลือกฟังก์ชันให้เหมาะสมกับประเภทของผลลัพธ์ที่ต้องการ ตัวอย่างเช่น หากเป็นปัญหาการจำแนกข้อมูลออกเป็นสองกลุ่ม อาจใช้ Sigmoid เพื่อสร้างผลลัพธ์ในช่วง 0 ถึง 1


สำหรับปัญหาการจำแนกข้อมูลออกเป็นหลายกลุ่ม สามารถใช้ฟังก์ชัน Softmax เพื่อแปลงค่าผลลัพธ์ของแต่ละกลุ่มให้สามารถเปรียบเทียบกันได้ โดยฟังก์ชัน Softmax สามารถเขียนได้ดังนี้

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}} \quad (9)$$

โดย (z_i) คือค่าของนิวรอนสำหรับกลุ่มที่ (i) และ (K) คือจำนวนกลุ่มทั้งหมด ผลลัพธ์ของ Softmax จะมีค่าอยู่ระหว่าง 0 และ 1 และผลรวมของผลลัพธ์ทุกกลุ่มเท่ากับ 1

ในกรณีของปัญหาการทำนายค่าต่อเนื่อง เช่น การพยากรณ์อุณหภูมิ ราคาสินค้า หรือปริมาณการใช้พลังงาน Output Layer อาจใช้ฟังก์ชันเชิงเส้น หรืออาจไม่มี Activation Function เพิ่มเติม ขึ้นอยู่กับการออกแบบแบบจำลอง

ดังแสดงในรูปที่ 7 การเลือกฟังก์ชันกระตุ้นสามารถพิจารณาได้จากหน้าที่ของแต่ละชั้นและลักษณะของผลลัพธ์ โดย Hidden Layer มักใช้ ReLU เพื่อช่วยให้แบบจำลองสามารถเรียนรู้ความสัมพันธ์ที่ไม่เป็นเชิงเส้น ขณะที่ Output Layer สามารถเลือกใช้ฟังก์ชันที่แตกต่างกันตามประเภทของปัญหา



รูปที่ 7 ตัวอย่างการเลือกฟังก์ชันกระตุ้นสำหรับ Hidden Layer และ Output Layer

โดยสรุป ฟังก์ชันกระตุ้นเป็นองค์ประกอบสำคัญที่ช่วยกำหนดว่าข้อมูลที่ผ่านเข้าสู่นิวรอนจะถูกแปลงเป็นผลลัพธ์ในลักษณะใด นอกจากการใช้เพื่อกำหนดผลลัพธ์ของนิวรอนแล้ว Activation Function ยังช่วยให้โครงข่ายประสาทเทียมสามารถเรียนรู้ความสัมพันธ์ของข้อมูลที่ไม่เป็นเชิงเส้น ซึ่งเป็นคุณสมบัติสำคัญสำหรับการจัดการกับปัญหาที่มีความซับซ้อน

ความเข้าใจเกี่ยวกับฟังก์ชันกระตุ้นจะช่วยให้สามารถศึกษาการทำงานของ Perceptron ได้อย่างชัดเจนยิ่งขึ้น เนื่องจาก Perceptron เป็นแบบจำลองพื้นฐานที่ใช้แนวคิดของการรวมข้อมูลแบบถ่วงน้ำหนัก ร่วมกับฟังก์ชันสำหรับกำหนดผลลัพธ์ ซึ่งจะกล่าวถึงในหัวข้อถัดไป

8.3 เพอร์เซปตรอน

เพอร์เซปตรอน หรือ Perceptron เป็นแบบจำลองโครงข่ายประสาทเทียมรูปแบบพื้นฐานที่ใช้สำหรับการเรียนรู้และการจำแนกข้อมูล โดยสามารถมองได้ว่าเป็นการนำองค์ประกอบของนิวรอนเทียมที่กล่าวถึงในหัวข้อ 8.1 มาใช้ในการสร้างแบบจำลองที่สามารถรับข้อมูล คำนวณผลรวมแบบถ่วงน้ำหนัก และตัดสินใจสร้างผลลัพธ์ได้


แนวคิดของเพอร์เซปตรอนมีความสำคัญต่อการศึกษาพัฒนาการของโครงข่ายประสาทเทียม เนื่องจากช่วยให้เข้าใจหลักการพื้นฐานของการเรียนรู้ผ่านการปรับค่าน้ำหนัก ก่อนที่จะพัฒนาไปสู่โครงข่ายประสาทเทียมแบบหลายชั้นที่มีความสามารถในการจัดการกับปัญหาที่ซับซ้อนมากขึ้น

8.3.1. โครงสร้างและการทำงานของเพอร์เซปตรอน

เพอร์เซปตรอนประกอบด้วยข้อมูลนำเข้า ($x_1, x_2, \dots, x_n$) โดยข้อมูลแต่ละตัวมีค่าน้ำหนัก ($w_1, w_2, \dots, w_n$) กำกับอยู่ จากนั้นจะคำนวณผลรวมแบบถ่วงน้ำหนักร่วมกับค่า Bias ดังที่ได้กล่าวไว้ในสมการที่ 3

ค่าที่ได้จากการคำนวณจะถูกนำเข้าสู่ฟังก์ชันกระตุ้นเพื่อสร้างผลลัพธ์ของเพอร์เซปตรอนตามความสัมพันธ์ในสมการที่ 5 สำหรับเพอร์เซปตรอนแบบพื้นฐาน ฟังก์ชันขั้นบันไดตามสมการที่ 6 สามารถใช้เป็นฟังก์ชันกระตุ้นเพื่อกำหนดผลลัพธ์เป็น 0 หรือ 1

ดังแสดงในรูปที่ 8 เพอร์เซปตรอนรับข้อมูลนำเข้าหลายค่า โดยข้อมูลแต่ละตัวจะถูกเชื่อมต่อกับนิวรอนผ่านค่าน้ำหนัก จากนั้นค่าที่ได้จะถูกนำมารวมกันร่วมกับค่า Bias ก่อนผ่านฟังก์ชันกระตุ้นเพื่อสร้างผลลัพธ์



รูปที่ 8 โครงสร้างพื้นฐานของเพอร์เซปตรอน

กระบวนการทำงานของเพอร์เซปตรอนสามารถอธิบายเป็นลำดับได้ดังนี้

1. รับข้อมูลนำเข้า

2. คูณข้อมูลนำเข้าแต่ละตัวด้วยค่าน้ำหนักที่สอดคล้องกัน
3. รวมค่าที่ได้และเพิ่มค่า Bias
4. ส่งผลลัพธ์ที่คำนวณได้เข้าสู่ฟังก์ชันกระตุ้น
5. สร้างผลลัพธ์เป็นค่าที่ใช้สำหรับการตัดสินใจหรือการจำแนกข้อมูล

ตัวอย่างเช่น หากเพอร์เซปตรอนมีข้อมูลนำเข้าสองตัว คือ $x_1=1$, $x_2=0$ สามารถคำนวณค่าได้ตามสมการที่ 3 โดยกำหนดให้ข้อมูลนำเข้าและค่าน้ำหนักมีค่าดังนี้

$$w_1=0.6, w_2=0.4, b=-0.2$$

เมื่อนำค่าไปแทนในสมการที่ 3 จะได้

$$z = (1)(0.6) + (0)(0.4) - 0.2$$

ดังนั้น

$$z = 0.4$$

เมื่อค่า มีค่ามากกว่าหรือเท่ากับ 0 เมื่อนำไปผ่านฟังก์ชันขั้นบันไดตามสมการที่ 6 จะได้ผลลัพธ์ $y = 1$

ตัวอย่างนี้แสดงให้เห็นว่าเพอร์เซปตรอนสามารถรับข้อมูลหลายตัวและนำมาพิจารณาร่วมกัน โดยค่าน้ำหนักมีผลต่อระดับอิทธิพลของข้อมูลแต่ละตัว ขณะที่ค่า Bias สามารถเลื่อนจุดที่ใช้ในการตัดสินใจของแบบจำลอง


8.3.2. การเรียนรู้ของเพอร์เซปตรอน

ความแตกต่างสำคัญระหว่างเพอร์เซปตรอนที่กำหนดค่าด้วยมนุษย์และเพอร์เซปตรอนที่สามารถเรียนรู้ได้ คือ ความสามารถในการปรับค่าของค่าน้ำหนักและค่า Bias จากข้อมูลตัวอย่าง

ในกระบวนการเรียนรู้ จะมีข้อมูลนำเข้าพร้อมกับผลลัพธ์ที่ถูกต้องหรือ Target ตัวอย่างเช่น หากต้องการจำแนกข้อมูลออกเป็นสองกลุ่ม อาจกำหนด Target เป็น 0 และ 1

เมื่อข้อมูลถูกส่งเข้าสู่เพอร์เซปตรอนแบบจำลองจะสร้างผลลัพธ์หรือ Prediction จากนั้นนำผลลัพธ์ที่ได้ไปเปรียบเทียบกับ Target หากผลลัพธ์ไม่ถูกต้อง ค่าน้ำหนักและ Bias จะถูกปรับเพื่อให้ Perceptron มีแนวโน้มสร้างผลลัพธ์ที่ถูกต้องมากขึ้นในการคำนวณครั้งต่อไป

ดังแสดงในรูปที่ 9 กระบวนการเรียนรู้ของเพอร์เซปตรอนเริ่มจากการนำข้อมูลเข้าสู่แบบจำลองและคำนวณผลลัพธ์ จากนั้นจึงเปรียบเทียบผลลัพธ์ที่ทำนายกับ Target หากผลลัพธ์ยังไม่ถูกต้อง จะมีการปรับค่า Weight และ Bias ก่อนนำข้อมูลเข้าสู่กระบวนการเรียนรู้อีกครั้ง



รูปที่ 9 กระบวนการเรียนรู้ของ Perceptron

แนวคิดพื้นฐานของการปรับค่าน้ำหนักสามารถอธิบายได้จากค่าความคลาดเคลื่อนระหว่างผลลัพธ์ที่ถูกต้องและผลลัพธ์ที่ Perceptron ทำนาย

$$e = y' - y \quad (10)$$

โดยที่ y คือค่า Target และ y' คือผลลัพธ์ที่เพอร์เซปตรอนทำนาย

หากเพอร์เซปตรอนทำนายถูกต้อง ค่าความคลาดเคลื่อนจะเท่ากับ 0 แต่หากทำนายไม่ถูกต้อง ค่าความคลาดเคลื่อนจะมีค่าแตกต่างจาก 0 ซึ่งสามารถนำมาใช้เป็นข้อมูลในการปรับค่าน้ำหนัก

กฎการเรียนรู้ของเพอร์เซปตรอนสามารถเขียนในรูปแบบพื้นฐานได้ดังนี้

$$w_{i(new)} = w_{i(old)} + \eta e x_i \quad (11)$$

โดยที่ $w_{i(new)}$ คือค่าน้ำหนักใหม่ $w_{i(old)}$ คือค่าน้ำหนักเดิม η คือ Learning Rate ซึ่งใช้กำหนดขนาดของการปรับค่า คือค่าความคลาดเคลื่อน และ คือข้อมูลนำเข้าลำดับที่

ค่า Bias สามารถปรับได้ในลักษณะเดียวกัน ดังสมการ

$$b_{new} = b_{old} + \eta e \quad (12)$$

จากสมการที่ 11 และสมการที่ 12 จะเห็นว่า หาก Perceptron ทำนายผลลัพธ์ไม่ถูกต้อง ระบบสามารถใช้ค่าความคลาดเคลื่อนเป็นส่วนหนึ่งของการปรับ Weight และ Bias เพื่อเปลี่ยนแปลงผลลัพธ์ในการคำนวณครั้งถัดไป

กระบวนการดังกล่าวจะทำซ้ำกับข้อมูลตัวอย่างจำนวนมาก โดยในแต่ละรอบแบบจำลองจะค่อย ๆ ปรับค่าพารามิเตอร์เพื่อให้สามารถจำแนกข้อมูลได้ถูกต้องมากขึ้น กระบวนการนี้เป็นตัวอย่างพื้นฐานของแนวคิด Supervised Learning ที่ได้กล่าวถึงในบทการเรียนรู้ของเครื่อง เนื่องจากแบบจำลองใช้ข้อมูลที่มีคำตอบหรือ Target อยู่แล้วในการเรียนรู้

8.3.3. ตัวอย่างการใช้เพอร์เซปตรอนกับปัญหา AND

หนึ่งในตัวอย่างที่นิยมใช้เพื่ออธิบาย Perceptron คือการจำลองการทำงานของตรรกะ AND ซึ่งมีข้อมูลนำเข้าสองตัว ได้แก่ x_1 และ x_2 โดยผลลัพธ์จะเป็น 1 ก็ต่อเมื่อข้อมูลนำเข้าทั้งสองตัวมีค่าเป็น 1

ตารางที่ 8.1 แสดงข้อมูลของตรรกะ AND

x_1	x_2	Target
0	0	0
0	1	0
1	0	0
1	1	1

กำหนดให้ Perceptron มีค่าน้ำหนักและ Bias ดังนี้

$$w_1=1, w_2=1, b=-1.5$$

เมื่อใช้ข้อมูล $x_1 = 1$ และ $x_2 = 1$ และนำไปคำนวณตามสมการที่ 3 จะได้ $z = (1)(1) + (1)(1) - 1.5$ ดังนั้น $z = 0.5$ เมื่อนำค่า ผ่านฟังก์ชันขั้นบันไดตามสมการที่ 6 ผลลัพธ์จะเป็น $y = 1$


ในกรณีที่ข้อมูลนำเข้าคู่ใดคู่หนึ่งมีค่าเป็น 0 ผลรวมที่ได้จะมีค่าน้อยกว่า 0 ทำให้ผลลัพธ์จาก Step Function เป็น 0 ดังนั้น Perceptron ชุดนี้สามารถใช้จำลองตรรกะ AND ได้

ตัวอย่างนี้แสดงให้เห็นว่า Perceptron สามารถสร้างขอบเขตการตัดสินใจสำหรับข้อมูลที่สามารถแบ่งออกจากกันได้ด้วยเส้นตรง ซึ่งเรียกว่าปัญหาที่มีลักษณะ Linearly Separable

8.3.4. ข้อจำกัดของเพอร์เซปตรอนแบบชั้นเดียว

แม้ Perceptron จะสามารถแก้ปัญหาการจำแนกข้อมูลบางประเภทได้ แต่ Perceptron แบบชั้นเดียวมีข้อจำกัดสำคัญ คือ สามารถเรียนรู้ขอบเขตการตัดสินใจแบบเชิงเส้นได้เท่านั้น

ในกรณีที่ข้อมูลสองกลุ่มสามารถแบ่งออกจากกันด้วยเส้นตรงหรือระนาบเดียว Perceptron สามารถปรับ Weight และ Bias เพื่อสร้างขอบเขตการตัดสินใจที่เหมาะสมได้ ดังแสดงในรูปที่ 10




รูปที่ 10 ตัวอย่างข้อมูลที่สามารถแบ่งแยกได้ด้วยเส้นตรง

อย่างไรก็ตาม มีปัญหาบางประเภทที่ไม่สามารถแบ่งข้อมูลออกจากกันด้วยเส้นตรงเพียงเส้นเดียวได้ ตัวอย่างที่สำคัญคือปัญหา XOR

ตารางที่ 8.2 แสดงผลลัพธ์ของตรรกะ XOR

x_1	x_2	Target
0	0	0
0	1	1
1	0	1
1	1	0

จากข้อมูลจะเห็นว่าข้อมูลที่มี Target เท่ากับ 1 อยู่ในตำแหน่งตรงข้ามกัน ขณะที่ข้อมูลที่มี Target เท่ากับ 0 อยู่ในอีกสองตำแหน่งตรงข้าม ดังนั้นจึงไม่สามารถใช้เส้นตรงเพียงเส้นเดียวแบ่งข้อมูลทั้งสองกลุ่มออกจากกันได้ ดังแสดงในรูปที่ 11



รูปที่ 11 ข้อจำกัดของ Perceptron แบบชั้นเดียวในการแก้ปัญหา XOR

ข้อจำกัดของ XOR แสดงให้เห็นว่า การมีนิวรอนเพียงชั้นเดียวไม่เพียงพอสำหรับการแก้ปัญหาบางประเภท หากต้องการเรียนรู้ความสัมพันธ์ที่ซับซ้อนมากขึ้น จำเป็นต้องมีการเชื่อมต่อนิวรอนหลายตัวและเพิ่มชั้นสำหรับการประมวลผลข้อมูล

แนวคิดดังกล่าวนำไปสู่การพัฒนา โครงข่ายประสาทเทียมแบบหลายชั้น (Multi-Layer Neural Network) ซึ่งประกอบด้วยชั้นข้อมูลนำเข้า ชั้นซ่อน และชั้นผลลัพธ์ การเพิ่มชั้นซ่อนทำให้แบบจำลองสามารถเรียนรู้การแปลงและความสัมพันธ์ของข้อมูลในระดับที่ซับซ้อนมากขึ้น ซึ่งจะกล่าวถึงในหัวข้อถัดไป

8.4 โครงข่ายประสาทเทียมแบบหลายชั้น


ข้อจำกัดของ Perceptron แบบชั้นเดียวที่กล่าวถึงในหัวข้อ 8.3 แสดงให้เห็นว่า แบบจำลองที่มีหน่วยประมวลผลเพียงชั้นเดียวสามารถสร้างขอบเขตการตัดสินใจได้ในระดับจำกัด โดยเฉพาะปัญหาที่ข้อมูลไม่สามารถแบ่งออกจากกันด้วยเส้นตรงเพียงเส้นเดียว เช่น ปัญหา XOR การเพิ่มจำนวนหน่วยประมวลผลและจัดการเชื่อมต่อเป็นหลายชั้นจึงเป็นแนวทางสำคัญที่ช่วยให้โครงข่ายสามารถเรียนรู้ความสัมพันธ์ของข้อมูลที่ซับซ้อนมากขึ้น

โครงข่ายประสาทเทียมแบบหลายชั้น หรือ Multi-Layer Neural Network ประกอบด้วย Artificial Neuron จำนวนมากที่เชื่อมต่อกันเป็นลำดับชั้น ข้อมูลจะถูกส่งจากชั้นหนึ่งไปยังอีกชั้นหนึ่ง โดยนิวรอนในแต่ละ

ละชั้นจะรับข้อมูล คำนวณผลรวมแบบถ่วงน้ำหนักร่วมกับค่า Bias และส่งผลลัพธ์ผ่านฟังก์ชันกระตุ้นตามหลักการเดียวกับนิวรอนเทียมที่กล่าวถึงในหัวข้อ 8.1

8.4.1. ชั้นของโครงข่ายประสาทเทียม

โดยทั่วไป โครงข่ายประสาทเทียมแบบหลายชั้นสามารถแบ่งองค์ประกอบออกเป็นสามส่วนหลัก ได้แก่ Input Layer, Hidden Layer และ Output Layer ดังแสดงในรูปที่ 12



รูปที่ 12 โครงสร้างพื้นฐานของโครงข่ายประสาทเทียมแบบหลายชั้น

Input Layer เป็นชั้นที่รับข้อมูลเข้าสู่โครงข่าย จำนวนหน่วยใน Input Layer มักสัมพันธ์กับจำนวนคุณลักษณะของข้อมูล ตัวอย่างเช่น หากข้อมูลของนักศึกษาประกอบด้วยคะแนนสอบ คะแนนงาน และอัตราการเข้าเรียน ซึ่งใช้เป็นข้อมูลนำเข้าจำนวน 3 ค่า ก็สามารถกำหนดให้ Input Layer มีหน่วยรับข้อมูล 3 หน่วย

หน่วยใน Input Layer ทำหน้าที่เป็นจุดรับข้อมูลเข้าสู่โครงข่าย โดยข้อมูลจะถูกส่งต่อไปยังชั้นถัดไปเพื่อทำการคำนวณ ในระดับพื้นฐานสามารถมองว่า Input Layer ทำหน้าที่แทนข้อมูล $x_1, x_2, x_3, \dots, x_n$ ที่ได้กล่าวถึงในหัวข้อ 8.1

Hidden Layer เป็นชั้นที่อยู่ระหว่าง Input Layer และ Output Layer เรียกว่า “ชั้นซ่อน” เนื่องจากไม่ได้รับข้อมูลโดยตรงจากภายนอก และไม่ได้แสดงผลลัพธ์สุดท้ายให้ผู้ใช้งานเห็นโดยตรง แต่มีหน้าที่สำคัญในการประมวลผลและแปลงข้อมูลที่ได้รับจากชั้นก่อนหน้า

Hidden Layer สามารถประกอบด้วยนิวรอนจำนวนหนึ่ง โดยแต่ละนิวรอนจะคำนวณข้อมูลตามหลักการของ Artificial Neuron กล่าวคือ รับข้อมูลจากนิวรอนในชั้นก่อนหน้า คำนวณผลรวมแบบถ่วงน้ำหนัก ร่วมกับค่า Bias ตามสมการที่ 3 และนำผลลัพธ์ผ่านฟังก์ชันกระตุ้นตามสมการที่ 5

ผลลัพธ์จากนิวรอนใน Hidden Layer จะกลายเป็นข้อมูลนำเข้าสำหรับนิวรอนในชั้นถัดไป ด้วยเหตุนี้โครงข่ายจึงสามารถค่อย ๆ แปลงข้อมูลจากรูปแบบหนึ่งไปสู่อีกรูปแบบหนึ่งผ่านการประมวลผลหลายชั้น

Output Layer เป็นชั้นสุดท้ายของโครงข่าย มีหน้าที่สร้างผลลัพธ์ที่ใช้ตอบปัญหาหรือทำการทำนายจำนวนของนิวรอนใน Output Layer ขึ้นอยู่กับลักษณะของปัญหา

ตัวอย่างเช่น หากเป็นปัญหาการจำแนกข้อมูลออกเป็นสองกลุ่ม อาจใช้ Output Layer ที่มีนิวรอนหนึ่งหน่วยและใช้ฟังก์ชัน Sigmoid ตามสมการที่ 7 เพื่อสร้างผลลัพธ์ในช่วง 0 ถึง 1

หากเป็นปัญหาการจำแนกข้อมูลออกเป็นหลายกลุ่ม อาจกำหนดจำนวนนิวรอนใน Output Layer ให้สอดคล้องกับจำนวนกลุ่ม และใช้ฟังก์ชัน Softmax ตามสมการที่ 8 เพื่อสร้างผลลัพธ์สำหรับแต่ละกลุ่ม

ในกรณีของปัญหาการทำนายค่าต่อเนื่อง เช่น การพยากรณ์อุณหภูมิหรือราคาสินค้า Output Layer อาจมีนิวรอนหนึ่งหน่วยเพื่อสร้างค่าที่ต้องการทำนาย

ดังนั้น จำนวนชั้นและจำนวนหน่วยในแต่ละชั้นไม่ได้มีรูปแบบตายตัว แต่ขึ้นอยู่กับลักษณะของข้อมูลและปัญหาที่ต้องการแก้ไข อย่างไรก็ตาม โครงสร้างพื้นฐานที่ประกอบด้วย Input Layer, Hidden Layer และ Output Layer เป็นแนวคิดสำคัญสำหรับการทำความเข้าใจการทำงานของโครงข่ายประสาทเทียมแบบหลายชั้น

8.4.2. การเชื่อมต่อระหว่างนิวรอน

นิวรอนในโครงข่ายประสาทเทียมเชื่อมต่อกันผ่านค่าน้ำหนัก โดยผลลัพธ์จากนิวรอนหนึ่งจะถูกส่งไปเป็นข้อมูลนำเข้าของนิวรอนในชั้นถัดไป


ตัวอย่างเช่น หากมี Hidden Layer จำนวนหนึ่งชั้นที่ประกอบด้วยนิวรอน 3 หน่วย และ Output Layer มีนิวรอน 1 หน่วย ผลลัพธ์ของนิวรอนทั้ง 3 หน่วยใน Hidden Layer จะถูกนำไปใช้เป็นข้อมูลนำเข้าของนิวรอนใน Output Layer

ในโครงข่ายแบบพื้นฐาน การเชื่อมต่อระหว่างชั้นมักเป็นแบบ Fully Connected หรือการเชื่อมต่ออย่างสมบูรณ์ หมายความว่านิวรอนทุกหน่วยในชั้นหนึ่งสามารถเชื่อมต่อกับนิวรอนทุกหน่วยในชั้นถัดไป

ดังแสดงในรูปที่ 13 นิวรอนใน Input Layer ส่งข้อมูลไปยังนิวรอนทุกหน่วยใน Hidden Layer และผลลัพธ์จาก Hidden Layer จะถูกส่งต่อไปยัง Output Layer การเชื่อมต่อแต่ละเส้นมีค่าน้ำหนักของตนเอง ซึ่งเป็นพารามิเตอร์ที่สามารถปรับเปลี่ยนได้ในระหว่างกระบวนการเรียนรู้

Previous Layer

Next Layer



Each neuron in one layer is connected to every neuron in the next layer

รูปที่ 13 การเชื่อมต่อแบบ Fully Connected ระหว่างชั้นของโครงข่ายประสาทเทียม


หาก Input Layer มีจำนวน n หน่วย และ Hidden Layer มีจำนวน m หน่วย การเชื่อมต่อระหว่างสองชั้นจะมีค่าน้ำหนักจำนวน $n \times m$ ค่า โดยยังไม่รวมค่า Bias ของนิวรอนใน Hidden Layer ตัวอย่างเช่น หาก Input Layer มี 4 หน่วย และ Hidden Layer มี 3 หน่วย จะมีค่าน้ำหนักสำหรับการเชื่อมต่อระหว่างสองชั้นจำนวน $4 \times 3 = 12$ หน่วย จำนวนค่าน้ำหนักจะเพิ่มขึ้นตามจำนวนหน่วยในแต่ละชั้น ซึ่งหมายความว่าโครงข่ายที่มีขนาดใหญ่ขึ้นจะมีพารามิเตอร์จำนวนมากขึ้น และต้องการข้อมูลและทรัพยากรในการเรียนรู้เพิ่มขึ้นตามไปด้วย

8.4.3. การส่งข้อมูลไปข้างหน้า

เมื่อข้อมูลถูกส่งเข้าสู่ Input Layer ข้อมูลจะถูกส่งต่อการเชื่อมต่อไปยัง Hidden Layer นิวรอนแต่ละตัวใน Hidden Layer จะคำนวณผลรวมแบบถ่วงน้ำหนักพร้อมกับค่า Bias ตามสมการที่ 3 และนำผลลัพธ์ผ่านฟังก์ชันกระตุ้นตามสมการที่ 5

ผลลัพธ์ที่ได้จาก Hidden Layer จะถูกส่งต่อไปยัง Output Layer ซึ่งจะดำเนินการกระบวนการในลักษณะเดียวกันจนได้ผลลัพธ์สุดท้ายของโครงข่าย กระบวนการส่งข้อมูลจาก Input Layer ไปยัง Output Layer นี้เรียกว่า Forward Propagation

ดังแสดงในรูปที่ 14 ข้อมูลเคลื่อนที่ในทิศทางไปข้างหน้า เริ่มจากข้อมูลนำเข้า ผ่านการประมวลผลของ Hidden Layer และสิ้นสุดที่ Output Layer ในระหว่างกระบวนการดังกล่าว แต่ละนิวรอนจะคำนวณข้อมูลที่รับโดยใช้ Weight, Bias และ Activation Function



รูปที่ 14 กระบวนการ Forward Propagation ในโครงข่ายประสาทเทียมแบบหลายชั้น

เพื่อให้เห็นภาพของการคำนวณมากขึ้น สมมติว่าข้อมูลนำเข้าประกอบด้วย x_1 และ x_2 และมี Hidden Layer ที่ประกอบด้วยนิวรอน 2 หน่วย ได้แก่ h_1 และ h_2

นิวรอนตัวแรกใน Hidden Layer สามารถคำนวณค่าก่อนผ่านฟังก์ชันกระตุ้นได้ดังนี้

$$z_{h1} = x_1w_{11} + x_2w_{21} + b_{h1} \quad (13)$$

จากนั้นนำค่าที่ได้เข้าสู่ฟังก์ชันกระตุ้น

$$h_1 = f(z_{h1}) \quad (14)$$

ในลักษณะเดียวกัน นิวรอนตัวที่สองสามารถคำนวณได้เป็น

$$z_{h2} = x_1w_{12} + x_2w_{22} + b_{h2} \quad (15)$$

$$h_2 = f(z_{h2})$$

เมื่อได้ผลลัพธ์จาก Hidden Layer แล้ว ค่า h_1 และ h_2 จะถูกส่งต่อไปยัง Output Layer หาก Output Layer มีนิวรอนหนึ่งหน่วย สามารถคำนวณค่าก่อนผ่านฟังก์ชันกระตุ้นได้ดังนี้

$$z_o = h_1 w_1 + h_2 w_2 + b_o \quad (16)$$

$$y = f(z_o)$$

จากตัวอย่างจะเห็นว่า หลักการคำนวณของโครงข่ายแบบหลายชั้นยังคงอาศัยแนวคิดเดียวกับ Artificial Neuron หนึ่งหน่วย แต่ความแตกต่างคือผลลัพธ์จากนิวรอนในชั้นหนึ่งสามารถนำไปใช้เป็นข้อมูลนำเข้าสำหรับนิวรอนในอีกชั้นหนึ่ง ทำให้เกิดการประมวลผลเป็นลำดับหลายชั้น

8.4.4. จำนวนชั้นและความซับซ้อนของโครงข่าย

จำนวนชั้นซ่อน (Hidden Layer) และจำนวนหน่วยประมวลผล หรือนิวรอน (Neuron) ภายในแต่ละชั้น มีผลต่อความสามารถของโครงข่ายประสาทเทียมในการเรียนรู้ความสัมพันธ์จากข้อมูล โดยทั่วไป โครงข่ายที่มีโครงสร้างขนาดใหญ่ขึ้นสามารถเรียนรู้รูปแบบที่มีความซับซ้อนมากขึ้นได้ แต่ขณะเดียวกันก็ต้องใช้ทรัพยากรและข้อมูลในการฝึกเพิ่มขึ้น

โครงข่ายที่มี Hidden Layer เพียงชั้นเดียวสามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนกว่าการใช้ Perceptron แบบชั้นเดียว เนื่องจากนิวรอนภายใน Hidden Layer สามารถสร้างการแปลงข้อมูลก่อนส่งต่อไปยัง Output Layer ดังนั้นข้อมูลที่ไม่สามารถแก้ปัญหาดได้ด้วยเส้นแบ่งตรงเพียงเส้นเดียว อาจสามารถเรียนรู้ได้เมื่อมีการเพิ่มชั้นซ่อนและใช้ฟังก์ชันกระตุ้นที่เหมาะสม

เมื่อเพิ่มจำนวน Hidden Layer ข้อมูลจะถูกประมวลผลผ่านหลายชั้นตอน โดยแต่ละชั้นสามารถเรียนรู้ลักษณะหรือความสัมพันธ์บางส่วนของข้อมูล แล้วส่งผลลัพธ์ไปยังชั้นถัดไป กระบวนการลักษณะนี้ช่วยให้โครงข่ายสามารถสร้างการแปลงข้อมูลที่มีความซับซ้อนมากขึ้น ดังแสดงแนวคิดในรูปที่ 14 ซึ่งข้อมูลถูกส่งผ่านจาก Input Layer ไปยัง Hidden Layer และ Output Layer

อย่างไรก็ตาม การเพิ่มจำนวนชั้นหรือนิวรอนไม่ได้หมายความว่าแบบจำลองจะมีประสิทธิภาพดีขึ้นเสมอไป หากโครงข่ายมีขนาดใหญ่เกินความจำเป็น จำนวน Weight และ Bias ที่ต้องปรับก็จะเพิ่มขึ้น ส่งผลให้ต้องใช้เวลาและทรัพยากรในการฝึกมากขึ้น นอกจากนี้ แบบจำลองที่มีความซับซ้อนสูงอาจต้องใช้ข้อมูลที่มีจำนวนและความหลากหลายเพียงพอเพื่อให้สามารถเรียนรู้รูปแบบทั่วไปของปัญหาได้

หากแบบจำลองมีความซับซ้อนมากเกินไปเมื่อเปรียบเทียบกับข้อมูลที่ใช้ฝึก อาจเกิดปัญหา Overfitting กล่าวคือ แบบจำลองสามารถให้ผลลัพธ์ที่ติดมากับข้อมูลฝึก แต่เมื่อได้รับข้อมูลใหม่ที่ไม่เคยพบมาก่อน ประสิทธิภาพอาจลดลง ในทางตรงกันข้าม หากโครงข่ายมีจำนวนชั้นหรือนิวรอนน้อยเกินไปสำหรับปัญหาที่มีความซับซ้อนสูง แบบจำลองอาจไม่สามารถเรียนรู้รูปแบบสำคัญของข้อมูลได้อย่างเพียงพอ ซึ่งสัมพันธ์กับปัญหา Underfitting ที่ได้กล่าวถึงในบทการเรียนรู้ของเครื่อง

ดังนั้น การออกแบบโครงข่ายประสาทเทียมควรพิจารณาความสมดุลระหว่างความซับซ้อนของปัญหา ปริมาณข้อมูล และทรัพยากรที่สามารถใช้ในการประมวลผล ผู้พัฒนาไม่ควรเพิ่มจำนวนชั้นหรือนิวรอนโดยไม่

เหตุผล แต่ควรเริ่มต้นจากโครงสร้างที่เหมาะสมกับปัญหา และปรับเปลี่ยนโครงสร้างตามผลที่ได้จากการทดลอง

แนวคิดเรื่องจำนวนชั้นของโครงข่ายนำไปสู่การพัฒนาโครงข่ายประสาทเทียมที่มีรูปแบบหลากหลายมากขึ้น โดยนอกจาก Feedforward Neural Network ที่ได้กล่าวถึงแล้ว ยังมีโครงข่ายที่ได้รับการออกแบบให้เหมาะสมกับข้อมูลประเภทต่าง ๆ เช่น Recurrent Neural Network สำหรับข้อมูลแบบลำดับ และ Convolutional Neural Network สำหรับข้อมูลที่มีโครงสร้างเชิงพื้นที่ โดยเฉพาะข้อมูลภาพ

8.5 ภาพรวมประเภทของโครงข่ายประสาทเทียม

แม้ว่าโครงข่ายประสาทเทียมแต่ละประเภทจะมีโครงสร้างแตกต่างกัน แต่ทั้งหมดมีพื้นฐานร่วมกันคือ การใช้หน่วยประมวลผลที่เรียกว่า นิวรอนเทียม (Artificial Neuron) เพื่อรับข้อมูล คำนวณความสัมพันธ์ระหว่างข้อมูล และส่งผลลัพธ์ไปยังส่วนถัดไปของโครงข่าย


ความแตกต่างสำคัญระหว่างโครงข่ายแต่ละประเภทอยู่ที่ รูปแบบการเชื่อมต่อระหว่างนิวรอน และ ลักษณะของข้อมูลที่โครงข่ายถูกออกแบบมาเพื่อจัดการ ดังนั้น การเลือกใช้โครงข่ายประสาทเทียมจึงควรพิจารณาลักษณะของข้อมูลและปัญหาที่ต้องการแก้ไข

ในระดับพื้นฐาน สามารถพิจารณาประเภทของโครงข่ายประสาทเทียมที่สำคัญได้ 3 ประเภท ได้แก่ Feedforward Neural Network (FNN), Recurrent Neural Network (RNN) และ Convolutional Neural Network (CNN)

8.5.1. Feedforward Neural Network

Feedforward Neural Network หรือ FNN เป็นรูปแบบพื้นฐานของโครงข่ายประสาทเทียมที่ข้อมูลเคลื่อนที่จากชั้นข้อมูลนำเข้า ผ่านชั้นซ่อน และไปยังชั้นผลลัพธ์ในทิศทางไปข้างหน้า โดยไม่มีการส่งข้อมูลย้อนกลับไปยังชั้นก่อนหน้าในระหว่างการสร้างผลลัพธ์

โครงข่ายหลายชั้นที่ได้กล่าวถึงในหัวข้อ 8.4 เป็นตัวอย่างของ Feedforward Neural Network โดยข้อมูลจาก Input Layer จะถูกส่งผ่านไปยัง Hidden Layer และ Output Layer ตามลำดับ ดังแสดงในรูปที่



รูปที่ 15 โครงสร้างของ Feedforward Neural Network

FNN มักเหมาะกับข้อมูลที่สามารถแทนด้วยชุดของคุณลักษณะ เช่น ข้อมูลตัวเลขหรือข้อมูลเชิงตาราง ตัวอย่างเช่น ข้อมูลคะแนน คุณลักษณะของผลิตภัณฑ์ หรือข้อมูลที่ผ่านมากระบวนการเตรียมและแปลงเป็นตัวเลขแล้ว ตัวอย่างงานที่สามารถใช้ FNN ได้แก่

- การจำแนกประเภทข้อมูล
- การทำนายผลลัพธ์
- การประมาณค่าตัวเลข
- การวิเคราะห์ข้อมูลเชิงตาราง

ในทางปฏิบัติ FNN อาจมีจำนวน Hidden Layer และจำนวน Neuron ที่แตกต่างกันตามความซับซ้อนของปัญหา โครงข่ายที่มีจำนวนชั้นซ่อนหลายชั้นอาจเรียกว่า Multi-Layer Perceptron หรือ MLP ซึ่งเป็นรูปแบบหนึ่งของ Feedforward Neural Network

สำหรับเนื้อหาในบทนี้ FNN ถือเป็นรูปแบบหลักที่ใช้ในการอธิบายแนวคิดพื้นฐานของโครงข่ายประสาทเทียม และสามารถนำแนวคิดเกี่ยวกับ Artificial Neuron, Weight, Bias, Activation Function และ Hidden Layer มาประยุกต์ใช้ร่วมกันได้

8.5.2. Recurrent Neural Network


Recurrent Neural Network หรือ RNN เป็นโครงข่ายประสาทเทียมที่ออกแบบมาเพื่อจัดการกับ **ข้อมูลที่มีลำดับ (Sequential Data)** ซึ่งข้อมูลในแต่ละตำแหน่งอาจมีความสัมพันธ์กับข้อมูลที่อยู่ก่อนหน้า หรือภายหลัง

ตัวอย่างข้อมูลที่มีลำดับ ได้แก่

- ข้อความและประโยค
- สัญญาณเสียง
- ข้อมูลตามเวลา
- ลำดับเหตุการณ์

ตัวอย่างเช่น ในประโยคหนึ่ง ความหมายของคำอาจขึ้นอยู่กับคำที่ปรากฏก่อนหน้า การประมวลผลคำแต่ละคำโดยพิจารณาแยกจากกันเพียงอย่างเดียวอาจไม่สามารถสะท้อนความสัมพันธ์ของข้อมูลทั้งหมดได้

แนวคิดสำคัญของ RNN คือการมีการเชื่อมโยงที่ทำให้ผลจากการประมวลผลในขั้นก่อนหน้าสามารถนำมาใช้ร่วมกับข้อมูลในขั้นปัจจุบันได้ ดังแสดงในรูปที่ 16



รูปที่ 16 แนวคิดพื้นฐานของ Recurrent Neural Network ซึ่งใช้ข้อมูลจากขั้นก่อนหน้าร่วมกับข้อมูลในขั้นปัจจุบันในการประมวลผลข้อมูลแบบลำดับ

กล่าวโดยง่าย RNN สามารถมองได้ว่าเป็นโครงข่ายที่มีแนวคิดเกี่ยวกับ สถานะ (State) ซึ่งช่วยให้ข้อมูลบางส่วนจากการประมวลผลก่อนหน้าถูกนำมาใช้ในการประมวลผลครั้งต่อไป

ตัวอย่างการประยุกต์ใช้ RNN ได้แก่

- การวิเคราะห์ข้อความ
- การรู้จำเสียง

- การพยากรณ์ข้อมูลตามเวลา
- การประมวลผลลำดับของเหตุการณ์

อย่างไรก็ตาม RNN แบบพื้นฐานอาจมีข้อจำกัดในการเรียนรู้ความสัมพันธ์ของข้อมูลที่อยู่ห่างกันมาก จึงมีการพัฒนาโครงสร้างอื่น เช่น Long Short-Term Memory (LSTM) และ Gated Recurrent Unit (GRU) เพื่อช่วยให้แบบจำลองสามารถจัดการกับความสัมพันธ์ในลำดับข้อมูลได้ดีขึ้น


ในระดับพื้นฐาน นักศึกษาควรเข้าใจว่า RNN เป็นโครงข่ายที่เหมาะสมสำหรับข้อมูลที่มีลำดับ และมีความแตกต่างจาก FNN ตรงที่ข้อมูลหรือสถานะจากขั้นก่อนหน้าสามารถมีอิทธิพลต่อการประมวลผลในขั้นถัดไป

8.5.3. Convolutional Neural Network


Convolutional Neural Network หรือ CNN เป็นโครงข่ายประสาทเทียมที่ได้รับการออกแบบมาเพื่อจัดการกับข้อมูลที่มี โครงสร้างเชิงพื้นที่ (Spatial Structure) โดยเฉพาะข้อมูลประเภทภาพ

ภาพดิจิทัลสามารถมองเป็นข้อมูลที่ประกอบด้วยค่าของพิกเซลที่เรียงตัวตามตำแหน่ง ความสัมพันธ์ระหว่างพิกเซลที่อยู่ใกล้กันจึงมีความสำคัญ ตัวอย่างเช่น กลุ่มของพิกเซลที่อยู่ติดกันอาจแสดงถึงขอบ เส้น หรือส่วนหนึ่งของวัตถุ

แทนที่จะเชื่อมต่อนิวรอนทุกหน่วยเข้ากับข้อมูลทุกตำแหน่งเหมือน Fully Connected Network CNN ใช้ตัวกรอง หรือ **Filter** เพื่อค้นหารูปแบบเฉพาะจากข้อมูล โดย Filter จะทำงานกับข้อมูลในบริเวณขนาดเล็กและเคลื่อนผ่านตำแหน่งต่าง ๆ ของข้อมูล ดังแสดงในรูปที่ 18



The convolutional layer



รูปที่ 18 แนวคิดพื้นฐานของ Convolutional Neural Network ซึ่งใช้ Filter ตรวจสอบรูปแบบจากข้อมูลที่มีโครงสร้างเชิงพื้นที่

ในกรณีของข้อมูลภาพ CNN สามารถเรียนรู้ลักษณะของข้อมูลเป็นลำดับขั้นได้ ตัวอย่างเช่น ขั้นตอนของโครงข่ายอาจเรียนรู้ลักษณะพื้นฐาน เช่น เส้นหรือขอบ ในขณะที่ชั้นที่ลึกขึ้นสามารถเรียนรู้ลักษณะที่มีความซับซ้อนมากขึ้น เช่น รูปร่างหรือส่วนประกอบของวัตถุ

ตัวอย่างการประยุกต์ใช้ CNN ได้แก่

- การจำแนกภาพ
- การตรวจจับวัตถุ
- การรู้จำใบหน้า
- การวิเคราะห์ภาพทางการแพทย์
- การตรวจสอบคุณภาพของผลิตภัณฑ์จากภาพ

CNN เป็นตัวอย่างสำคัญของการออกแบบโครงข่ายประสาทเทียมให้เหมาะสมกับลักษณะของข้อมูล และจะกล่าวถึงรายละเอียดเพิ่มเติมเกี่ยวกับแนวคิดของ Convolution, Filter, Feature Map และการประยุกต์ใช้งานในบทที่ 9

8.5.4. การเลือกใช้โครงข่ายตามลักษณะข้อมูล

โครงข่ายประสาทเทียมแต่ละประเภทไม่ได้เหมาะสมกับข้อมูลทุกประเภท การเลือกใช้โครงข่ายจึงควรเริ่มต้นจากการพิจารณาว่า ข้อมูลมีลักษณะอย่างไร และ ต้องการแก้ปัญหาประเภทใด

หากข้อมูลสามารถแทนเป็นชุดคุณลักษณะหรือตัวแปร เช่น อายุ รายได้ คะแนน หรือค่าที่ได้จากเซนเซอร์ในช่วงเวลาหนึ่ง FNN อาจเป็นจุดเริ่มต้นที่เหมาะสม เนื่องจากสามารถรับข้อมูลในรูปแบบตัวเลขและเรียนรู้ความสัมพันธ์ระหว่างคุณลักษณะต่าง ๆ ได้

หากข้อมูลมีลำดับและความสัมพันธ์ระหว่างตำแหน่งของข้อมูลมีความสำคัญ เช่น คำในประโยค ลำดับของเสียง หรือข้อมูลตามเวลา RNN หรือโครงข่ายที่พัฒนาต่อยอดจาก RNN อาจเหมาะสมกว่า

ในกรณีของข้อมูลภาพหรือข้อมูลที่มีความสัมพันธ์ระหว่างตำแหน่งมีความสำคัญ CNN เป็นโครงข่ายที่ได้รับการออกแบบมาโดยเฉพาะเพื่อเรียนรู้รูปแบบเชิงพื้นที่จากข้อมูล

ตารางที่ 8.3 แสดงการเปรียบเทียบลักษณะพื้นฐานของโครงข่ายทั้งสามประเภท

ประเภท	ลักษณะของข้อมูล	แนวคิดสำคัญ	ตัวอย่างการประยุกต์ใช้
Feedforward Neural Network (FNN)	ข้อมูลตัวเลขหรือข้อมูลเชิงตาราง	ข้อมูลเคลื่อนที่ไปข้างหน้าผ่านแต่ละชั้น	การจำแนกและการทำนาย
Recurrent Neural Network (RNN)	ข้อมูลแบบลำดับ	ใช้ข้อมูลหรือสถานะจากชั้นก่อนหน้า	ข้อความ เสียง และข้อมูลตามเวลา
Convolutional Neural Network (CNN)	ข้อมูลที่มีโครงสร้างเชิงพื้นที่	ใช้ Filter เพื่อค้นหารูปแบบเฉพาะ	การจำแนกภาพและการตรวจจบบั้วตุ

จากตารางที่ 8.3 จะเห็นได้ว่า แม้โครงข่ายทั้งสามประเภทจะมีพื้นฐานมาจากแนวคิดของ Artificial Neuron เหมือนกัน แต่รูปแบบของการเชื่อมต่อและการประมวลผลถูกออกแบบให้เหมาะสมกับข้อมูลที่แตกต่างกัน

ดังนั้น ก่อนเลือกใช้โครงข่ายประสาทเทียม ผู้พัฒนาควรพิจารณาลักษณะของข้อมูลเป็นสำคัญ ไม่ควรเลือกแบบจำลองจากความซับซ้อนหรือความนิยมของเทคนิคเพียงอย่างเดียว แบบจำลองที่มีโครงสร้างเหมาะสมกับข้อมูลและปัญหามักเป็นจุดเริ่มต้นที่ดีกว่าแบบจำลองที่มีความซับซ้อนสูงแต่ไม่เหมาะสมกับลักษณะของข้อมูล

เนื้อหาในบทนี้ได้อธิบายพื้นฐานของโครงข่ายประสาทเทียม ตั้งแต่แนวคิดของ Artificial Neuron, Weight, Bias, Activation Function, Perceptron และ Multi-Layer Neural Network ก่อนขยายมาสู่ภาพรวมของ FNN, RNN และ CNN

ในบทถัดไป จะนำแนวคิดพื้นฐานของ Neural Network มาต่อยอด โดยศึกษารายละเอียดของ Convolutional Neural Network สำหรับการวิเคราะห์ข้อมูลภาพ และแนวคิดของ Generative AI ซึ่งเป็นเทคโนโลยีปัญญาประดิษฐ์ที่สามารถสร้างเนื้อหาใหม่ เช่น ข้อความ ภาพ เสียง และข้อมูลรูปแบบอื่นได้

แบบฝึกหัดท้ายบทที่ 8Error! Reference source not found.

1. จงอธิบายความหมายของโครงข่ายประสาทเทียม (Artificial Neural Networks)

2. จงอธิบายหน้าที่ขององค์ประกอบต่อไปนี้

Input

Weight

Bias

Output

3. จงอธิบายความแตกต่างระหว่าง Input Layer, Hidden Layer และ Output Layer

4. เพราะเหตุใดจึงต้องใช้ ฟังก์ชันกระตุ้น (Activation Function) ในโครงข่ายประสาทเทียม

5. จงเปรียบเทียบฟังก์ชัน Sigmoid, Tanh และ ReLU พร้อมยกตัวอย่างการใช้งาน

6. จงอธิบายกระบวนการฝึกสอนโครงข่ายประสาทเทียม โดยกล่าวถึง

Forward Propagation

Loss Function

Backpropagation

Gradient Descent

7. Single Layer Perceptron และ Multi Layer Perceptron แตกต่างกันอย่างไร

8. จงอธิบายลักษณะและการประยุกต์ใช้งานของ

Feedforward Neural Networks (FNN)

Convolutional Neural Networks (CNN)

Recurrent Neural Networks (RNN)

9. เพราะเหตุใด CNN จึงได้รับความนิยมในงานประมวลผลภาพ

10. จงยกตัวอย่างการประยุกต์ใช้งานโครงข่ายประสาทเทียมในชีวิตประจำวันอย่างน้อย 5 ตัวอย่าง

11. จงอธิบายข้อดีและข้อจำกัดของโครงข่ายประสาทเทียม