

บทที่ 9

ปัญญาประดิษฐ์สมัยใหม่

จากเนื้อหาในบทก่อนหน้า อธิบายถึงพื้นฐานของโครงข่ายประสาทเทียม (Neural Network) ตั้งแต่แนวคิดของเซลล์ประสาทเทียม การกำหนดน้ำหนัก (Weight) และไบแอส (Bias) การใช้ฟังก์ชันกระตุ้น (Activation Function) ไปจนถึงการทำงานของโครงข่ายหลายชั้น (Multi-Layer Neural Network) ความรู้เหล่านี้เป็นพื้นฐานสำคัญของการพัฒนาปัญญาประดิษฐ์สมัยใหม่ โดยเฉพาะในกลุ่มเทคนิคที่เรียกว่า การเรียนรู้เชิงลึก (Deep Learning)

เมื่อรูปแบบของข้อมูลมีความซับซ้อนมากขึ้น การใช้โครงข่ายแบบเชื่อมต่อเต็มรูปแบบ (Fully Connected Network) เพียงอย่างเดียวอาจไม่เหมาะสมกับข้อมูลทุกประเภท ตัวอย่างเช่น ข้อมูลภาพมีความสัมพันธ์เชิงตำแหน่งระหว่างจุดภาพ ข้อมูลภาษาเกี่ยวข้องกับลำดับและความสัมพันธ์ของคำ และข้อมูลในรูปแบบอื่นอาจมีลักษณะเฉพาะที่แตกต่างกัน ดังนั้นจึงมีการพัฒนาโครงสร้างของ Neural Network ให้เหมาะสมกับลักษณะของข้อมูลและงานที่ต้องการแก้ปัญหา

ในบทนี้จะเริ่มต้นจากโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) ซึ่งเป็นตัวอย่างสำคัญของการออกแบบ Neural Network สำหรับข้อมูลภาพ จากนั้นจะศึกษาภาพรวมของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ซึ่งเป็นแนวทางของปัญญาประดิษฐ์ที่ไม่ได้มีหน้าที่เพียงวิเคราะห์ จำแนก หรือทำนายข้อมูลเท่านั้น แต่ยังสามารถเรียนรู้รูปแบบจากข้อมูลและนำไปสู่การสร้างเนื้อหาใหม่ได้

9.1 แนวคิดพื้นฐานของโครงข่ายประสาทเทียมแบบคอนโวลูชัน

โครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) เป็นรูปแบบหนึ่งของ Neural Network ที่ได้รับการออกแบบให้เหมาะสมกับข้อมูลที่มีโครงสร้างเชิงพื้นที่ (Spatial Structure) โดยเฉพาะข้อมูลภาพ เช่น ภาพถ่าย ภาพจากกล้องวงจรปิด ภาพเอกซเรย์ หรือภาพจากกล้องในระบบอุตสาหกรรม

จากบทที่ 8 โครงข่ายประสาทเทียมแบบทั่วไปสามารถประกอบด้วยชั้นข้อมูลนำเข้า (Input Layer) ชั้นซ่อน (Hidden Layer) และชั้นผลลัพธ์ (Output Layer) โดยในโครงข่ายแบบเชื่อมต่อเต็มรูปแบบ แต่ละหน่วยประมวลผลในชั้นหนึ่งสามารถเชื่อมต่อกับหน่วยประมวลผลจำนวนมากในชั้นถัดไป รูปแบบดังกล่าวเหมาะสมสำหรับข้อมูลที่สามารถแสดงเป็นชุดของตัวแปรได้ เช่น


- อายุ รายได้ และจำนวนปีการทำงาน
- คะแนนสอบในแต่ละรายวิชา
- ข้อมูลจากเซนเซอร์
- คุณลักษณะที่ผ่านการเตรียมข้อมูลมาแล้ว

อย่างไรก็ตาม ข้อมูลภาพมีลักษณะแตกต่างจากข้อมูลทั่วไป เนื่องจากภาพไม่ได้เป็นเพียงรายการของตัวเลขที่แยกออกจากกัน แต่ค่าของแต่ละจุดภาพหรือพิกเซล (Pixel) มีความสัมพันธ์กับตำแหน่งของพิกเซลรอบข้าง ตัวอย่างเช่น หากต้องการตรวจสอบว่าภาพมีเส้นขอบของวัตถุอยู่หรือไม่ การพิจารณาค่าของพิกเซลเพียงจุดเดียวยังไม่เพียงพอ แต่จำเป็นต้องพิจารณาความสัมพันธ์ระหว่างพิกเซลที่อยู่ใกล้กัน

แนวคิดนี้เป็นจุดสำคัญที่ทำให้ CNN แตกต่างจาก Fully Connected Network

9.1.1. ความแตกต่างระหว่าง Fully Connected Network และ CNN

สมมติว่ามีภาพขนาด 28×28 พิกเซล หากเป็นภาพขาวดำ ภาพหนึ่งภาพสามารถแทนด้วยค่าจำนวน 784 ค่า หากนำข้อมูลดังกล่าวเข้าสู่ Fully Connected Network โดยตรง อาจทำการเรียงค่าพิกเซลทั้งหมดเป็นข้อมูลหนึ่งมิติ ดังแสดงในรูปที่ 9.1



รูปที่ 9.1 การแปลงข้อมูลภาพเป็นชุดข้อมูลหนึ่งมิติเพื่อนำเข้าสู่ Fully Connected Network

เมื่อภาพถูกแปลงเป็นรายการของตัวเลข ความสัมพันธ์เชิงตำแหน่งระหว่างพิกเซลอาจไม่ถูกนำมาใช้โดยตรง ตัวอย่างเช่น พิกเซลสองจุดที่อยู่ติดกันในภาพอาจกลายเป็นเพียงข้อมูลสองค่าที่อยู่ในรายการจำนวนมาก CNN จึงได้รับการออกแบบให้สามารถประมวลผลข้อมูลในลักษณะที่ยังคงโครงสร้างเชิงพื้นที่ของภาพไว้

ใน Fully Connected Network การเชื่อมต่อระหว่างหน่วยประมวลผลอาจมีจำนวนมาก เนื่องจากข้อมูลจากหน่วยจำนวนมากในชั้นก่อนหน้าสามารถเชื่อมต่อไปยังหน่วยในชั้นถัดไปได้ ส่งผลให้จำนวน Weight เพิ่มขึ้นอย่างรวดเร็วเมื่อขนาดของข้อมูลภาพมีขนาดใหญ่

ในทางตรงกันข้าม CNN ใช้แนวคิดของการตรวจสอบข้อมูลเฉพาะบริเวณ (Local Region) แทนที่จะเชื่อมต่อกับข้อมูลภาพทั้งหมดในครั้งเดียว โดยใช้ตัวตรวจจบบรูปแบบขนาดเล็กที่เรียกว่า ตัวกรอง (Filter) หรือ เคอร์เนล (Kernel) เลื่อนผ่านตำแหน่งต่าง ๆ ของภาพ เพื่อค้นหาารูปแบบที่สนใจ

ตัวอย่างเช่น Filter หนึ่งตัวอาจเรียนรู้ที่จะตอบสนองต่อรูปแบบของ

- เส้นแนวนอน
- เส้นแนวตั้ง
- เส้นทแยงมุม
- ขอบของวัตถุ
- ลวดลายหรือพื้นผิวบางประเภท

ในระหว่างการเรียนรู้ ค่า Weight ภายใน Filter จะถูกปรับจากข้อมูลตัวอย่าง คล้ายกับแนวคิดการเรียนรู้ของ Neural Network ที่ศึกษาในบทก่อนหน้า ความแตกต่างคือ CNN จัดโครงสร้างการเชื่อมต่อและการใช้ Weight ให้เหมาะกับข้อมูลที่มีลักษณะเชิงพื้นที่


9.1.2. โครงสร้างเชิงพื้นที่ของข้อมูลภาพ

ภาพดิจิทัลสามารถมองเป็นข้อมูลที่จัดเรียงตามตำแหน่ง ในภาพขาวดำ ค่าของแต่ละ Pixel อาจแสดงระดับความสว่าง ส่วนภาพสีมักประกอบด้วยหลายช่องสี เช่น แดง เขียว และน้ำเงิน

สิ่งสำคัญคือ ตำแหน่งของ Pixel มีความหมายต่อการตีความภาพ หากมีการสลับตำแหน่งของ Pixel อย่างไม่เป็นระบบ แม้ว่าค่าตัวเลขทั้งหมดจะยังคงมีอยู่ครบ แต่ภาพที่ได้ อาจไม่สามารถสื่อความหมายเดิมได้


ตัวอย่างเช่น ภาพตัวเลขเขียนด้วยมือมีโครงสร้างของเส้นและรูปทรงที่เกิดจาก Pixel ซึ่งอยู่ติดกัน การจดจำตัวเลขจึงไม่ได้พิจารณาเพียงว่าภาพมี Pixel สีเข้มจำนวนเท่าใด แต่ยังพิจารณาว่า Pixel เหล่านั้นจัดเรียงกันเป็นรูปแบบใด

1 ภาพที่มีโครงสร้างเชิงพื้นที่ (Spatial Structure)



2 การเรียงค่าพิกเซลเป็นข้อมูลหนึ่งมิติ (1D Flattened)

นำค่าพิกเซลมาเรียงต่อกันเป็นลำดับ



รูปที่ 9.2 ความสัมพันธ์เชิงตำแหน่งของพิกเซลเป็นข้อมูลสำคัญในการวิเคราะห์ภาพ

จากรูปที่ 9.2 จะเห็นได้ว่า การจัดเรียงตำแหน่งของข้อมูลมีความสำคัญต่อความหมายของภาพ CNN จึงประมวลผลข้อมูลโดยพิจารณาบริเวณต่าง ๆ ของภาพและค้นหารูปแบบจากความสัมพันธ์ของข้อมูลในบริเวณนั้น

แนวคิดนี้ไม่ได้จำกัดเฉพาะภาพเท่านั้น แต่สามารถประยุกต์ใช้กับข้อมูลอื่นที่มีโครงสร้างเชิงตำแหน่ง หรือความสัมพันธ์ในพื้นที่ได้ อย่างไรก็ตาม ในระดับพื้นฐาน CNN มักถูกนำมาใช้เพื่ออธิบายการประมวลผล และการวิเคราะห์ข้อมูลภาพ

9.1.3. แนวคิดของ Filter หรือ Kernel

องค์ประกอบสำคัญของ CNN คือ Filter หรือ Kernel ซึ่งสามารถมองได้ว่าเป็นชุดของ Weight ขนาดเล็กที่ใช้ตรวจสอบรูปแบบภายในบริเวณหนึ่งของภาพ

ตัวอย่างเช่น สมมติว่า Filter มีขนาด 3×3 ซึ่งหมายความว่าในแต่ละครั้ง Filter จะพิจารณาข้อมูลจากบริเวณขนาด 3×3 Pixel จากนั้น Filter จะเลื่อนไปยังตำแหน่งอื่นของภาพและทำกระบวนการในลักษณะเดียวกัน

แนวคิดพื้นฐานสามารถแสดงได้ดังรูปที่ 3 ในแต่ละตำแหน่ง CNN จะนำค่าของ Pixel ในบริเวณที่ Filter ครอบคลุมมาคำนวณร่วมกับ Weight ภายใน Filter ผลลัพธ์ที่ได้จะแสดงระดับการตอบสนองต่อรูปแบบบางอย่าง

ในระดับแนวคิด กระบวนการดังกล่าวสามารถเขียนได้เป็น



$$y = f(x_1w_1 + x_2w_2 + \dots + x_nw_n + b) \quad (1)$$

โดยที่

- $x_1, x_2, \dots, x_n$ คือค่าของข้อมูลจากบริเวณที่กำลังพิจารณา
- $w_1, w_2, \dots, w_n$ คือค่า Weight ของ Filter
- b คือค่า Bias
- f คือ Activation Function
- y คือผลลัพธ์ที่ได้จากการตรวจสอบบริเวณนั้น

สมการที่ 1 มีแนวคิดพื้นฐานเช่นเดียวกับ Artificial Neuron ที่ศึกษาในบทที่ 8 กล่าวคือ ข้อมูลนำเข้าจะถูกนำมาคำนวณร่วมกับ Weight และ Bias ก่อนผ่าน Activation Function แต่ใน CNN การประมวลผลดังกล่าวจะถูกนำมาใช้กับบริเวณย่อยของข้อมูลภาพ และมีการใช้ Weight ชุดเดียวกันตรวจสอบหลายตำแหน่งของภาพดังรูปที่ 9.3

แนวคิดของการใช้ Weight ชุดเดียวกันกับหลายตำแหน่งนี้เรียกว่า การใช้พารามิเตอร์ร่วมกัน (Parameter Sharing) ซึ่งเป็นเหตุผลสำคัญที่ทำให้ CNN สามารถตรวจหารูปแบบเดียวกันในตำแหน่งต่าง ๆ ของภาพได้ โดยไม่จำเป็นต้องสร้างชุด Weight ใหม่สำหรับทุกตำแหน่ง




รูปที่ 9.3 การใช้ Filter ตรวจสอบข้อมูลภาพในแต่ละบริเวณ

9.1.4. การค้นหารูปแบบจากภาพ

ในช่วงเริ่มต้นของการเรียนรู้ Filter ภายใน CNN อาจยังไม่มีความสามารถในการตรวจจับรูปแบบที่มีความหมายชัดเจน แต่เมื่อโมเดลได้รับข้อมูลตัวอย่างจำนวนมากและมีการปรับค่า Weight ตามกระบวนการเรียนรู้ Filter แต่ละตัวจะค่อย ๆ เรียนรู้รูปแบบที่เป็นประโยชน์ต่อการแก้ปัญหา

ตัวอย่างเช่น หาก CNN ถูกนำมาใช้จำแนกภาพสัตว์ ในขั้นแรก ๆ ของโครงข่ายอาจเรียนรู้ลักษณะพื้นฐาน เช่น เส้น ขอบ มุม และการเปลี่ยนแปลงของสีหรือความสว่าง เป็นต้น เมื่อข้อมูลถูกส่งผ่านไปยังขั้นที่ลึกขึ้น รูปแบบที่เรียนรู้สามารถมีความซับซ้อนมากขึ้น เช่น รูปร่างของส่วนประกอบ ลักษณะของดวงตารูปทรงของหู และ พื้นผิวของขน เป็นต้น และในขั้นที่ลึกมากขึ้น โครงข่ายอาจรวมคุณลักษณะเหล่านี้เพื่อใช้ในการตัดสินใจเกี่ยวกับวัตถุหรือประเภทของภาพ



รูปที่ 9.4 การเรียนรู้คุณลักษณะของ CNN จากเส้นและขอบไปสู่รูปแบบที่ซับซ้อนขึ้น

จากรูปที่ 9.4 จะเห็นว่า CNN ไม่ได้เริ่มต้นจากการกำหนดด้วยมนุษย์ว่าระบบต้องตรวจสอบเส้น รูปร่าง หรือส่วนประกอบใดของภาพโดยละเอียด แต่ระบบสามารถเรียนรู้คุณลักษณะที่เหมาะสมจากข้อมูลตัวอย่างผ่านกระบวนการฝึกสอน

แนวคิดนี้เรียกว่า การสกัดคุณลักษณะโดยอัตโนมัติ (Automatic Feature Extraction) ซึ่งเป็นข้อได้เปรียบสำคัญของ Deep Learning เมื่อเปรียบเทียบกับแนวทางที่ต้องออกแบบคุณลักษณะของข้อมูลด้วยมนุษย์เป็นจำนวนมาก

9.1.5. เหตุผลที่ CNN เหมาะสำหรับข้อมูลภาพ

CNN มีความเหมาะสมกับข้อมูลภาพเนื่องจากสามารถใช้ประโยชน์จากคุณสมบัติสำคัญหลายประการของภาพ ได้แก่

ประการแรก CNN สามารถพิจารณาความสัมพันธ์ของข้อมูลในบริเวณใกล้เคียงกันได้ Pixel ที่อยู่ติดกันมักมีความสัมพันธ์กัน และความสัมพันธ์ดังกล่าวสามารถใช้เพื่อค้นหารูปแบบ เช่น เส้น ขอบ และรูปร่าง

ประการที่สอง CNN ใช้ Filter เดียวกันตรวจสอบหลายตำแหน่งของภาพ ทำให้สามารถค้นหารูปแบบเดียวกันได้แม้ว่ารูปแบบนั้นจะปรากฏอยู่คนละตำแหน่ง ตัวอย่างเช่น หากระบบเรียนรู้ลักษณะของดวงตา ระบบสามารถค้นหารูปแบบดังกล่าวได้ในบริเวณต่าง ๆ ของภาพ

ประการที่สาม CNN สามารถเรียนรู้คุณลักษณะเป็นลำดับชั้น จากลักษณะพื้นฐานไปสู่ลักษณะที่มีความซับซ้อนมากขึ้น ส่งผลให้สามารถนำไปใช้กับงานด้าน Computer Vision ที่ต้องวิเคราะห์ข้อมูลภาพในหลายระดับ

อย่างไรก็ตาม CNN ไม่ได้หมายความว่าระบบจะเข้าใจภาพในลักษณะเดียวกับมนุษย์ แต่เป็นกระบวนการเรียนรู้รูปแบบทางคณิตศาสตร์และความสัมพันธ์ของข้อมูล que ช่วยให้โมเดลสามารถนำข้อมูลภาพไปใช้ในการจำแนก ตระจจับ หรือวิเคราะห์ตามวัตถุประสงค์ที่กำหนด

โดยสรุป CNN เป็นการต่อยอดแนวคิดของ Neural Network ที่นักศึกษาได้เรียนในบทที่ 8 โดยยังคงใช้หลักการพื้นฐาน เช่น Weight, Bias, Activation Function และการส่งผ่านข้อมูลไปข้างหน้า (Forward Propagation) แต่มีการออกแบบโครงสร้างให้สามารถเรียนรู้จากข้อมูลที่มีความสัมพันธ์เชิงพื้นที่ได้อย่างมีประสิทธิภาพมากขึ้น

ในหัวข้อถัดไปจะศึกษาส่วนประกอบพื้นฐานของ CNN เพื่อทำความเข้าใจว่าข้อมูลภาพถูกส่งผ่านส่วนต่าง ๆ ของโครงข่ายอย่างไร ตั้งแต่ภาพนำเข้า การใช้ Filter การสร้าง Feature Map การใช้ Activation Function และการลดขนาดข้อมูลด้วย Pooling จนถึงการนำคุณลักษณะที่เรียนรู้ไปใช้ในการจำแนกผลลัพธ์.

9.2 องค์ประกอบพื้นฐานของ โครงข่ายประสาทเทียมแบบคอนโวลูชัน

จากหัวข้อที่ผ่านมา CNN ได้รับการออกแบบให้สามารถเรียนรู้รูปแบบจากข้อมูลที่มีโครงสร้างเชิงพื้นที่ โดยเฉพาะข้อมูลภาพ แทนที่จะนำค่าของ Pixel ทั้งหมดมาเชื่อมต่อกับหน่วยประมวลผลทุกหน่วยโดยตรง CNN จะแบ่งกระบวนการทำงานออกเป็นหลายส่วน เพื่อค่อย ๆ สกัดคุณลักษณะของภาพและนำคุณลักษณะที่ได้ไปใช้ในการตัดสินใจ

แม้ว่าสถาปัตยกรรมของ CNN ในงานจริงอาจมีความซับซ้อนและมีจำนวนชั้นแตกต่างกัน แต่ CNN พื้นฐานสามารถอธิบายองค์ประกอบหลักได้ดังนี้

Input Image

→ Convolution Layer

→ Activation Function

→ Pooling Layer

→ Feature Extraction

→ Fully Connected Layer

→ Output Layer

องค์ประกอบเหล่านี้ทำงานร่วมกันเพื่อเปลี่ยนข้อมูลภาพจากค่าของ Pixel ไปเป็นข้อมูลที่มีความหมายต่อการจำแนกหรือการวิเคราะห์ภาพ จะเห็นว่า CNN ไม่ได้พยายามตัดสินใจผลลัพธ์จากค่าของ Pixel

โดยตรงตั้งแต่เริ่มต้น แต่จะผ่านกระบวนการสกัดคุณลักษณะหลายขั้นตอน เพื่อค้นหารูปแบบที่เป็นประโยชน์ ก่อนนำข้อมูลไปสู่ขั้นตอนการจำแนกหรือการตัดสินใจ

9.2.1. Input Image

ข้อมูลนำเข้า (Input Image) คือภาพที่ต้องการนำเข้าสู่ CNN เพื่อทำการวิเคราะห์ ตัวอย่างเช่น

- ภาพตัวเลขที่เขียนด้วยมือ
- ภาพแมวและสุนัข
- ภาพใบหน้า
- ภาพชิ้นส่วนจากสายการผลิต
- ภาพทางการแพทย์ เช่น ภาพเอกซเรย์หรือภาพจากการตรวจทางการแพทย์

ในมุมมองของคอมพิวเตอร์ ภาพประกอบด้วยจุดภาพหรือ Pixel แต่ละ Pixel จะถูกแทนด้วยค่าตัวเลข

สำหรับภาพขาวดำ ค่า Pixel อาจใช้แทนระดับความสว่าง เช่น ค่าใกล้ 0 อาจหมายถึงสีดำ และค่าที่สูงขึ้นอาจหมายถึงสีขาวหรือสีที่มีความสว่างมากกว่า ขึ้นอยู่กับรูปแบบการแทนข้อมูลที่ใช้


สำหรับภาพสี โดยทั่วไปภาพหนึ่งภาพสามารถประกอบด้วยหลายช่องข้อมูล เช่น Red Green Blue เป็นต้น ดังนั้น ภาพสีจึงสามารถมองเป็นข้อมูลหลายชั้นที่ซ้อนกันอยู่ โดยแต่ละชั้นเก็บค่าของสีในแต่ละตำแหน่ง ตัวอย่างเช่น หากภาพมีขนาด 32×32 Pixel และมี 3 ช่องสี ข้อมูลภาพสามารถมองเป็นขนาด $32 \times 32 \times 3$ โดยสองมิติแรกแสดงตำแหน่งของ Pixel ในแนวกว้างและแนวสูง ส่วนมิติสุดท้ายแสดงจำนวนช่องสี สิ่งสำคัญคือ CNN จะรักษาโครงสร้างของข้อมูลภาพไว้ในลักษณะเชิงพื้นที่ ทำให้สามารถพิจารณาความสัมพันธ์ระหว่าง Pixel ที่อยู่ใกล้กันได้ ต่างจากการแปลงข้อมูลภาพทั้งหมดให้เป็นรายการหนึ่งมิติตั้งแต่เริ่มต้น

ก่อนนำภาพเข้าสู่ CNN ในการใช้งานจริงอาจมีการเตรียมข้อมูล เช่น การปรับขนาดภาพให้มีขนาดเท่ากัน หรือการปรับช่วงค่าของ Pixel ให้เหมาะสมกับการประมวลผล อย่างไรก็ตาม แนวคิดสำคัญในระดับพื้นฐานคือ ภาพจะถูกส่งเข้าสู่ CNN ในรูปแบบที่ยังคงข้อมูลเกี่ยวกับตำแหน่งและโครงสร้างของภาพไว้

9.2.2. Convolution Layer

ชั้นคอนโวลูชัน (Convolution Layer) เป็นองค์ประกอบสำคัญที่ทำให้ CNN มีความแตกต่างจาก Neural Network แบบ Fully Connected Layer โดยหน้าที่หลักของชั้นนี้คือการตรวจสอบข้อมูลในแต่ละบริเวณของภาพเพื่อค้นหารูปแบบหรือคุณลักษณะ

Convolution Layer ใช้ Filter หรือ Kernel ขนาดเล็กเลื่อนผ่านข้อมูลภาพ ในแต่ละตำแหน่ง Filter จะนำค่าของ Pixel ในบริเวณนั้นมาคำนวณร่วมกับ Weight ที่อยู่ภายใน Filter หาก Filter มีขนาด 3×3 ก็จะพิจารณาข้อมูลที่ละบริเวณขนาด 3×3 Pixel ดังแสดงในรูปที่ 9.5



รูปที่ 9.5 Filter ตรวจสอบข้อมูลในแต่ละบริเวณของภาพเพื่อสร้างผลลัพธ์ใหม่

ผลลัพธ์จากการคำนวณในแต่ละตำแหน่งสามารถอธิบายตามแนวคิดของสมการที่ 1 คือ การนำข้อมูลจากบริเวณหนึ่งมาคำนวณร่วมกับ Weight และ Bias จากนั้นส่งผลลัพธ์ผ่าน Activation Function ตามโครงสร้างของโครงข่าย

สิ่งสำคัญคือ CNN ไม่ได้มี Filter เพียงตัวเดียว ใน Convolution Layer หนึ่งชั้นอาจประกอบด้วย Filter หลายตัว โดยแต่ละ Filter สามารถเรียนรู้รูปแบบที่แตกต่างกัน

ตัวอย่างเช่น Filter หนึ่งอาจตอบสนองต่อเส้นแนวตั้ง ขณะที่อีก Filter อาจตอบสนองต่อเส้นแนวนอน หรือรูปแบบของพื้นผิวบางประเภท

ดังนั้น เมื่อภาพหนึ่งภาพผ่าน Convolution Layer ระบบจึงสามารถสร้างข้อมูลคุณลักษณะหลายชุด ซึ่งแสดงรูปแบบที่ Filter แต่ละตัวตรวจพบ

ค่า Weight ภายใน Filter ไม่ได้ถูกกำหนดขึ้นด้วยมนุษย์โดยตรง แต่เป็นค่าที่ CNN เรียนรู้จากข้อมูลฝึกสอน ผ่านกระบวนการเรียนรู้ของ Neural Network ดังนั้น หาก CNN ได้รับการฝึกด้วยข้อมูลที่เหมาะสม Filter ภายในโครงข่ายจะค่อย ๆ ปรับตัวเพื่อค้นหารูปแบบที่มีประโยชน์ต่อการแก้ปัญหา

9.2.3. Filter หรือ Kernel


ตัวกรอง (Filter) หรือเคอร์เนล (Kernel) เป็นชุดของ Weight ที่ใช้สำหรับตรวจสอบรูปแบบในบริเวณหนึ่งของข้อมูลภาพ ในเอกสารหรือแหล่งอ้างอิงต่าง ๆ อาจพบการใช้คำว่า Filter และ Kernel ในความหมายที่ใกล้เคียงกัน โดยในระดับพื้นฐานสามารถเข้าใจได้ว่าเป็นชุดของค่าที่ใช้เลื่อนผ่านข้อมูลเพื่อค้นหารูปแบบ

ตัวอย่างเช่น Filter ขนาด 3×3 สามารถเขียนในเชิงแนวคิดได้ดังนี้

$$\begin{matrix} w_1 & w_2 & w_3 \\ w_4 & w_5 & w_6 \\ w_7 & w_8 & w_9 \end{matrix}$$

เมื่อ Filter ถูกวางบนบริเวณหนึ่งของภาพ ค่าของ Pixel และค่า Weight ในตำแหน่งที่สอดคล้องกัน จะถูกนำมาคำนวณร่วมกัน จากนั้นจึงได้ผลลัพธ์สำหรับตำแหน่งนั้น

แนวคิดสำคัญคือ Filter เดียวกันจะถูกใช้ซ้ำในหลายตำแหน่งของภาพ ดังนั้น หาก Filter เรียนรู้รูปแบบบางอย่าง เช่น ขอบในแนวตั้ง Filter ดังกล่าวก็สามารถใช้ค้นหาขอบในแนวตั้งจากหลายตำแหน่งภายในภาพได้



รูปที่ 9.6 Filter แต่ละตัวสามารถเรียนรู้และตรวจจับรูปแบบที่แตกต่างกันจากภาพเดียวกัน

จากรูปที่ 9.6 จะเห็นว่า ภาพนำเข้าหนึ่งภาพสามารถผ่าน Filter หลายตัว และแต่ละ Filter จะสร้างผลลัพธ์ของตนเอง ด้วยเหตุนี้ CNN จึงสามารถเรียนรู้คุณลักษณะหลายรูปแบบจากข้อมูลภาพเดียวกัน

ในระหว่างการฝึกสอน ค่า Weight ภายใน Filter จะถูกปรับเพื่อให้ผลลัพธ์สุดท้ายของโมเดลมีความถูกต้องมากขึ้น กล่าวได้ว่า CNN เรียนรู้ว่าจะใช้ Filter ลักษณะใดในการค้นหารูปแบบที่มีประโยชน์ต่อการทำงาน

9.2.4. Feature Map

แผนที่คุณลักษณะ (Feature Map) คือผลลัพธ์ที่ได้จากการนำ Filter ไปประมวลผลกับข้อมูลภาพ โดยสามารถมองว่า Feature Map เป็นภาพหรือชุดข้อมูลใหม่ที่แสดงบริเวณซึ่ง Filter ตรวจจับรูปแบบที่สนใจ

ตัวอย่างเช่น หาก Filter หนึ่งมีความสามารถในการตรวจจับเส้นแนวตั้ง พื้นที่ที่มีลักษณะใกล้เคียงกับเส้นแนวตั้งอาจให้ค่าการตอบสนองสูง ขณะที่บริเวณอื่นอาจให้ค่าการตอบสนองต่ำ

ดังนั้น Feature Map ไม่จำเป็นต้องมีลักษณะเหมือนภาพต้นฉบับ แต่เป็นข้อมูลที่แสดงผลของการตรวจจับคุณลักษณะบางประเภท

กระบวนการพื้นฐานสามารถอธิบายได้ดังนี้

Input Image → Filter → Convolution → Feature Map

หาก Convolution Layer มี Filter หลายตัว ก็จะสามารถสร้าง Feature Map ได้หลายชุด โดยแต่ละชุดแสดงข้อมูลจากมุมมองของคุณลักษณะที่แตกต่างกัน

ในช่วงแรกของ CNN Feature Map มักเกี่ยวข้องกับลักษณะพื้นฐานของภาพ เช่น ขอบ เส้น มุม ความแตกต่างของความสว่าง เป็นต้น เมื่อข้อมูลผ่านไปยัง Convolution Layer ที่อยู่ลึกขึ้น Feature Map สามารถแสดงรูปแบบที่มีความซับซ้อนมากขึ้น เนื่องจากข้อมูลในชั้นหลังไม่ได้รับเฉพาะภาพต้นฉบับ แต่ได้รับ Feature Map ที่ผ่านการสกัดคุณลักษณะจากชั้นก่อนหน้าแล้ว

9.2.5. Activation Function

หลังจากข้อมูลผ่านการคำนวณใน Convolution Layer ผลลัพธ์มักถูกส่งผ่านฟังก์ชันกระตุ้น (Activation Function) ซึ่งเป็นแนวคิดเดียวกับที่ศึกษาในบทที่ 8

Activation Function มีหน้าที่ช่วยเพิ่มความสามารถในการเรียนรู้ความสัมพันธ์ที่ซับซ้อนให้กับ Neural Network หากไม่มี Activation Function โครงข่ายหลายชั้นจะมีข้อจำกัดในการเรียนรู้รูปแบบที่ซับซ้อน

ใน CNN ฟังก์ชันกระตุ้นที่พบได้บ่อยคือ ReLU (Rectified Linear Unit) ซึ่งสามารถเขียนได้ดังนี้

$$f(x) = \max(0, x) \quad (2)$$

จากสมการที่ 2 หากค่า x มีค่ามากกว่า 0 ผลลัพธ์จะเท่ากับ x แต่หาก x มีค่าน้อยกว่า 0 ผลลัพธ์จะเป็น 0 ตัวอย่างเช่น

$$\text{ถ้า } x = 5 \text{ จะได้ } f(5) = 5$$

$$\text{ถ้า } x = -3 \text{ จะได้ } f(-3) = 0$$

แนวคิดของ ReLU ถูกนำมาใช้กับผลลัพธ์จาก Convolution Layer เพื่อช่วยให้โครงข่ายสามารถเรียนรู้รูปแบบที่ซับซ้อนมากขึ้น ในการศึกษา CNN ระดับพื้นฐาน สามารถมองลำดับการทำงานในส่วนนี้ได้ดังนี้

Input → Convolution → Activation → Feature Map

แม้ว่าการออกแบบ CNN ในงานจริงอาจใช้ Activation Function หลายประเภทตามลักษณะของโมเดล แต่ ReLU เป็นตัวอย่างที่ช่วยเชื่อมโยงความรู้จาก Neural Network ในบทที่ 8 มาสู่การทำงานของ CNN ได้อย่างชัดเจน

9.2.6. Pooling Layer

ชั้นรวมข้อมูล (Pooling Layer) มีหน้าที่ลดขนาดของ Feature Map เพื่อช่วยลดปริมาณข้อมูลที่ต้องประมวลผลในขั้นถัดไป

หลังจาก Convolution Layer ทำงานแล้ว อาจได้ Feature Map ที่มีขนาดใหญ่ หากส่งข้อมูลขนาดใหญ่ผ่านทุกชั้นของโครงข่าย อาจทำให้ต้องใช้ทรัพยากรในการประมวลผลมากขึ้น Pooling Layer จึงช่วยลดขนาดของข้อมูลโดยสรุปค่าจากบริเวณขนาดเล็ก

รูปแบบที่พบบ่อยคือ Max Pooling ซึ่งจะเลือกค่าที่มากที่สุดจากแต่ละบริเวณ


ตัวอย่างเช่น หากมีข้อมูลขนาด 2×2

1 1

1 1

เมื่อใช้ Max Pooling ผลลัพธ์ของการกระทำระหว่าง Input และ Feature Map ที่มากที่สุดคือ 6 เนื่องจาก เป็นค่าที่มากที่สุดในบริเวณดังกล่าว

นอกจาก Max Pooling แล้ว ยังมี Average Pooling ซึ่งใช้ค่าเฉลี่ยของข้อมูลในบริเวณที่กำหนด อย่างไรก็ตาม ในระดับพื้นฐาน Max Pooling เป็นตัวอย่างที่ช่วยให้เข้าใจหน้าที่ของ Pooling Layer ได้อย่างชัดเจน



รูปที่ 9.7 Max Pooling เลือกค่าที่มากที่สุดจากแต่ละบริเวณเพื่อลดขนาดของ Feature Map

จากรูปที่ 9.7 จะเห็นว่า Pooling ไม่ได้มีหน้าที่ค้นหาคุณลักษณะใหม่โดยตรงเหมือน Convolution Layer แต่ช่วยลดขนาดของข้อมูลที่ได้จากการสกัดคุณลักษณะ การลดขนาดข้อมูลสามารถช่วยให้ ลดปริมาณการคำนวณในขั้นถัดไป ลดจำนวนข้อมูลที่ต้องจัดการ หรือ ทำให้โมเดลให้ความสำคัญกับลักษณะสำคัญในระดับหนึ่ง

ดังนั้น Convolution Layer และ Pooling Layer จึงมีบทบาทที่แตกต่างกัน โดย Convolution Layer เน้นการค้นหาและสกัดคุณลักษณะ ส่วน Pooling Layer เน้นการลดขนาดและสรุปข้อมูลจากคุณลักษณะที่ตรวจพบ

9.2.7. Fully Connected Layer

หลังจากข้อมูลภาพผ่านกระบวนการ Convolution และ Pooling หลายขั้นตอน CNN จะได้ข้อมูลคุณลักษณะที่ผ่านการสกัดมาแล้ว ในขั้นตอนต่อไป ข้อมูลเหล่านี้สามารถถูกนำไปใช้ในชั้นเชื่อมต่อเต็มรูปแบบ (Fully Connected Layer)

แนวคิดของ Fully Connected Layer เหมือนกับ Neural Network ที่ศึกษาในบทที่ 8 กล่าวคือ หน่วยประมวลผลในชั้นหนึ่งสามารถเชื่อมต่อกับหน่วยประมวลผลในชั้นถัดไป

ความแตกต่างคือ ข้อมูลที่เข้าสู่ Fully Connected Layer ใน CNN ไม่ใช่ค่าของ Pixel ดิบจากภาพโดยตรง แต่เป็นคุณลักษณะที่ผ่านกระบวนการสกัดมาแล้ว

ตัวอย่างเช่น หาก CNN ถูกออกแบบเพื่อจำแนกภาพออกเป็น 3 ประเภท ได้แก่ แมว สุนัข และ นก เป็นต้น Convolution Layer อาจช่วยค้นหารูปแบบต่าง ๆ ของภาพ เช่น ขอบ รูปร่าง หรือพื้นผิว จากนั้นข้อมูลคุณลักษณะที่ผ่านกระบวนการต่าง ๆ จะถูกส่งไปยัง Fully Connected Layer เพื่อรวมข้อมูลและใช้ในการตัดสินใจว่าภาพดังกล่าวควรอยู่ในกลุ่มใด ดังนั้น ในระดับแนวคิด สามารถมองได้ว่า

- Convolution และ Pooling ทำหน้าที่หลักในการสกัดคุณลักษณะ
- Fully Connected Layer ทำหน้าที่หลักในการนำคุณลักษณะมาใช้ประกอบการตัดสินใจ

อย่างไรก็ตาม CNN สมัยใหม่บางรูปแบบอาจออกแบบส่วนของโครงข่ายแตกต่างจากตัวอย่างพื้นฐานนี้ ดังนั้น Fully Connected Layer จึงควรเข้าใจว่าเป็นองค์ประกอบหนึ่งของโครงสร้าง CNN แบบพื้นฐาน ไม่ใช่ส่วนที่จำเป็นต้องปรากฏใน CNN ทุกสถาปัตยกรรม

9.2.8. Output Layer

ชั้นผลลัพธ์ (Output Layer) เป็นส่วนที่แสดงผลลัพธ์สุดท้ายจากการประมวลผลของ CNN รูปแบบของ Output Layer ขึ้นอยู่กับประเภทของปัญหาที่ต้องการแก้ไข

ตัวอย่างเช่น ในงานจำแนกภาพออกเป็น 3 ประเภท ผลลัพธ์อาจแสดงเป็นค่าความน่าจะเป็นหรือคะแนนสำหรับแต่ละกลุ่ม เช่น

Cat: 0.85

Dog: 0.10

Bird: 0.05

ในตัวอย่างนี้ โมเดลอาจเลือก Cat เป็นผลลัพธ์ของการจำแนก เนื่องจากมีค่าคะแนนสูงที่สุด

ในงานประเภทอื่น Output Layer อาจมีรูปแบบแตกต่างกัน เช่น การระบุตำแหน่งของวัตถุในภาพ หรือการแบ่งพื้นที่ของภาพออกเป็นส่วนต่าง ๆ ตามประเภทที่กำหนด

ดังนั้น Output Layer จึงเป็นส่วนที่เชื่อมโยงผลลัพธ์จากการเรียนรู้ภายในโครงข่ายไปสู่ผลลัพธ์ที่สามารถนำไปใช้ตอบโจทย์ของปัญหาได้

9.2.9. ภาพรวมการทำงานขององค์ประกอบพื้นฐาน

เมื่อพิจารณาองค์ประกอบทั้งหมดร่วมกัน การทำงานของ CNN แบบพื้นฐานสามารถสรุปเป็นลำดับได้ดังนี้

ภาพถูกนำเข้าสู่ระบบผ่าน Input Image จากนั้น Convolution Layer ใช้ Filter หลายตัวเพื่อตรวจสอบรูปแบบในบริเวณต่าง ๆ ของภาพ ผลลัพธ์ที่ได้เรียกว่า Feature Map ซึ่งแสดงข้อมูลเกี่ยวกับคุณลักษณะที่ Filter ตรวจพบ

จากนั้นข้อมูลจะผ่าน Activation Function เพื่อช่วยให้โครงข่ายสามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนมากขึ้น และอาจผ่าน Pooling Layer เพื่อลดขนาดของ Feature Map กระบวนการ Convolution, Activation และ Pooling สามารถเกิดซ้ำได้หลายครั้ง ทำให้ข้อมูลในชั้นลึกขึ้นสามารถแสดงคุณลักษณะที่มีความซับซ้อนมากขึ้น

ในขั้นตอนสุดท้าย คุณลักษณะที่ผ่านการสกัดจะถูกนำไปใช้ในส่วนของการตัดสินใจ เช่น Fully Connected Layer และ Output Layer เพื่อสร้างผลลัพธ์ตามวัตถุประสงค์ของระบบ

กล่าวโดยสรุป องค์ประกอบแต่ละส่วนของ CNN สามารถแบ่งบทบาทหลักออกเป็นสองส่วน ได้แก่ ส่วนแรกคือ การสกัดคุณลักษณะ (Feature Extraction) ซึ่งประกอบด้วยองค์ประกอบสำคัญ เช่น Convolution Layer, Filter, Activation Function และ Pooling Layer

ส่วนที่สองคือ การใช้คุณลักษณะเพื่อสร้างผลลัพธ์ (Decision or Classification) ซึ่งใน CNN พื้นฐานอาจใช้ Fully Connected Layer และ Output Layer

ความเข้าใจเกี่ยวกับองค์ประกอบเหล่านี้เป็นพื้นฐานสำคัญสำหรับการศึกษาหลักการทำงานของ CNN ในหัวข้อถัดไป ซึ่งจะอธิบายการเดินทางของข้อมูลตั้งแต่ภาพนำเข้าจนถึงผลลัพธ์ และแสดงให้เห็นว่า CNN สามารถเรียนรู้คุณลักษณะจากระดับพื้นฐานไปสู่รูปแบบที่มีความซับซ้อนมากขึ้นได้อย่างไร.


9.3 หลักการทำงานของ โครงข่ายประสาทเทียมแบบคอนโวลูชัน

หลังจากได้ศึกษาหน้าที่ขององค์ประกอบพื้นฐานของ โครงข่ายประสาทเทียมแบบคอนโวลูชัน ในหัวข้อ 9.2 แล้ว ในหัวข้อนี้จะอธิบายภาพรวมการทำงานขององค์ประกอบเหล่านั้นร่วมกัน เพื่อให้เห็นลำดับการไหลของข้อมูลตั้งแต่ภาพถูกนำเข้าสู่ระบบจนกระทั่งได้ผลลัพธ์สุดท้าย

แนวคิดสำคัญของ CNN คือการเปลี่ยนข้อมูลภาพที่อยู่ในรูปของ Pixel จำนวนมาก ให้กลายเป็นข้อมูลคุณลักษณะ (Feature) ที่มีความหมายต่อการแก้ปัญหา โดย CNN จะไม่ได้พยายามตัดสินใจผลลัพธ์จาก

ภาพทั้งหมดในขั้นตอนเดียว แต่จะค่อย ๆ ประมวลผลและสกัดคุณลักษณะจากระดับพื้นฐานไปสู่ระดับที่มีความซับซ้อนมากขึ้น

องค์ประกอบในแต่ละขั้นตอน ได้แก่ Convolution Layer, Activation Function, Pooling Layer, Fully Connected Layer และ Output Layer ได้อธิบายหน้าที่ไว้แล้วในหัวข้อ 9.2 โดยในส่วนนี้จะเน้นความสัมพันธ์และลำดับการทำงานขององค์ประกอบเหล่านั้น



รูปที่ 9.8 ลำดับการทำงานของ CNN ตั้งแต่ข้อมูลภาพนำเข้าจนถึงผลลัพธ์

จากรูปที่ 9.8 จะเห็นว่า การทำงานของ CNN สามารถแบ่งออกเป็นสองกระบวนการหลัก ได้แก่ การสกัดคุณลักษณะ (Feature Extraction) และการนำคุณลักษณะไปใช้ในการตัดสินใจหรือจำแนกผลลัพธ์ (Classification)

9.3.1. การไหลของข้อมูลจากภาพสู่คุณลักษณะ

กระบวนการเริ่มต้นจาก Input Image ซึ่งเก็บข้อมูลในรูปของ Pixel ที่ยังไม่ได้ผ่านการตีความโดยโมเดล จากนั้นข้อมูลจะถูกส่งเข้าสู่ Convolution Layer

ตามที่กล่าวไว้ในหัวข้อ 9.2 Convolution Layer ใช้ Filter หรือ Kernel ตรวจสอบข้อมูลในบริเวณต่าง ๆ ของภาพ ผลลัพธ์ที่ได้จาก Filter จะถูกสร้างเป็น Feature Map ซึ่งแสดงข้อมูลเกี่ยวกับรูปแบบหรือคุณลักษณะที่ Filter ตรวจพบ

ข้อมูลจาก Feature Map จะผ่าน Activation Function ก่อนส่งต่อไปยังขั้นตอนถัดไป และในบางส่วนของโครงข่ายอาจมี Pooling Layer เพื่อช่วยลดขนาดของ Feature Map ดังนั้น ลำดับการไหลของข้อมูลในส่วนหนึ่งของ CNN ดังรูปที่ 9.8 ผลลัพธ์จากแต่ละขั้นตอนจะไม่ใช่ว่าภาพต้นฉบับอีกต่อไป แต่เป็นข้อมูลที่ผ่านการแปลงและแสดงคุณลักษณะบางอย่างที่ CNN ตรวจพบจากภาพ กระบวนการดังกล่าวสามารถเกิดขึ้นซ้ำหลายครั้ง โดย Feature Map ที่ได้จากขั้นก่อนหน้าจะกลายเป็นข้อมูลนำเข้าสำหรับ Convolution Layer ในขั้นถัดไป

9.3.2. การสกัดคุณลักษณะเป็นลำดับชั้น

ลักษณะสำคัญของ CNN คือการเรียนรู้คุณลักษณะเป็นลำดับชั้น (Hierarchical Feature Learning) ในขั้นแรก ๆ ของโครงข่าย CNN จะเริ่มจากการค้นหารูปแบบพื้นฐานของข้อมูลภาพ เช่น เส้น ขอบ มุม หรือความแตกต่างของสีและความสว่าง

เมื่อข้อมูลผ่านไปยัง Convolution Layer ที่อยู่ลึกขึ้น Feature Map จากชั้นก่อนหน้าจะถูกนำมาประมวลผลต่อ ทำให้ CNN สามารถเรียนรู้รูปแบบที่ซับซ้อนขึ้นได้ ตัวอย่างเช่น ในการวิเคราะห์ภาพใบหน้า ชั้นแรกของ CNN อาจตอบสนองต่อเส้นและขอบทั่วไป ชั้นต่อมาอาจเรียนรู้รูปแบบของส่วนประกอบ เช่น ดวงตาหรือปาก และในชั้นที่ลึกขึ้น ข้อมูลจากส่วนประกอบหลายส่วนสามารถถูกนำมารวมกันเป็นคุณลักษณะที่ช่วยในการวิเคราะห์หรือจำแนกภาพ จากแนวคิดที่แสดงในรูปที่ 4 จะเห็นว่า CNN สามารถเรียนรู้คุณลักษณะของข้อมูลภาพเป็นลำดับชั้น โดยชั้นแรก ๆ มักตอบสนองต่อคุณลักษณะพื้นฐาน เช่น ขอบหรือความแตกต่างของค่าพิกเซล ขณะที่ชั้นที่ลึกขึ้นสามารถนำคุณลักษณะเหล่านี้มาประกอบกันเพื่อแทนรูปแบบที่ซับซ้อนขึ้น เช่น ส่วนประกอบของวัตถุหรือรูปแบบของวัตถุโดยรวม กระบวนการนี้เป็นตัวอย่างของ Automatic Feature Extraction ซึ่งแตกต่างจากแนวทางดั้งเดิมที่ผู้พัฒนาระบบอาจต้องกำหนดคุณลักษณะที่ต้องการใช้ด้วยตนเอง

9.3.3. การทำซ้ำของกระบวนการ Feature Extraction

CNN สามารถมี Convolution Layer หลายชั้นตามความซับซ้อนของปัญหา ในแต่ละชั้นจะทำงานกับข้อมูลที่ผ่านการสกัดคุณลักษณะจากชั้นก่อนหน้าแล้ว การเพิ่มจำนวนชั้นทำให้ CNN มีโอกาสเรียนรู้รูปแบบที่มีความซับซ้อนมากขึ้น อย่างไรก็ตาม การมีจำนวนชั้นมากขึ้นไม่ได้หมายความว่าจะให้ผลลัพธ์ที่ดีขึ้นเสมอไป เนื่องจากโมเดลที่มีความซับซ้อนสูงอาจต้องการข้อมูลและทรัพยากรในการฝึกมากขึ้น

แนวคิดนี้สามารถเชื่อมโยงกับเรื่องจำนวนชั้นและความซับซ้อนของ Neural Network รวมถึงปัญหา Underfitting และ Overfitting ที่ได้ศึกษาในบทที่ 8

ดังนั้น การออกแบบ CNN จึงต้องเลือกความซับซ้อนให้เหมาะสมกับลักษณะของข้อมูลและปัญหาที่ต้องการแก้

9.3.4. จากคุณลักษณะสู่การจำแนกผลลัพธ์

เมื่อข้อมูลผ่านกระบวนการ Feature Extraction แล้ว CNN จะได้ชุดข้อมูลที่แสดงคุณลักษณะสำคัญของภาพ ซึ่งสามารถนำไปใช้ในการตัดสินใจในส่วนของ Classification ใน CNN แบบพื้นฐาน ส่วนนี้อาจใช้ Fully Connected Layer และ Output Layer ตามที่กล่าวไว้ในหัวข้อ 9.2 ตัวอย่างเช่น หากต้องการจำแนกภาพออกเป็น 3 ประเภท ได้แก่ Cat Dog และ Bird หลังจากภาพผ่านกระบวนการ Feature Extraction แล้ว ข้อมูลคุณลักษณะที่ได้จะถูกส่งไปยังส่วน Classification เพื่อคำนวณผลลัพธ์สำหรับแต่ละประเภท

ผลลัพธ์อาจมีลักษณะดังนี้

Cat = 0.82

Dog = 0.14

Bird = 0.04

ในกรณีนี้ Cat มีค่าผลลัพธ์สูงที่สุด จึงสามารถเลือก Cat เป็นผลลัพธ์ของการจำแนก

สิ่งสำคัญคือ การตัดสินใจในขั้นตอนนี้ไม่ได้เกิดจากการนำค่าของ Pixel ดิบทั้งหมดมาเปรียบเทียบโดยตรง แต่เกิดจากการใช้คุณลักษณะที่ CNN ได้เรียนรู้และสกัดออกมาจากกระบวนการในชั้นก่อนหน้านี้

ดังนั้น การทำงานของ CNN จึงสามารถมองได้เป็นสองส่วนสำคัญ ได้แก่

ส่วนการสกัดคุณลักษณะ

Input Image → Convolution → Activation → Pooling → Feature Map

และส่วนการตัดสินใจ

Extracted Features → Fully Connected Layer → Output

การแบ่งบทบาทในลักษณะนี้ช่วยให้เห็นภาพว่า CNN เปลี่ยนข้อมูลจากระดับ Pixel ไปสู่ข้อมูลคุณลักษณะ ก่อนนำคุณลักษณะเหล่านั้นไปใช้ในการจำแนกหรือตัดสินใจ

9.3.5. การเรียนรู้ของ CNN ในระหว่างการฝึกสอน

การทำงานที่กล่าวมาข้างต้นเป็นกระบวนการ Forward Propagation ซึ่งเชื่อมโยงโดยตรงกับแนวคิดของ Neural Network ที่ศึกษาในบทที่ 8

ในระหว่างการฝึกสอน CNN จะรับข้อมูลภาพเข้าสู่ระบบและส่งข้อมูลผ่านองค์ประกอบต่าง ๆ จนได้ผลลัพธ์ จากนั้นผลลัพธ์ที่โมเดลสร้างขึ้นจะถูกเปรียบเทียบกับผลลัพธ์ที่ถูกต้องของข้อมูลตัวอย่าง

หากผลลัพธ์ยังมีความแตกต่างจากค่าที่ต้องการ ค่า Weight ภายใน CNN จะถูกปรับเพื่อให้โมเดลสามารถสร้างผลลัพธ์ที่เหมาะสมขึ้น

กระบวนการดังกล่าวเกิดขึ้นกับ Weight หลายส่วนของโครงข่าย รวมถึง Weight ที่อยู่ภายใน Filter ดังนั้น Filter ที่กล่าวถึงในหัวข้อ 9.2 ไม่ได้เป็นรูปแบบที่มนุษย์กำหนดขึ้นตายตัว แต่สามารถเรียนรู้รูปแบบที่เหมาะสมจากข้อมูลที่ใช้ในการฝึก

ในระดับแนวคิด กระบวนการเรียนรู้สามารถสรุปได้ดังนี้

Input Image → Forward Propagation → Predicted Output → เปรียบเทียบกับผลลัพธ์ที่ถูกต้อง → ปรับ Weight → ทำซ้ำ

เมื่อกระบวนการนี้เกิดขึ้นกับข้อมูลจำนวนมาก CNN จะค่อย ๆ เรียนรู้ว่า Filter และ Weight ลักษณะใดช่วยให้สามารถสกัดคุณลักษณะและสร้างผลลัพธ์ได้อย่างถูกต้องมากขึ้น

9.3.6. ตัวอย่างภาพรวมการทำงานของ CNN

สมมติว่าต้องการสร้างระบบสำหรับจำแนกภาพว่าเป็น “แมว” หรือ “สุนัข”

ภาพจะถูกนำเข้าสู CNN และส่งผ่านกระบวนการ Feature Extraction ตามองค์ประกอบที่กล่าวไว้ในหัวข้อ 9.2 Filter หลายตัวจะเรียนรู้รูปแบบที่แตกต่างกันจากข้อมูลภาพ และเมื่อข้อมูลผ่านเข้าสู่ชั้นที่ลึกขึ้นคุณลักษณะพื้นฐานจะถูกนำมาประกอบกันเป็นรูปแบบที่มีความซับซ้อนมากขึ้น


หลังจากได้คุณลักษณะที่เหมาะสม ข้อมูลจะถูกส่งเข้าสู่ส่วน Classification เพื่อสร้างผลลัพธ์ เช่น

Cat = 0.91

Dog = 0.09

ระบบจึงเลือก Cat เป็นผลลัพธ์ของการจำแนก

ภาพรวมของกระบวนการแสดงในรูปที่ 9.9



รูปที่ 9.9 การทำงานของ CNN ตั้งแต่ภาพนำเข้า การสกัดคุณลักษณะ จนถึงการจำแนกผลลัพธ์

จากรูปที่ 9.9 จะเห็นว่าหลักการสำคัญของ CNN ไม่ได้อยู่ที่การจำแนกภาพเพียงอย่างเดียว แต่คือความสามารถในการเรียนรู้การแทนข้อมูลและคุณลักษณะที่เหมาะสมจากข้อมูลภาพ

กล่าวอีกนัยหนึ่ง CNN สามารถเปลี่ยนข้อมูลจาก Pixel → คุณลักษณะพื้นฐาน → คุณลักษณะที่ซับซ้อน → ผลลัพธ์

แนวคิดของการเรียนรู้คุณลักษณะโดยอัตโนมัตินี้ทำให้ CNN สามารถนำไปใช้กับปัญหาด้าน Computer Vision ได้อย่างหลากหลาย

9.4 การประยุกต์ใช้ โครงข่ายประสาทเทียมแบบคอนโวลูชัน

จากหัวข้อที่ผ่านมา จะเห็นว่าโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network: CNN) สามารถเรียนรู้และสกัดคุณลักษณะจากข้อมูลที่มีโครงสร้างเชิงพื้นที่ โดยเฉพาะข้อมูลภาพ ความสามารถดังกล่าวทำให้ CNN ถูกนำไปประยุกต์ใช้กับงานด้านการมองเห็นของคอมพิวเตอร์ (Computer Vision) อย่างแพร่หลาย

การประยุกต์ใช้ CNN ไม่ได้จำกัดอยู่เพียงการตอบคำถามว่า “ภาพนี้คืออะไร” เท่านั้น แต่ยังสามารถนำไปใช้เพื่อค้นหาวัตถุ วิเคราะห์ลักษณะของภาพ ตรวจสอบความผิดปกติ และสนับสนุนการตัดสินใจในงานด้านต่าง ๆ

9.4.1. CNN กับงาน Computer Vision

การมองเห็นของคอมพิวเตอร์ (Computer Vision) เป็นสาขาหนึ่งของปัญญาประดิษฐ์ที่เกี่ยวข้องกับการทำให้คอมพิวเตอร์สามารถวิเคราะห์และตีความข้อมูลจากภาพหรือวิดีโอ

สำหรับมนุษย์ การมองภาพและระบุวัตถุเป็นกระบวนการที่เกิดขึ้นได้อย่างรวดเร็ว ตัวอย่างเช่น มนุษย์สามารถมองภาพและบอกได้ว่าภาพนั้นเป็นรถยนต์ สัตว์ หรือบุคคล อย่างไรก็ตาม สำหรับคอมพิวเตอร์ ภาพเป็นเพียงข้อมูลที่ประกอบด้วยค่าของ Pixel จำนวนมาก

CNN ช่วยให้ระบบสามารถเรียนรู้ความสัมพันธ์และรูปแบบจากข้อมูลภาพ โดยผ่านกระบวนการ Feature Extraction ที่ได้ศึกษาในหัวข้อ 9.3 ทำให้ข้อมูลภาพสามารถถูกนำไปใช้กับงานต่าง ๆ ได้

ตัวอย่างของงาน Computer Vision ที่สามารถประยุกต์ใช้ CNN ได้แก่

- การจำแนกภาพ (Image Classification)
- การตรวจจับวัตถุ (Object Detection)
- การรู้จำหรือวิเคราะห์ใบหน้า (Face Recognition and Face Analysis)
- การวิเคราะห์ภาพทางการแพทย์ (Medical Image Analysis)
- การตรวจสอบคุณภาพในภาคอุตสาหกรรม (Quality Inspection)

9.4.2. การจำแนกภาพ

การจำแนกภาพ (Image Classification) เป็นหนึ่งในการประยุกต์ใช้ CNN ที่เข้าใจได้ง่ายที่สุด โดยระบบจะรับภาพเป็นข้อมูลนำเข้า และสร้างผลลัพธ์เป็นประเภทหรือกลุ่มของภาพ

ตัวอย่างเช่น ระบบอาจได้รับการฝึกสอนให้จำแนกภาพออกเป็น 3 ประเภท ได้แก่ แมว สุนัข และ นก เมื่อมีภาพใหม่เข้าสู่ระบบ CNN จะใช้คุณลักษณะที่เรียนรู้จากข้อมูลฝึกสอนเพื่อสร้างผลลัพธ์ว่า ภาพดังกล่าวมีแนวโน้มอยู่ในกลุ่มใด ตัวอย่างการประยุกต์ใช้ Image Classification ได้แก่

- การจำแนกชนิดของพืชหรือสัตว์

- การจำแนกประเภทสินค้า
- การคัดแยกขยะตามประเภท
- การจำแนกภาพเอกสาร
- การวิเคราะห์ภาพจากกล้องในระบบต่าง ๆ

จุดสำคัญของ Image Classification คือ ระบบจะให้คำตอบเกี่ยวกับภาพโดยรวม เช่น “ภาพนี้เป็นแมว” หรือ “ภาพนี้เป็นสินค้าเสียหาย”

อย่างไรก็ตาม หากภาพหนึ่งภาพมีวัตถุหลายชิ้น Image Classification อาจไม่สามารถระบุได้อย่างละเอียดว่าวัตถุแต่ละชิ้นอยู่ที่ตำแหน่งใดของภาพ

9.4.3. การตรวจจับวัตถุ

การตรวจจับวัตถุ (Object Detection) เป็นงานที่มีความซับซ้อนมากกว่าการจำแนกภาพ เนื่องจากระบบไม่ได้ตอบเพียงว่าวัตถุชนิดใดปรากฏอยู่ในภาพ แต่ยังต้องระบุตำแหน่งของวัตถุนั้นด้วย

ตัวอย่างเช่น ภาพหนึ่งอาจมี รถยนต์ บุคคล หรือ สุนัข ระบบ Object Detection สามารถสร้างผลลัพธ์ที่ระบุว่า

Person → ตำแหน่งที่ 1

Car → ตำแหน่งที่ 2

Dog → ตำแหน่งที่ 3

โดยตำแหน่งของวัตถุอาจแสดงเป็นกรอบสี่เหลี่ยมล้อมรอบวัตถุ หรือ Bounding Box


จากรูปที่ 9.10 จะเห็นความแตกต่างสำคัญระหว่างสองงานนี้ โดย Image Classification ตอบคำถามว่า “ภาพนี้เกี่ยวข้องกับอะไร” ขณะที่ Object Detection ตอบคำถามว่า “มีวัตถุอะไรอยู่ในภาพ และวัตถุนั้นอยู่ที่ตำแหน่งใด”

การตรวจจับวัตถุสามารถนำไปใช้ในงานหลายประเภท เช่น ระบบช่วยวิเคราะห์การจราจร ระบบกล้องอัจฉริยะ ระบบตรวจนับสินค้า หุ่นยนต์ และ ระบบตรวจสอบความปลอดภัย เป็นต้น CNN เป็นหนึ่งในแนวคิดพื้นฐานที่มีบทบาทต่อการพัฒนาระบบ Computer Vision ประเภทนี้ แม้ว่าในงานจริงอาจมีการใช้สถาปัตยกรรมหรือแบบจำลองที่ซับซ้อนมากขึ้น

9.4.4. การรู้จำใบหน้า

การรู้จำใบหน้า (Face Recognition) เป็นอีกตัวอย่างหนึ่งของการนำ CNN และเทคนิค Deep Learning ไปใช้กับข้อมูลภาพ

ระบบสามารถเรียนรู้คุณลักษณะจากภาพใบหน้า เช่น รูปร่างโดยรวมของใบหน้า ตำแหน่งและลักษณะของดวงตา รูปร่างของจมูก ลักษณะของปาก ความสัมพันธ์ระหว่างส่วนประกอบต่าง ๆ



รูปที่ 9.10 Image Classification ระบุประเภทของภาพ ขณะที่ Object Detection ระบุทั้งประเภทและตำแหน่งของวัตถุ



รูปที่ 9.11 เปรียบเทียบ AI ที่ใช้วิเคราะห์หรือจำแนกข้อมูลกับ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ที่สามารถสร้างข้อมูลหรือเนื้อหาใหม่

หลังจากเรียนรู้คุณลักษณะเหล่านี้ ระบบสามารถนำข้อมูลไปใช้ในงาน เช่น การตรวจสอบว่าภาพสองภาพเป็นบุคคลเดียวกันหรือไม่ หรือการเปรียบเทียบใบหน้ากับข้อมูลที่มีอยู่ในระบบ ตัวอย่างการประยุกต์ใช้ได้แก่ ระบบยืนยันตัวตน ระบบควบคุมการเข้าออก การจัดกลุ่มภาพบุคคล และระบบค้นหาบุคคลจากฐานข้อมูลภาพ เป็นต้น อย่างไรก็ตาม การใช้ระบบรู้จำใบหน้าเกี่ยวข้องกับข้อมูลส่วนบุคคล จึงต้องพิจารณาเรื่องความเป็นส่วนตัว (Privacy) และความปลอดภัยของข้อมูลร่วมด้วย

9.4.5. การวิเคราะห์ภาพทางการแพทย์

ข้อมูลภาพมีบทบาทสำคัญในงานด้านการแพทย์ เช่น

- ภาพเอกซเรย์
- ภาพเอกซเรย์คอมพิวเตอร์
- ภาพจากการตรวจด้วยคลื่นแม่เหล็กไฟฟ้า
- ภาพจากกล้องจุลทรรศน์
- ภาพถ่ายภาพทางการแพทย์

CNN สามารถนำมาใช้เพื่อเรียนรู้รูปแบบจากภาพเหล่านี้ และช่วยค้นหาลักษณะที่อาจเกี่ยวข้องกับความผิดปกติหรือภาวะที่ต้องการศึกษา

ตัวอย่างเช่น ระบบอาจถูกพัฒนาเพื่อช่วย

- จำแนกภาพที่มีลักษณะแตกต่างจากปกติ
- ค้นหาบริเวณที่ควรได้รับการตรวจสอบเพิ่มเติม
- สนับสนุนการวิเคราะห์ข้อมูลภาพจำนวนมาก

การประยุกต์ใช้ AI ในลักษณะนี้ควรมองว่าเป็นเครื่องมือสำหรับช่วยสนับสนุนผู้เชี่ยวชาญในการวิเคราะห์ข้อมูล ไม่ควรนำผลลัพธ์จากระบบไปใช้เป็นข้อสรุปโดยไม่ผ่านการตรวจสอบจากผู้มีความรู้และผู้เชี่ยวชาญในสาขาที่เกี่ยวข้อง

9.4.6. การตรวจสอบคุณภาพในภาคอุตสาหกรรม

CNN สามารถนำมาใช้ในการตรวจสอบคุณภาพ (Quality Inspection) โดยใช้กล้องถ่ายภาพสินค้าชิ้นส่วน หรือผลิตภัณฑ์ จากนั้นระบบจะวิเคราะห์ภาพเพื่อค้นหาความผิดปกติ

ตัวอย่างเช่น ระบบอาจใช้ตรวจสอบว่า

- ชิ้นส่วนมีรอยแตกหรือไม่
- ผลิตภัณฑ์มีตำหนิหรือไม่
- มีชิ้นส่วนบางส่วนหายไปหรือไม่
- สินค้าถูกประกอบอย่างถูกต้องหรือไม่
- ผลิตภัณฑ์ตรงตามมาตรฐานที่กำหนดหรือไม่

9.5 แนวคิดพื้นฐานของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ และ แบบจำลองเชิงสร้างสรรค์

ปัญญาประดิษฐ์ที่กล่าวถึงในบทก่อนหน้านี้และเนื้อหาส่วนแรกของบทนี้แสดงให้เห็นว่า Neural Network สามารถพัฒนาเป็นสถาปัตยกรรมที่เหมาะสมกับลักษณะของข้อมูลและวัตถุประสงค์ที่แตกต่างกันได้ ตัวอย่างเช่น โครงข่ายประสาทเทียมแบบคอนโวลูชัน ได้รับการออกแบบให้สามารถเรียนรู้คุณลักษณะเชิงพื้นที่จากข้อมูลภาพ

อย่างไรก็ตาม การประยุกต์ใช้ AI ไม่ได้จำกัดอยู่เพียงการจำแนกข้อมูลหรือการทำนายผลลัพธ์ ในปัจจุบัน AI สามารถเรียนรู้รูปแบบจากข้อมูลจำนวนมากและนำความรู้ที่เรียนรู้มาใช้ในการสร้างข้อมูลหรือเนื้อหาใหม่ได้ แนวคิดดังกล่าวเป็นพื้นฐานสำคัญของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ (Generative Artificial Intelligence: Generative AI)

ปัญญาประดิษฐ์เชิงสร้างสรรค์ เป็นแนวทางของปัญญาประดิษฐ์ที่มุ่งเน้นความสามารถในการสร้างข้อมูลหรือเนื้อหาใหม่ โดยอาศัยแบบจำลองที่เรียนรู้รูปแบบ ความสัมพันธ์ และลักษณะต่าง ๆ จากข้อมูลที่ใช้ในการฝึก

ข้อมูลหรือเนื้อหาที่ ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสร้างได้มีหลายรูปแบบ เช่น ข้อความ (Text) ภาพ (Image) เสียง (Audio) วิดีโอ (Video) โปรแกรมหรือโค้ด (Code) เป็นต้น ตัวอย่างเช่น ระบบ AI ที่ใช้สำหรับการจำแนกภาพอาจได้รับภาพหนึ่งภาพเป็นข้อมูลนำเข้า แล้วตอบว่าภาพนั้นเป็นภาพของวัตถุประเภทใด

ในขณะที่ ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถรับคำสั่งหรือเงื่อนไขจากผู้ใช้ แล้วสร้างข้อมูลใหม่ตามข้อมูลนำเข้านั้น ดังนั้น แนวคิดสำคัญของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ คือการเปลี่ยนบทบาทของ AI จากระบบที่มีหน้าที่หลักในการ วิเคราะห์ จำแนก หรือทำนายข้อมูล ไปสู่ระบบที่สามารถ สร้างเนื้อหาใหม่ ได้

จากรูปที่ 9.11 AI สำหรับการวิเคราะห์หรือจำแนกข้อมูลอาจตอบคำถาม เช่น

“ข้อมูลนี้คืออะไร”

“ข้อมูลนี้อยู่ในกลุ่มใด”

“ค่าที่ควรทำนายคือเท่าใด”

ในขณะที่ ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถตอบสนองต่อคำสั่งในลักษณะ เช่น

“เขียนบทความเกี่ยวกับ Neural Network”

“สร้างภาพตามคำอธิบาย”

“สร้างโปรแกรมสำหรับแก้ปัญหาที่กำหนด”

ผลลัพธ์ของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ จึงไม่ได้จำเป็นต้องเป็นคำตอบจากชุดตัวเลือกที่กำหนดไว้ล่วงหน้า แต่สามารถเป็นเนื้อหาใหม่ที่ถูกสร้างขึ้นตามรูปแบบและบริบทที่แบบจำลองได้เรียนรู้

9.5.1. การเรียนรู้รูปแบบเพื่อสร้างข้อมูลใหม่

แม้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ จะสามารถสร้างผลลัพธ์ได้หลากหลายรูปแบบ แต่แนวคิดพื้นฐานสามารถอธิบายได้ว่า แบบจำลองจะเรียนรู้รูปแบบ (Pattern) และความสัมพันธ์ (Relationship) จากข้อมูลตัวอย่างจำนวนมาก แล้วนำสิ่งที่เรียนรู้มาใช้ในการสร้างข้อมูลใหม่

แนวคิดดังกล่าวสามารถแสดงได้ดังนี้

ข้อมูลตัวอย่าง → เรียนรู้รูปแบบและความสัมพันธ์ → Generative Model → สร้างข้อมูลใหม่
แบบจำลองที่ใช้เรียนรู้และสร้างข้อมูลใหม่เรียกว่า แบบจำลองเชิงกำเนิด (Generative Model)

ปัญญาประดิษฐ์เชิงสร้างสรรค์ และ Generative Model จึงมีความสัมพันธ์กัน โดยสามารถอธิบายอย่างง่ายได้ว่า ปัญญาประดิษฐ์เชิงสร้างสรรค์ เป็นแนวคิดหรือกลุ่มของระบบ AI ที่มีความสามารถในการสร้างเนื้อหาใหม่ ส่วน Generative Model คือแบบจำลองที่ใช้เป็นกลไกสำคัญในการทำให้ระบบสามารถเรียนรู้รูปแบบและสร้างผลลัพธ์ได้

ตัวอย่างเช่น หากแบบจำลองเรียนรู้จากข้อมูลข้อความจำนวนมาก แบบจำลองจะเรียนรู้ลักษณะต่างๆ ของภาษา เช่น คำที่มักปรากฏร่วมกัน ลำดับของคำ โครงสร้างของประโยค ความสัมพันธ์ระหว่างข้อความ ความหมายที่เปลี่ยนแปลงตามบริบท เป็นต้น เมื่อได้รับข้อความหรือคำสั่งใหม่ แบบจำลองสามารถนำรูปแบบที่เรียนรู้มาใช้ในการสร้างข้อความที่มีความต่อเนื่องและสอดคล้องกับบริบท


ในทำนองเดียวกัน หากแบบจำลองเรียนรู้จากข้อมูลภาพจำนวนมาก ก็สามารถเรียนรู้ลักษณะ เช่น รูปร่าง สี พื้นผิว ตำแหน่งขององค์ประกอบ ความสัมพันธ์ระหว่างวัตถุ จากนั้นสามารถนำรูปแบบเหล่านี้มาใช้ในการสร้างภาพใหม่

จากรูปที่ 9.12 สิ่งสำคัญคือแบบจำลองไม่ได้ถูกออกแบบมาเพื่อจดจำข้อมูลตัวอย่างที่ละรายการแล้วเลือกข้อมูลเดิมออกมาโดยตรง แต่พยายามเรียนรู้รูปแบบและโครงสร้างที่ปรากฏอยู่ในข้อมูล

อย่างไรก็ตาม ระดับความสามารถของแบบจำลองขึ้นอยู่กับหลายปัจจัย เช่น

- ปริมาณและคุณภาพของข้อมูล
- ลักษณะของแบบจำลอง
- กระบวนการฝึก
- ขนาดและความซับซ้อนของแบบจำลอง
- วิธีการกำหนดข้อมูลนำเข้าและเงื่อนไขในการสร้างผลลัพธ์

ดังนั้น แม้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ จะสามารถสร้างเนื้อหาที่มีลักษณะใหม่ได้ แต่คุณภาพและความเหมาะสมของผลลัพธ์ไม่ได้รับประกันว่าจะถูกต้องเสมอไป



รูปที่ 9.12 Generative Model เรียนรู้รูปแบบจากข้อมูลตัวอย่าง และนำรูปแบบที่เรียนรู้มาใช้ในการสร้างข้อมูลใหม่

9.5.2. ประเภทของข้อมูลที่ ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสร้างได้

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถประยุกต์ใช้กับข้อมูลได้หลายรูปแบบ ซึ่งเป็นเหตุผลสำคัญที่ทำให้เทคโนโลยีนี้ได้รับความสนใจอย่างมาก

- **1) การสร้างข้อความ**

การสร้างข้อความ (Text Generation) เป็นหนึ่งในการประยุกต์ใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ที่พบได้ทั่วไป ระบบสามารถสร้างเนื้อหาหลายประเภท เช่น

- บทความ
- รายงาน
- คำอธิบาย
- บทสนทนา
- การสรุปเนื้อหา
- เอกสารทางเทคนิค

แบบจำลองจะใช้ข้อความหรือคำสั่งที่ได้รับเป็นส่วนหนึ่งของบริบทในการสร้างผลลัพธ์

ตัวอย่างเช่น ผู้ใช้อาจกำหนดคำสั่งว่า

“อธิบายหลักการทำงานของ Neural Network สำหรับนักศึกษาในระดับปริญญาตรี”

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสร้างคำอธิบายที่สอดคล้องกับหัวข้อและเงื่อนไขที่ได้รับ

- **2) การสร้างภาพ**

การสร้างภาพ (Image Generation) เป็นการใช้แบบจำลองเพื่อสร้างภาพใหม่จากข้อมูลหรือเงื่อนไขที่กำหนด เช่น คำอธิบายด้วยข้อความ

ตัวอย่างเช่น

“สร้างภาพหุ่นยนต์กำลังทำงานในห้องปฏิบัติการ”

แบบจำลองสามารถสร้างภาพที่มีองค์ประกอบสอดคล้องกับคำอธิบายดังกล่าว

การสร้างภาพด้วย ปัญญาประดิษฐ์เชิงสร้างสรรค์ แตกต่างจากงาน Image Classification ที่ใช้ CNN ใน PART 1 โดยงาน Image Classification มีเป้าหมายเพื่อวิเคราะห์และระบุสิ่งที่ปรากฏในภาพ ส่วนปัญญาประดิษฐ์เชิงสร้างสรรค์ มีเป้าหมายเพื่อสร้างภาพใหม่ตามรูปแบบหรือเงื่อนไขที่กำหนด

ดังนั้น แม้ทั้งสองงานจะเกี่ยวข้องกับข้อมูลภาพ แต่มีวัตถุประสงค์ที่ต่างกัน

- **3) การสร้างเสียง**

การสร้างเสียง (Audio Generation) สามารถครอบคลุมงานหลายประเภท เช่น

- การสร้างเสียงพูด
- การแปลงข้อความเป็นเสียง

- การสร้างดนตรี
- การสร้างเสียงประกอบ

ตัวอย่างเช่น ระบบสามารถรับข้อความเป็นข้อมูลนำเข้าและสร้างเสียงพูดที่สอดคล้องกับข้อความนั้น

- **4) การสร้างวิดีโอ**

การสร้างวิดีโอ (Video Generation) เกี่ยวข้องกับการสร้างข้อมูลภาพที่มีการเปลี่ยนแปลงตามเวลา ทำให้แบบจำลองต้องพิจารณาความสัมพันธ์ระหว่างภาพในแต่ละช่วงเวลา

ตัวอย่างการประยุกต์ใช้ ได้แก่

- การสร้างวิดีโอจากข้อความ
- การสร้างภาพเคลื่อนไหว
- การสร้างสื่อประกอบการนำเสนอ
- การสร้างเนื้อหาดิจิทัล

- **5) การสร้างโค้ด**

การสร้างโค้ด (Code Generation) เป็นการประยุกต์ใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ที่เกี่ยวข้องโดยตรงกับนักศึกษาวิศวกรรมคอมพิวเตอร์

ผู้ใช้งานสามารถอธิบายปัญหาหรือความต้องการด้วยภาษาธรรมชาติ จากนั้นระบบสามารถช่วยสร้างโค้ดที่สอดคล้องกับคำสั่ง ตัวอย่างเช่น

“เขียนโปรแกรมภาษา Python เพื่ออ่านข้อมูลจากไฟล์และคำนวณค่าเฉลี่ย”

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสร้างโครงสร้างของโปรแกรมตามเงื่อนไขที่ได้รับ

อย่างไรก็ตาม การสร้างโค้ดโดย ปัญญาประดิษฐ์เชิงสร้างสรรค์ ไม่ได้หมายความว่าโค้ดนั้นถูกต้องหรือสามารถใช้งานได้อย่างสมบูรณ์เสมอไป ผู้พัฒนายังคงจำเป็นต้องอ่าน ทำความเข้าใจ ทดสอบ และตรวจสอบผลลัพธ์ที่สร้างขึ้น

9.5.3. ตัวอย่างแนวคิดของ แบบจำลองเชิงสร้างสรรค์

ปัญญาประดิษฐ์เชิงสร้างสรรค์ ไม่ได้ใช้แบบจำลองเพียงประเภทเดียว นักวิจัยได้พัฒนาแนวคิดและสถาปัตยกรรมของ แบบจำลองเชิงสร้างสรรค์ หลายรูปแบบ โดยแต่ละแบบมีวิธีการเรียนรู้และสร้างข้อมูลที่แตกต่างกัน

ตัวอย่างแนวคิดที่สำคัญ ได้แก่

- **Generative Adversarial Network**

โครงข่ายปฏิปักษ์เชิงกำเนิด (Generative Adversarial Network: GAN) ใช้แนวคิดของแบบจำลองสองส่วน ได้แก่ ตัวสร้างข้อมูล (Generator) และตัวตรวจสอบข้อมูล (Discriminator)

Generator มีหน้าที่สร้างข้อมูลใหม่ ส่วน Discriminator มีหน้าที่ช่วยประเมินว่าข้อมูลที่ได้รับมีลักษณะใกล้เคียงกับข้อมูลจริงหรือไม่

แนวคิดของ GAN คือการแข่งขันระหว่างทั้งสองส่วนในระหว่างกระบวนการเรียนรู้ ซึ่งช่วยให้ Generator สามารถพัฒนาความสามารถในการสร้างข้อมูลที่มีลักษณะสมจริงมากขึ้น

- **Variational Autoencoder**

Variational Autoencoder (VAE) ใช้แนวคิดของการเรียนรู้การแทนข้อมูล โดยแบบจำลองพยายามเรียนรู้ลักษณะสำคัญและโครงสร้างของข้อมูลในรูปแบบที่สามารถนำมาใช้สร้างข้อมูลใหม่ได้

แนวคิดพื้นฐานสามารถมองได้ว่า

Input Data → Encoder → Data Representation → Decoder → Generated Data

VAE แสดงให้เห็นว่าแบบจำลองสามารถเรียนรู้โครงสร้างของข้อมูลและนำความรู้ที่ได้มาใช้ในการสร้างตัวอย่างใหม่ได้

- **Transformer**

ทรานส์ฟอร์มเมอร์ (Transformer) เป็นสถาปัตยกรรมของ Neural Network ที่มีบทบาทสำคัญอย่างมากต่อ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ในปัจจุบัน โดยเฉพาะงานที่เกี่ยวข้องกับภาษาและความ

แนวคิดสำคัญของ Transformer คือการพิจารณาความสัมพันธ์และบริบทระหว่างส่วนต่าง ๆ ของข้อมูล ซึ่งช่วยให้แบบจำลองสามารถจัดการกับข้อมูลที่มีลำดับและความสัมพันธ์ซับซ้อนได้

Transformer เป็นสถาปัตยกรรมพื้นฐานที่สำคัญของ แบบจำลองภาษาขนาดใหญ่ซึ่งจะกล่าวถึงรายละเอียดในหัวข้อถัดไป

- **Diffusion Model**


แบบจำลองการแพร่ (Diffusion Model) ใช้แนวคิดของการเรียนรู้กระบวนการสร้างข้อมูลผ่านการจัดการกับความสุ่มหรือสัญญาณรบกวน (Noise)

ในระดับแนวคิด สามารถมองได้ว่าแบบจำลองเรียนรู้กระบวนการเปลี่ยนข้อมูลจากลักษณะที่มีความสุ่มไปสู่ข้อมูลที่มีโครงสร้างและความหมาย

Random Noise → ลด Noise ทีละขั้น → Generated Data

แนวคิดนี้ได้รับความนิยมอย่างมากในงานด้านการสร้างภาพ เนื่องจากสามารถนำมาใช้สร้างผลลัพธ์ที่มีรายละเอียดและความซับซ้อนได้

การศึกษาโครงสร้างและรายละเอียดเชิงลึกของ GAN, VAE, Transformer หรือ Diffusion Model ต้องอาศัยความรู้ด้าน Deep Learning ในระดับสูงขึ้นไป สำหรับเนื้อหาในบทนี้ นักศึกษาควรเข้าใจว่าปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถใช้แบบจำลองได้หลายแนวทาง และแต่ละแนวทางมีวิธีการเรียนรู้และสร้างข้อมูลแตกต่างกัน



รูปที่ 9.13 ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถใช้ แบบจำลองเชิงสร้างสรรค์ ที่มีแนวคิดแตกต่างกันเพื่อเรียนรู้รูปแบบของข้อมูลและสร้างผลลัพธ์ใหม่

ในบรรดาสถาปัตยกรรมที่เกี่ยวข้องกับ ปัญญาประดิษฐ์เชิงสร้างสรรค์ นั้น Transformer มีบทบาทสำคัญอย่างมากต่อการพัฒนา แบบจำลองภาษาขนาดใหญ่หรือ LLM ซึ่งเป็นพื้นฐานของระบบ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ด้านภาษาที่สามารถสร้างข้อความ สนทนา วิเคราะห์ปัญหา และช่วยสนับสนุนการทำงานในลักษณะต่าง ๆ ได้

หัวข้อถัดไปจะอธิบาย Large Language Model และหลักการทำงานของแบบจำลอง ตั้งแต่การเปลี่ยนข้อความเป็น Token การใช้ Context การสร้างข้อความทีละส่วน บทบาทของ Transformer และแนวคิดของ Reasoning ในแบบจำลอง AI สมัยใหม่

9.6 แบบจำลองภาษาขนาดใหญ่และหลักการทำงาน

แบบจำลองภาษาขนาดใหญ่ (Large Language Model: LLM) เป็น Generative Model ประเภทหนึ่งที่ได้รับการพัฒนาขึ้นเพื่อเรียนรู้รูปแบบของภาษาจากข้อมูลข้อความจำนวนมาก LLM สามารถนำความรู้ที่เรียนรู้จากข้อมูลมาใช้ในการสร้างข้อความ ตอบคำถาม สรุปเนื้อหา แปลภาษา วิเคราะห์ข้อมูล และช่วยสร้างโปรแกรมได้

แบบจำลองที่มีขนาดใหญ่และมีพารามิเตอร์ (Parameter) จำนวนมาก รวมถึงผ่านการเรียนรู้จากข้อมูลจำนวนมาก ทำให้แบบจำลองสามารถเรียนรู้รูปแบบและความสัมพันธ์ของภาษาได้ในระดับที่ซับซ้อน

LLM เป็นตัวอย่างสำคัญของการนำ Neural Network และ Deep Learning มาประยุกต์ใช้กับข้อมูลภาษา โดยมีสถาปัตยกรรมที่สำคัญคือ Transformer ซึ่งช่วยให้แบบจำลองสามารถพิจารณาความสัมพันธ์และบริบทของข้อความได้อย่างมีประสิทธิภาพ การทำงานของ LLM ในระดับพื้นฐาน สามารถมองเป็นกระบวนการดังรูปที่ 9.14

จากรูปที่ 9.14 แม้ผลลัพธ์ของ LLM จะปรากฏเป็นข้อความที่มีลักษณะคล้ายการสนทนาหรือการเขียนของมนุษย์ แต่ภายในกระบวนการทำงาน แบบจำลองไม่ได้จัดการกับข้อความในลักษณะเดียวกับที่มนุษย์อ่านและเข้าใจภาษาโดยตรง ข้อความจะถูกแปลงให้อยู่ในรูปแบบที่แบบจำลองสามารถประมวลผลได้ก่อน

9.6.1. Context และความสัมพันธ์ของข้อความ

ในการสนทนาหรือการอ่านข้อความ ความหมายของคำหนึ่งคำอาจขึ้นอยู่กับข้อความที่อยู่ก่อนหน้า ตัวอย่างเช่นคำว่า “เขา” จะไม่สามารถทราบได้อย่างชัดเจนว่าหมายถึงบุคคลใด หากไม่มีข้อความก่อนหน้านี้ให้ข้อมูลประกอบ ตัวอย่างเช่น สมชายเป็นนักศึกษาวิศวกรรมคอมพิวเตอร์ เขากำลังศึกษาเรื่อง Artificial Intelligence คำว่า “เขา” มีความหมายสัมพันธ์กับคำว่า “สมชาย” ที่ปรากฏก่อนหน้านี้

ข้อมูลหรือข้อความที่ช่วยให้สามารถตีความความหมายได้เรียกว่า บริบท (Context) สำหรับ LLM Context หมายถึงข้อมูลที่แบบจำลองสามารถนำมาพิจารณาร่วมกันในขณะที่กำลังประมวลผลและสร้างข้อความ ตัวอย่างเช่น หากผู้ใช้กำหนดข้อความว่า “อธิบาย CNN สำหรับนักศึกษาวิศวกรรมคอมพิวเตอร์ โดย

ไม่ใช่คณิตศาสตร์ที่ซับซ้อน” ข้อความดังกล่าวไม่ได้บอกเพียงหัวข้อที่ต้องการเท่านั้น แต่ยังระบุเงื่อนไขของคำตอบ ได้แก่

- หัวข้อคือ CNN
- กลุ่มผู้อ่านคือนักศึกษาวิศวกรรมคอมพิวเตอร์
- ควรหลีกเลี่ยงคณิตศาสตร์ที่ซับซ้อน

ข้อมูลทั้งหมดนี้จะกลายเป็นส่วนหนึ่งของ Context ที่ช่วยกำหนดลักษณะของผลลัพธ์

อย่างไรก็ตาม LLM ไม่สามารถพิจารณาข้อมูลได้อย่างไม่จำกัด ข้อมูลที่สามารถนำมาพิจารณาในช่วงเวลาหนึ่งจะถูกจำกัดด้วยขนาดของ Context Window

หากการสนทนามีความยาวมาก หรือมีเอกสารจำนวนมาก ข้อมูลบางส่วนอาจไม่สามารถอยู่ภายใน Context เดียวกันได้ทั้งหมด

ดังนั้น การกำหนด Context ที่เหมาะสมจึงเป็นปัจจัยสำคัญต่อคุณภาพของผลลัพธ์

9.6.2. Token และการแทนข้อมูลภาษา

คอมพิวเตอร์ไม่สามารถนำข้อความในรูปแบบภาษามนุษย์ไปใช้ในการคำนวณได้โดยตรง ดังนั้น ก่อนที่ข้อความจะถูกนำเข้าสู่ LLM จำเป็นต้องมีการแบ่งและแปลงข้อความให้อยู่ในรูปแบบที่แบบจำลองสามารถประมวลผลได้ หน่วยข้อมูลที่ใช้ในการประมวลผลเรียกว่า โทเค็น (Token)

Token ไม่จำเป็นต้องมีขนาดเท่ากับคำหนึ่งคำเสมอไป ขึ้นอยู่กับวิธีการแบ่งข้อความของแต่ละระบบ Token อาจเป็น คำหนึ่งคำ ส่วนหนึ่งของคำ ตัวอักษร เครื่องหมายวรรคตอน หรือ สัญลักษณ์พิเศษ ตัวอย่างเช่น ประโยค “Artificial Intelligence is changing the world” อาจถูกแบ่งออกเป็น Token ในลักษณะ Artificial | Intelligence | is | changing | the | world | . ในบางระบบ คำที่มีความยาวหรือมีรูปแบบเฉพาะอาจถูกแบ่งออกเป็นหลาย Token ตัวอย่างเช่น ปัญญาประดิษฐ์เชิงสร้างสรรค์ อาจถูกแบ่งเป็นหน่วยข้อมูลมากกว่าหนึ่ง Token ตามวิธีการของ Tokenizer

กระบวนการแบ่งข้อความเป็น Token เรียกว่า Tokenization แนวคิดพื้นฐานสามารถแสดงได้ดังนี้

Text → Tokenization → Token → Numerical Representation → LLM


หลังจากข้อความถูกแบ่งเป็น Token แล้ว Token จะถูกแปลงเป็นค่าหรือตัวแทนเชิงตัวเลข เพื่อให้สามารถนำเข้าสู่ Neural Network ได้ สำหรับผู้ใช้ทั่วไป ไม่จำเป็นต้องทราบรายละเอียดของการเข้ารหัส Token แต่การเข้าใจแนวคิดนี้มีความสำคัญ เนื่องจาก LLM ไม่ได้ประมวลผลข้อความทั้งหมดในลักษณะของประโยคที่สมบูรณ์เพียงหน่วยเดียว แต่ประมวลผลข้อมูลในรูปแบบของ Token

สำหรับภาษาไทย แนวคิดเรื่อง Token มีความสำคัญเป็นพิเศษ เนื่องจากข้อความภาษาไทยมีลักษณะการเขียนที่แตกต่างจากภาษาอังกฤษ โดยทั่วไปภาษาอังกฤษมักใช้ช่องว่างเพื่อแยกคำ ขณะที่ภาษาไทยสามารถเขียนข้อความต่อเนื่องกันโดยไม่มีช่องว่างระหว่างทุกคำ เช่น ปัญญาประดิษฐ์กำลังเปลี่ยนแปลงโลก

ดังนั้น Tokenizer จำเป็นต้องวิเคราะห์ลำดับของตัวอักษรเพื่อพิจารณาว่าข้อความควรถูกแบ่งออกเป็นหน่วยใด นอกจากนี้ คำภาษาไทยหนึ่งคำอาจถูกแบ่งออกเป็นหลายส่วนตามวิธีการของ Tokenizer ทำให้ข้อความภาษาไทยที่มีความหมายใกล้เคียงกับข้อความภาษาอังกฤษอาจใช้จำนวน Token มากกว่า

ตัวอย่างเช่น ประโยคภาษาอังกฤษและภาษาไทยที่มีความหมายใกล้เคียงกันอาจมีจำนวน Token แตกต่างกัน ดังนั้น เมื่อใช้งาน LLM กับข้อความภาษาไทย ผู้ใช้ควรเข้าใจว่าความยาวของข้อความไม่ได้วัดจากจำนวนคำหรือจำนวนตัวอักษรเพียงอย่างเดียว แต่ยังขึ้นอยู่กับการแบ่ง Token ของแบบจำลองนั้นด้วย

ความแตกต่างนี้อาจส่งผลต่อปริมาณข้อความที่สามารถส่งเข้าสู่แบบจำลองภายใน Context Window และในบางระบบอาจเกี่ยวข้องกับปริมาณการประมวลผลหรือค่าใช้จ่ายบริการด้วย



รูปที่ 9.14 Context ช่วยให้ LLM สามารถพิจารณาความสัมพันธ์ระหว่างข้อความและสร้างผลลัพธ์ที่สอดคล้องกับคำสั่ง

9.6.3. การสร้างข้อความด้วยการทำนาย Token ถัดไป

หลักการสำคัญประการหนึ่งของ LLM คือการสร้างข้อความทีละ Token โดยอาศัยการทำนายว่า Token ใดควรปรากฏถัดไปจากข้อความและ Context ที่มีอยู่

ตัวอย่างเช่น หากมีข้อความว่า “Artificial Intelligence is” แบบจำลองอาจพิจารณาว่า Token ที่สามารถปรากฏถัดไปมีหลายความเป็นไปได้ เช่น

“changing” “a” “used” “becoming”

LLM จะประเมินความเป็นไปได้ของ Token ต่าง ๆ โดยอาศัยรูปแบบและความสัมพันธ์ที่ได้เรียนรู้จากข้อมูล

สามารถแสดงแนวคิดได้ดังนี้

Input Tokens → LLM → Probability of Next Tokens → Select Next Token

เมื่อเลือก Token ถัดไปแล้ว Token นั้นจะถูกนำไปรวมกับข้อความเดิม และกระบวนการจะเกิดขึ้นซ้ำอีกครั้ง ตัวอย่างเช่น

Artificial Intelligence

↓

Artificial Intelligence is

↓

Artificial Intelligence is changing

↓

Artificial Intelligence is changing the

↓

Artificial Intelligence is changing the way

กระบวนการดังกล่าวจะดำเนินต่อไปจนกว่าจะสร้างข้อความเสร็จสมบูรณ์ หรือถึงเงื่อนไขที่กำหนด

แนวคิดนี้ช่วยอธิบายได้ว่า เหตุใด LLM จึงสามารถสร้างข้อความที่มีความต่อเนื่องเป็นประโยคย่อหน้า หรือเอกสารที่มีความยาวได้ แม้กระบวนการพื้นฐานของการสร้างผลลัพธ์จะเกิดขึ้นทีละ Token สิ่งสำคัญคือ LLM ไม่ได้เลือก Token จากรายการคำตอบที่กำหนดไว้ล่วงหน้า แต่ใช้แบบจำลองในการประเมิน Token ที่มีความเหมาะสมกับ Context ในขณะนั้น

อย่างไรก็ตาม Token ที่มีความน่าจะเป็นสูงที่สุดไม่จำเป็นต้องถูกเลือกเสมอไป กระบวนการสร้างข้อความสามารถกำหนดรูปแบบการเลือกที่แตกต่างกัน เพื่อให้ผลลัพธ์มีความหลากหลายหรือมีความคาดเดาได้น้อยลง ในระดับพื้นฐาน สามารถมองได้ว่า ข้อความที่มีการเลือก Token อย่างคาดเดาได้มาก → มีความสม่ำเสมอมากขึ้น

ขึ้น

ข้อความที่มีการเปิดโอกาสให้เลือก Token ที่หลากหลาย → มีความหลากหลายและสร้างสรรค์มาก

9.6.4. บทบาทของ Transformer ใน Large Language Models


Transformer เป็นสถาปัตยกรรมของ Neural Network ที่มีบทบาทสำคัญต่อการพัฒนา LLM ก่อนหน้านี้ งานด้านการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) มักใช้แบบจำลองที่ประมวลผลข้อมูลตามลำดับ เช่น Recurrent Neural Network หรือ RNN ซึ่งได้รับการกล่าวถึงในบทที่ 8

อย่างไรก็ตาม ข้อความหนึ่งประโยคอาจมีความสัมพันธ์ระหว่างคำที่อยู่ห่างกัน ตัวอย่างเช่น “นักศึกษาที่ศึกษาวิชา Artificial Intelligence สามารถนำความรู้ที่ได้รับไปประยุกต์ใช้กับปัญหาต่าง ๆ ได้”

การตีความความหมายของบางคำอาจต้องพิจารณาคำหรือข้อความที่อยู่ห่างออกไป ไม่ได้ขึ้นอยู่กับคำที่อยู่ก่อนหน้าเพียงคำเดียว

Transformer ช่วยให้แบบจำลองสามารถพิจารณาความสัมพันธ์ระหว่างส่วนต่าง ๆ ของข้อมูลและนำข้อมูลเหล่านั้นมาใช้ร่วมกันในการประมวลผล

แนวคิดพื้นฐานสามารถมองได้ดังนี้




ในบทนี้ไม่จำเป็นต้องศึกษารายละเอียดของ Attention Mechanism หรือโครงสร้างภายในของ Transformer แต่ควรเข้าใจว่า Transformer เป็นสถาปัตยกรรมที่ช่วยให้ LLM สามารถจัดการกับความสัมพันธ์และบริบทของข้อความได้อย่างมีประสิทธิภาพ

จากแนวคิดดังกล่าว LLM จึงไม่ได้พิจารณา Token แต่ละตัวอย่างอิสระจากกัน แต่ใช้ Context และความสัมพันธ์ระหว่างข้อมูลที่อยู่ภายในขอบเขตที่แบบจำลองสามารถพิจารณาได้

9.6.5. Prompt และการกำหนดคำสั่งให้ LLM

คำสั่งหรือข้อมูลที่ใช้ป้อนเข้าสู่ ปัญญาประดิษฐ์เชิงสร้างสรรค์ เรียกว่า พรอมต์ (Prompt)

Prompt สามารถเป็นได้หลายรูปแบบ เช่น คำถาม คำสั่ง ข้อความอธิบาย ตัวอย่าง เงื่อนไข ข้อมูล ประกอบ ตัวอย่าง Prompt ที่เรียบง่าย เช่น “อธิบายการทำงานของ CNN” แม้ Prompt ดังกล่าวจะทำให้ LLM สามารถสร้างคำตอบได้ แต่ผู้ใช้อย่างไม่ได้ระบุกลุ่มผู้อ่าน ระดับความลึก หรือรูปแบบของคำตอบ หากปรับ Prompt เป็น “อธิบายหลักการทำงานของ CNN สำหรับนักศึกษาวิศวกรรมคอมพิวเตอร์ระดับปริญญาตรี โดยใช้ภาษาที่เข้าใจง่าย และยกตัวอย่างการประยุกต์ใช้” Prompt นี้ให้ข้อมูลเพิ่มเติมแก่แบบจำลอง ทำให้ Context มีรายละเอียดมากขึ้น Prompt ที่เหมาะสมจึงช่วยกำหนด สิ่งที่ต้องการให้ทำ ขอบเขตของคำตอบ กลุ่มเป้าหมาย รูปแบบของผลลัพธ์ และ เงื่อนไขหรือข้อจำกัดดังรูปที่ 9.15



รูปที่ 9.15 Prompt เป็นข้อมูลสำคัญที่กำหนด Context และส่งผลต่อลักษณะของผลลัพธ์ที่ LLM สร้างขึ้น

อย่างไรก็ตาม Prompt ที่มีรายละเอียดมากขึ้นไม่ได้หมายความว่าจะให้ผลลัพธ์ที่ถูกต้องเสมอไป คุณภาพของผลลัพธ์ยังขึ้นอยู่ความสามารถของแบบจำลอง ข้อมูลที่เกี่ยวข้องกับคำถาม และลักษณะของปัญหา ดังนั้นการกำหนด Prompt ควรถือเป็นการสื่อสารความต้องการกับแบบจำลอง ไม่ใช่กลไกที่รับประกันความถูกต้องของคำตอบ

9.6.6. แนวคิดของ Reasoning ใน Large Language Models

ความสามารถที่ทำให้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ และ LLM ได้รับความสนใจอย่างมากในปัจจุบัน ไม่ได้จำกัดอยู่เพียงการสร้างข้อความที่มีความต่อเนื่อง แต่ยังรวมถึงความสามารถในการช่วยวิเคราะห์ปัญหา วางแผน และแก้ปัญหาที่ต้องอาศัยหลายขั้นตอน ความสามารถในการลักษณะนี้มักเรียกว่า การให้เหตุผล (Reasoning) ตัวอย่างเช่น พิจารณาปัญหา “ระบบหนึ่งมีผู้ใช้ 120 คน แต่ละคนส่งข้อมูล 5 รายการต่อวัน ระบบจะได้รับข้อมูลทั้งหมดกี่รายการต่อวัน”

การตอบคำถามนี้ไม่ได้อาศัยเพียงการเลือกคำตอบที่เหมาะสมเท่านั้น แต่ต้องมีการวิเคราะห์ความสัมพันธ์ของข้อมูล ได้แก่ จำนวนผู้ใช้ จำนวนรายการต่อคน ดังนั้น

$$120 \times 5 = 600$$

คำตอบคือ 600 รายการต่อวัน

สำหรับมนุษย์ เราสามารถมองกระบวนการนี้เป็นลำดับของขั้นตอน

ทำความเข้าใจปัญหา → ระบุข้อมูลที่เกี่ยวข้อง → เลือกวิธีแก้ปัญหา → ดำเนินการแก้ปัญหา → สรุป
คำตอบ

ใน LLM สมัยใหม่ แบบจำลองสามารถถูกออกแบบหรือปรับปรุงให้มีความสามารถในการจัดการกับปัญหาที่ต้องอาศัยการวิเคราะห์หลายขั้นตอนมากขึ้น

อย่างไรก็ตาม ควรเข้าใจว่า Reasoning ของ LLM ไม่ได้หมายความว่าแบบจำลองมีความคิดหรือจิตสำนึกเหมือนมนุษย์ แต่หมายถึงความสามารถของระบบในการสร้างกระบวนการหรือผลลัพธ์ที่สามารถใช้ในการจัดการกับปัญหาที่มีหลายขั้นตอนและมีความซับซ้อน

Reasoning มีความสำคัญต่อการประยุกต์ใช้ LLM ในงานที่ไม่ได้ต้องการเพียงการสร้างข้อความ เช่น


- การวิเคราะห์โจทย์ทางคณิตศาสตร์
- การช่วยแก้ปัญหาคodingโปรแกรม
- การวิเคราะห์ข้อผิดพลาดของโปรแกรม
- การวางแผนขั้นตอนการทำงาน
- การวิเคราะห์ข้อมูล
- การเปรียบเทียบทางเลือก

ตัวอย่างในงานด้านวิศวกรรมคอมพิวเตอร์ ผู้ใช้อาจกำหนดปัญหาว่า “โปรแกรมไม่สามารถเชื่อมต่อกับฐานข้อมูลได้ ให้ช่วยวิเคราะห์สาเหตุที่เป็นไปได้” ระบบอาจช่วยวิเคราะห์ปัญหาเป็นลำดับ เช่น

1. ตรวจสอบการเชื่อมต่อเครือข่าย
2. ตรวจสอบชื่อ Host และ Port
3. ตรวจสอบชื่อผู้ใช้และรหัสผ่าน
4. ตรวจสอบสถานะของ Database Server
5. ตรวจสอบการตั้งค่า Firewall หรือสิทธิ์ในการเข้าถึง

ผลลัพธ์ในลักษณะนี้แสดงให้เห็นว่า LLM สามารถช่วยจัดระเบียบข้อมูล วิเคราะห์ความสัมพันธ์ และเสนอขั้นตอนในการแก้ปัญหาได้

อย่างไรก็ตาม ความสามารถด้าน Reasoning ไม่ได้หมายความว่าแบบจำลองจะให้เหตุผลได้ถูกต้องทุกครั้ง LLM ยังสามารถเลือกข้อมูลที่ไม่เกี่ยวข้อง สรุปความสัมพันธ์ผิด หรือสร้างคำตอบที่ดูมีเหตุผลแต่ไม่ถูกต้องได้ ดังนั้น ผลลัพธ์จาก LLM ควรถูกมองว่าเป็นข้อมูลหรือข้อเสนอที่ช่วยสนับสนุนการคิดและการแก้ปัญหา ไม่ใช่ข้อสรุปที่ถูกต้องโดยอัตโนมัติ



รูปที่ 9.16 LLM รับข้อความเป็น Token ประมวลผล Context ผ่านสถาปัตยกรรม Transformer และสร้างผลลัพธ์ทีละ Token

9.6.7. ภาพรวมการทำงานของ Large Language Model

จากเนื้อหาที่กล่าวมาสามารถสรุปภาพรวมการทำงานของ LLM ได้รูปที่ 9.16 จะเห็นว่า แม้การทำงานพื้นฐานของ LLM จะสามารถอธิบายได้ว่าเป็นการทำนาย Token ถัดไป แต่เมื่อแบบจำลองได้รับการฝึกจากข้อมูลจำนวนมากและมีความสามารถในการเรียนรู้ความสัมพันธ์ที่ซับซ้อน กระบวนการดังกล่าวสามารถนำไปสู่ความสามารถที่หลากหลาย เช่น การสนทนา การสรุป การแปล การสร้างโค้ด การวิเคราะห์ปัญหา และการช่วยสนับสนุนการให้เหตุผล

ความเข้าใจหลักที่นักศึกษาควรได้รับจากหัวข้อนี้คือ LLM ไม่ได้ทำงานโดยการค้นหาคำตอบจากฐานข้อมูลคำตอบสำเร็จรูป แต่ใช้แบบจำลองที่เรียนรู้รูปแบบของข้อมูลภาษาเพื่อประมวลผล Context และสร้างผลลัพธ์ทีละ Token

อย่างไรก็ตาม ความสามารถในการสร้างข้อความที่มีความต่อเนื่องและมีลักษณะคล้ายคำตอบที่น่าเชื่อถือ ไม่ได้หมายความว่าผลลัพธ์นั้นถูกต้องเสมอไป ประเด็นนี้นำไปสู่ข้อจำกัดและข้อควรพิจารณาในการใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ซึ่งจะกล่าวถึงในหัวข้อถัดไป และจะเชื่อมโยงไปสู่การศึกษาประเด็นด้านจริยธรรมของ AI ในบทที่ 10

• 9.7 ข้อจำกัดและการใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ อย่างรอบคอบ

ปัญญาประดิษฐ์เชิงสร้างสรรค์ และ แบบจำลองภาษาขนาดใหญ่สามารถช่วยสร้างข้อความ ภาพ เสียง วิดีโอ และโค้ด รวมถึงสนับสนุนการวิเคราะห์และการแก้ปัญหาได้ อย่างไรก็ตาม ความสามารถในการสร้างผลลัพธ์ที่มีลักษณะคล้ายกับผลงานของมนุษย์ ไม่ได้หมายความว่าผลลัพธ์ที่สร้างขึ้นจะถูกต้อง เหมาะสม หรือสามารถนำไปใช้งานได้โดยไม่ต้องตรวจสอบ

การใช้งาน ปัญญาประดิษฐ์เชิงสร้างสรรค์ จึงควรทำความเข้าใจทั้งความสามารถและข้อจำกัดของเทคโนโลยี เพื่อให้สามารถนำไปใช้เป็นเครื่องมือสนับสนุนการทำงานได้อย่างเหมาะสม

• 9.7.1 Hallucination และความถูกต้องของผลลัพธ์

ข้อจำกัดสำคัญประการหนึ่งของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ คือการสร้างข้อมูลที่ดูสมเหตุสมผลหรือมีลักษณะน่าเชื่อถือ แต่มีเนื้อหาที่ไม่ถูกต้อง ปรากฏการณ์นี้มักเรียกว่า การสร้างข้อมูลคลาดเคลื่อน (Hallucination) ตัวอย่างเช่น ผู้ใช้ถามจากระบบเกี่ยวกับหนังสือ งานวิจัย บุคคล หรือเหตุการณ์บางอย่าง ระบบอาจสร้างคำตอบที่มีรายละเอียดครบถ้วน เช่น

- ชื่อหนังสือ
- ชื่อผู้เขียน
- ชื่อวารสาร
- ปีที่ตีพิมพ์
- รายละเอียดของงานวิจัย

แต่ข้อมูลบางส่วนหรือทั้งหมดอาจไม่มีอยู่จริง

ปัญหานี้เกิดขึ้นได้เนื่องจาก ปัญญาประดิษฐ์เชิงสร้างสรรค์ มีหน้าที่หลักในการสร้างผลลัพธ์ที่สอดคล้องกับรูปแบบและ Context ที่ได้รับ ไม่ได้หมายความว่าแบบจำลองจะตรวจสอบข้อเท็จจริงจากแหล่งข้อมูลภายนอกทุกครั้ง ดังนั้น ข้อความที่สร้างขึ้นอย่างถูกต้องตามหลักภาษา มีรายละเอียดมาก หรือมีลักษณะมั่นใจ ไม่สามารถใช้เป็นหลักฐานว่าข้อมูลนั้นถูกต้อง

ในการสร้างโค้ดสามารถเกิด Hallucination ขึ้นได้เช่นกัน ตัวอย่างเช่น ปัญญาประดิษฐ์เชิงสร้างสรรค์ อาจ

- แนะนำชื่อฟังก์ชันที่ไม่มีอยู่จริง
- ใช้ API ที่ไม่ตรงกับเวอร์ชันของ Library
- สร้างโค้ดที่มีข้อผิดพลาดทางตรรกะ
- อธิบายการทำงานของโปรแกรมไม่ถูกต้อง

ดังนั้น การนำโค้ดที่สร้างโดย ปัญญาประดิษฐ์เชิงสร้างสรรค์ ไปใช้งานโดยไม่อ่านหรือทดสอบ อาจทำให้เกิดข้อผิดพลาดหรือปัญหาด้านความปลอดภัยได้

แนวทางที่เหมาะสมคือ

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สร้างผลลัพธ์ → ผู้ใช้ตรวจสอบ → ทดสอบหรือเปรียบเทียบกับแหล่งข้อมูลที่เชื่อถือได้ → นำไปใช้งาน

นักศึกษาจึงควรมอง ปัญญาประดิษฐ์เชิงสร้างสรรค์ เป็น ผู้ช่วยในการสร้างและวิเคราะห์ข้อมูล ไม่ใช่แหล่งข้อมูลที่ต้องการโดยอัตโนมัติ

• 9.7.2 Bias และผลกระทบจากข้อมูลที่ใช้ในการเรียนรู้

แบบจำลอง AI เรียนรู้จากข้อมูล ดังนั้น ลักษณะของข้อมูลที่ใช้ในการฝึกล้วนส่งผลต่อพฤติกรรมและผลลัพธ์ของแบบจำลอง หากข้อมูลมีความเอนเอียง (Bias) หรือมีการนำเสนอมุมมองของบางกลุ่มมากกว่ากลุ่มอื่น ผลลัพธ์ที่สร้างโดย AI ก็อาจสะท้อนความเอนเอียงดังกล่าว ตัวอย่างเช่น หากข้อมูลที่ใช้ในการเรียนรู้มีตัวอย่างเกี่ยวกับอาชีพบางประเภทที่เชื่อมโยงกับกลุ่มบุคคลในลักษณะเดิมซ้ำ ๆ แบบจำลองอาจสร้างเนื้อหาที่สะท้อนรูปแบบดังกล่าว

Bias อาจส่งผลกระทบต่อหลายด้าน เช่น

- การนำเสนอข้อมูล
- การใช้ภาษา
- การให้คำแนะนำ
- การสร้างภาพ
- การจัดลำดับหรือเลือกข้อมูล

ประเด็นสำคัญคือ Bias ไม่ได้หมายความว่าแบบจำลองมีความตั้งใจที่จะเลือกปฏิบัติ แต่เป็นผลที่อาจเกิดขึ้นจากข้อมูล กระบวนการเรียนรู้ และวิธีการออกแบบระบบ

ผู้ใช้งานจึงควรพิจารณาว่าผลลัพธ์ที่สร้างขึ้นอาจมีมุมมองหรือข้อจำกัดบางอย่าง และไม่ควรรนำผลลัพธ์ไปใช้ในสถานการณ์สำคัญโดยไม่ตรวจสอบ

• 9.7.3 Privacy และข้อมูลส่วนบุคคล

การใช้งาน ปัญญาประดิษฐ์เชิงสร้างสรรค์ มักเกี่ยวข้องกับการส่งข้อมูลเข้าสู่ระบบผ่าน Prompt หรือไฟล์ประกอบ ผู้ใช้จึงควรพิจารณาว่าข้อมูลที่ส่งเข้าสู่ระบบมีความละเอียดอ่อนหรือไม่

ตัวอย่างข้อมูลที่ควรระมัดระวัง ได้แก่

- รหัสผ่าน
- ข้อมูลส่วนบุคคล
- ข้อมูลทางการเงิน
- ข้อมูลภายในองค์กร
- Source Code ที่เป็ความลับ
- เอกสารที่ยังไม่ได้เผยแพร่

การนำข้อมูลเข้าสู่ระบบ AI โดยไม่พิจารณาโยบายการจัดการข้อมูล อาจทำให้เกิดความเสี่ยงด้านความเป็นส่วนตัวหรือความลับของข้อมูล ดังนั้น ก่อนใช้งาน ปัญญาประดิษฐ์เชิงสร้างสรรค์ ควรพิจารณาว่าข้อมูลนี้สามารถเปิดเผยได้หรือไม่ ระบบที่ใช้งานมีนโยบายเกี่ยวกับการจัดเก็บและการใช้ข้อมูลอย่างไร ผลลัพธ์หรือข้อมูลที่ป้อนเข้าสู่ระบบอาจส่งผลกระทบต่อบุคคลหรือองค์กรอื่นหรือไม่

ประเด็นด้าน Privacy จะมีความสำคัญมากขึ้นเมื่อ AI ถูกนำไปใช้กับข้อมูลจริงของผู้ใช้ องค์กร หรือระบบสารสนเทศ

• 9.7.4 Copyright และการใช้เนื้อหาที่สร้างโดย AI

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสร้างข้อความ ภาพ เพลง และโค้ดได้อย่างรวดเร็ว ทำให้เกิดคำถามเกี่ยวกับลิขสิทธิ์ (Copyright) และความเป็นเจ้าของผลงาน

ประเด็นที่ควรพิจารณา ได้แก่

- ข้อมูลที่ใช้ในการฝึกแบบจำลองมาจากแหล่งใด
- ผลงานที่สร้างขึ้นมีลักษณะใกล้เคียงกับผลงานเดิมหรือไม่
- สามารถนำผลลัพธ์ไปใช้ในเชิงพาณิชย์ได้หรือไม่
- ผู้ใช้มีสิทธิ์ในการนำผลลัพธ์ไปเผยแพร่หรือไม่
- ผลงานที่สร้างโดย AI ต้องมีการเปิดเผยหรือระบุแหล่งที่มาหรือไม่

ในทางปฏิบัติ เงื่อนไขเกี่ยวกับการใช้งาน ปัญญาประดิษฐ์เชิงสร้างสรรค์ และผลลัพธ์ที่สร้างขึ้นอาจแตกต่างกันตามผู้ให้บริการ ระบบ หรือกฎหมายที่เกี่ยวข้อง สำหรับนักศึกษา ประเด็นสำคัญคือไม่ควรนำเนื้อหาที่สร้างโดย AI มาใช้โดยไม่ตรวจสอบแหล่งที่มา โดยเฉพาะในงานวิชาการ

หากใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ เพื่อช่วยในการเขียนหรือสรุปข้อมูล ควรตรวจสอบข้อมูลจากแหล่งอ้างอิงจริง และปฏิบัติตามข้อกำหนดของรายวิชา สถาบัน หรือองค์กรที่เกี่ยวข้อง

• 9.7.5 Security และการใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ในงานวิศวกรรมคอมพิวเตอร์

ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถช่วยนักพัฒนาซอฟต์แวร์ได้หลายด้าน เช่น

- อธิบายโค้ด
- ช่วยสร้างตัวอย่างโปรแกรม
- วิเคราะห์ข้อผิดพลาด
- ช่วยออกแบบขั้นตอนวิธี
- สรุปเอกสารทางเทคนิค

อย่างไรก็ตาม การใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ในงานพัฒนาซอฟต์แวร์ยังมีประเด็นด้านความปลอดภัย (Security) ที่ควรพิจารณา ตัวอย่างเช่น โค้ดที่สร้างโดย AI อาจ

- มีช่องโหว่ด้านความปลอดภัย
- ไม่มีการตรวจสอบข้อมูลนำเข้าอย่างเหมาะสม
- เปิดเผยข้อมูลสำคัญผ่านการจัดการข้อผิดพลาด
- ใช้วิธีการหรือ Library ที่ไม่เหมาะสม
- ไม่สอดคล้องกับมาตรฐานของระบบ

ดังนั้น แม้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ จะสามารถช่วยลดเวลาในการเขียนโค้ด แต่ผู้พัฒนายังคงต้องมีความรู้พื้นฐานในการตรวจสอบและทดสอบโปรแกรม การทำงานที่เหมาะสมจึงไม่ใช่ AI สร้างโค้ดแล้วสามารถนำไปใช้งานทันที แต่ควรเป็น

AI สร้างโค้ด → อ่านและทำความเข้าใจ → ตรวจสอบ → ทดสอบ → ปรับปรุง → นำไปใช้งาน

แนวคิดนี้สอดคล้องกับหลักการพื้นฐานของวิศวกรรมซอฟต์แวร์ ซึ่งไม่ว่าซอร์สโค้ดจะถูกเขียนโดยมนุษย์หรือสร้างขึ้นโดย AI ก็ยังจำเป็นต้องผ่านกระบวนการตรวจสอบและทดสอบ

• 9.7.6 การใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ อย่างรับผิดชอบ

จากข้อจำกัดที่กล่าวมา ปัญญาประดิษฐ์เชิงสร้างสรรค์ ควรถูกนำมาใช้ในฐานะเครื่องมือที่ช่วยเพิ่มประสิทธิภาพในการทำงานและสนับสนุนการคิด ไม่ใช่เครื่องมือที่ใช้แทนการตัดสินใจของมนุษย์ในทุกสถานการณ์ แนวทางพื้นฐานในการใช้งาน ปัญญาประดิษฐ์เชิงสร้างสรรค์ อย่างรอบคอบสามารถสรุปได้ดังนี้

1) ตรวจสอบความถูกต้องของผลลัพธ์

ข้อมูลที่สร้างขึ้นควรได้รับการตรวจสอบ โดยเฉพาะข้อมูลที่เกี่ยวข้องกับข้อเท็จจริง งานวิชาการ โปรแกรม หรือการตัดสินใจที่สำคัญ

2) ไม่เปิดเผยข้อมูลที่มีความละเอียดอ่อนโดยไม่จำเป็น

ผู้ใช้ควรพิจารณาข้อมูลก่อนนำเข้าสู่ระบบ AI และปฏิบัติตามนโยบายด้านความเป็นส่วนตัวของระบบ ที่ใช้งาน

3) เข้าใจและตรวจสอบสิ่งที่ AI สร้างขึ้น


โดยเฉพาะในงานด้านวิศวกรรมคอมพิวเตอร์ ผู้ใช้ควรสามารถอธิบายหลักการทำงานของโค้ดที่นำไปใช้งานได้

4) ใช้ AI เป็นเครื่องมือสนับสนุนการเรียนรู้

สำหรับนักศึกษา ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถช่วยอธิบายแนวคิด ยกตัวอย่าง เปรียบเทียบ วิธีการ และช่วยตรวจสอบความเข้าใจได้ แต่ไม่ควรใช้เพียงเพื่อสร้างคำตอบแล้วนำเสนอโดยไม่มีการเรียนรู้หรือทำความเข้าใจเนื้อหา

5) พิจารณาผลกระทบจากการใช้งาน

ก่อนนำผลลัพธ์ไปใช้ ควรพิจารณาว่าผลลัพธ์อาจส่งผลกระทบต่อบุคคลอื่น ความเป็นธรรม ความเป็นส่วนตัว หรือความปลอดภัยหรือไม่



รูปที่ 9.17 ปัญญาประดิษฐ์เชิงสร้างสรรค์ สามารถสนับสนุนการทำงานได้ แต่ผู้ใช้อย่างงมีบทบาทสำคัญในการตรวจสอบและตัดสินใจ

จากรูปที่ 9.17 แนวคิดสำคัญของการใช้ ปัญญาประดิษฐ์เชิงสร้างสรรค์ คือ การมีมนุษย์ทำหน้าที่กำกับ (Human Oversight) ตรวจสอบ และตัดสินใจเกี่ยวกับผลลัพธ์ที่ AI สร้างขึ้น ปัญญาประดิษฐ์เชิง

สร้างสรรค์ จึงไม่ควรถูกมองว่าเป็นเพียงระบบที่สามารถตอบคำถามหรือสร้างเนื้อหาได้เท่านั้น แต่เป็นเทคโนโลยีที่ส่งผลต่อวิธีการทำงาน การเรียนรู้ การพัฒนาซอฟต์แวร์ และการเข้าถึงข้อมูลของมนุษย์

การนำ AI ไปใช้จึงจำเป็นต้องพิจารณาทั้งด้านเทคนิค ความถูกต้อง ผลกระทบต่อผู้ใช้งาน และความรับผิดชอบต่อผลลัพธ์ที่เกิดขึ้น ประเด็นเหล่านี้จะเชื่อมโยงไปสู่เนื้อหาใน บทที่ 10 จริยธรรมและความรับผิดชอบต่อปัญญาประดิษฐ์ (AI Ethics and Responsible AI) ซึ่งจะศึกษาประเด็นด้านผลกระทบ ความเป็นธรรม ความโปร่งใส ความรับผิดชอบต่อสังคม และแนวทางในการพัฒนาและใช้งาน AI อย่างเหมาะสม

แบบฝึกหัดท้ายบทที่ 9

1. จงอธิบายความหมายของปัญญาประดิษฐ์สมัยใหม่ (Modern AI) และยกตัวอย่างการประยุกต์ใช้งานในชีวิตประจำวันอย่างน้อย 3 ตัวอย่าง
2. จงอธิบายความแตกต่างระหว่างปัญญาประดิษฐ์แบบดั้งเดิม (Traditional AI) และปัญญาประดิษฐ์สมัยใหม่ (Modern AI)
3. เพราะเหตุใดปัญญาประดิษฐ์สมัยใหม่จึงสามารถแก้ปัญหาที่ซับซ้อนได้ดีกว่าปัญญาประดิษฐ์แบบดั้งเดิม
4. Deep Learning คืออะไร และมีความสัมพันธ์กับ Artificial Intelligence และ Machine Learning อย่างไร
5. จงอธิบายหลักการเรียนรู้คุณลักษณะโดยอัตโนมัติ (Automatic Feature Learning) ของ Deep Learning พร้อมยกตัวอย่างประกอบ
6. จงยกตัวอย่างสถาปัตยกรรมของ Deep Learning ที่สำคัญอย่างน้อย 3 ชนิด และอธิบายลักษณะการใช้งานของแต่ละชนิดโดยสังเขป
7. Transformer คืออะไร และเหตุใดจึงมีความสำคัญต่อการพัฒนา AI ในปัจจุบัน
8. กลไก Attention มีบทบาทสำคัญต่อ Transformer อย่างไร
9. Large Language Model (LLM) คืออะไร และแตกต่างจากระบบค้นหาข้อมูล (Search Engine) อย่างไร
10. จงอธิบายหลักการทำงานของแบบจำลองภาษาขนาดใหญ่ที่ใช้การทำนายคำถัดไป (Next Token Prediction)
11. Prompt คืออะไร และเหตุใดการออกแบบ Prompt ที่เหมาะสมจึงมีผลต่อคุณภาพของผลลัพธ์ที่ได้จาก AI
12. ปัญญาประดิษฐ์เชิงสร้างสรรค์ แตกต่างจาก AI แบบที่ใช้จำแนกข้อมูล (Discriminative AI) อย่างไร
13. จงยกตัวอย่างประเภทของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ อย่างน้อย 4 ประเภท พร้อมยกตัวอย่างเครื่องมือที่เกี่ยวข้อง
14. จงอธิบายประโยชน์ของ ปัญญาประดิษฐ์เชิงสร้างสรรค์ ในด้านการศึกษา ธุรกิจ และอุตสาหกรรมซอฟต์แวร์
15. Hallucination คืออะไร และผู้ใช้งานควรปฏิบัติอย่างไรเพื่อป้องกันผลกระทบจากปัญหาดังกล่าว
16. จงอธิบายแนวคิด Human + AI และแสดงความคิดเห็นว่าการทำงานร่วมกันระหว่างมนุษย์และ AI มีข้อดีอย่างไร